

Detecção e Segmentação de objetos

Aprendizado de máquina e aprendizado profundo - Lux.AI

INSTITUIÇÃO EXECUTORA



COORDENADORA

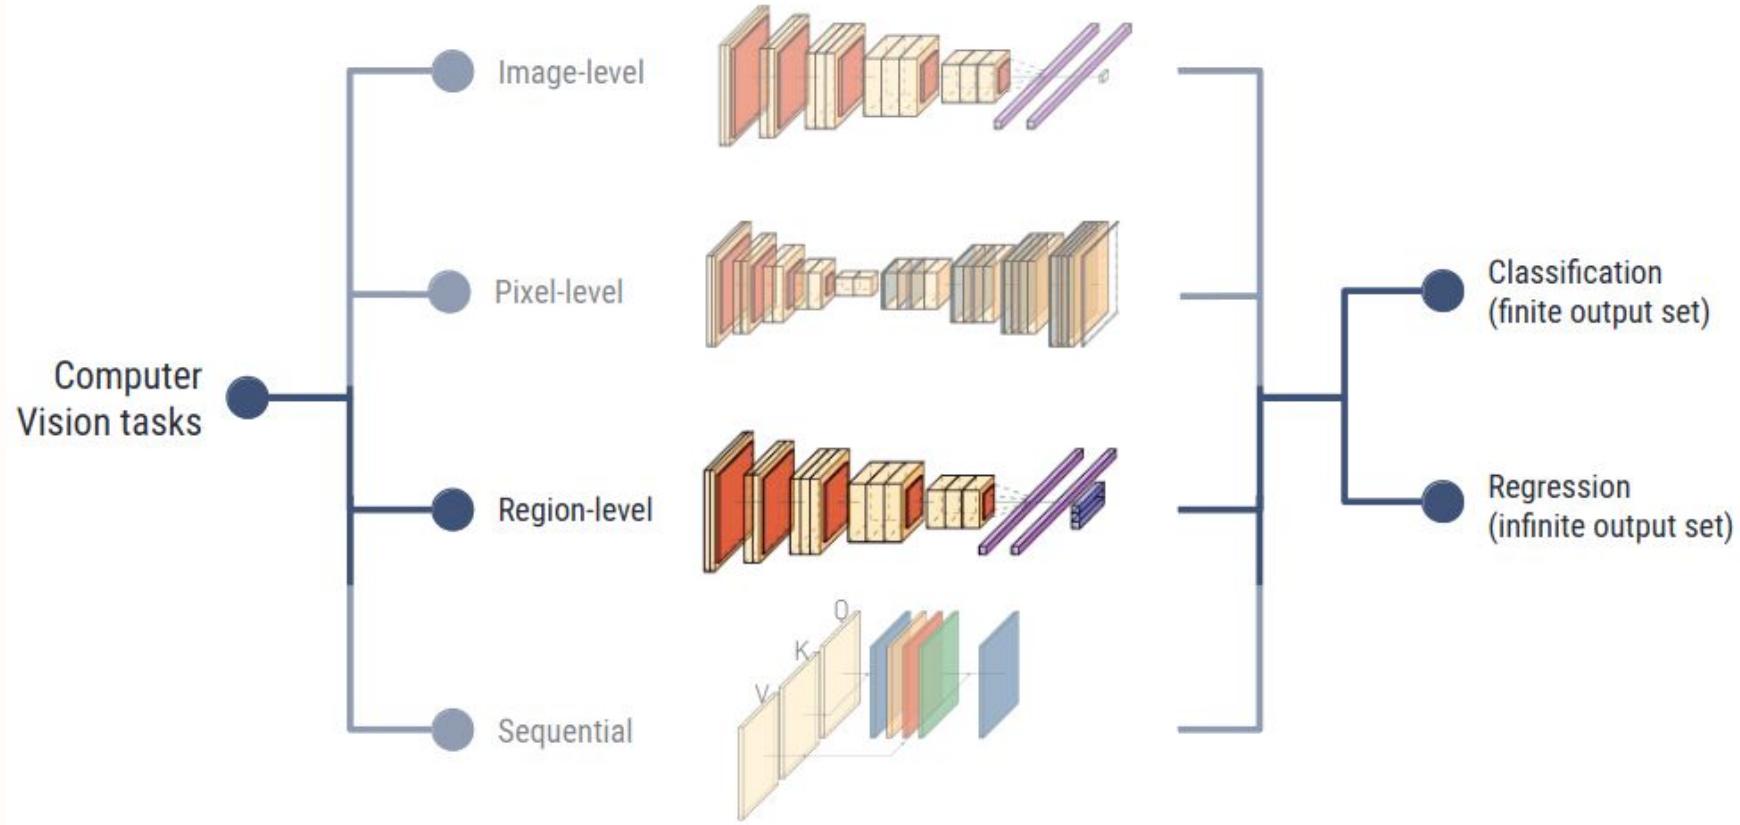


APOIO



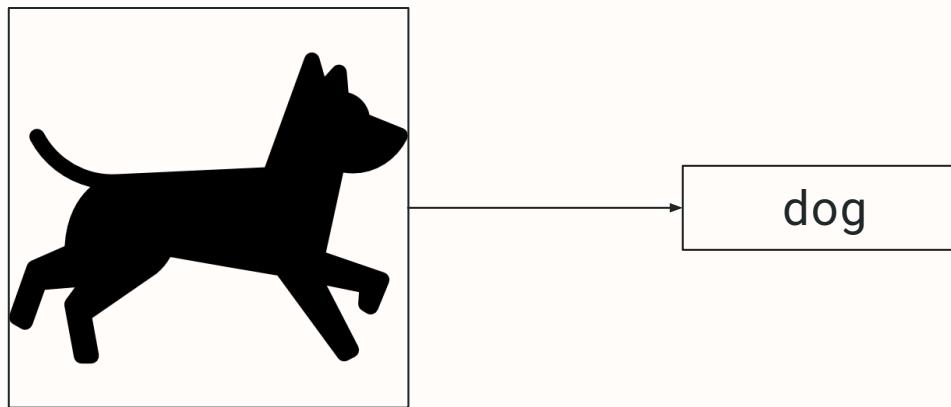
Detecção 2D - Introdução

Tarefas em visão computacional



Classificação de objetos

- A **Classificação** busca categorizar se a imagem de entrada contém um objeto de interesse
 - ◆ Geralmente temos o objeto de interesse em **evidência** na imagem, e precisamos apenas estimar a qual **classe** o objeto pertence



Classificação de objetos

6: frog



9: truck



9: truck



4: deer



1: automobile



1: automobile



2: bird



7: horse



8: ship



3: cat



4: deer



7: horse



7: horse



2: bird



9: truck



9: truck



9: truck



3: cat



2: bird

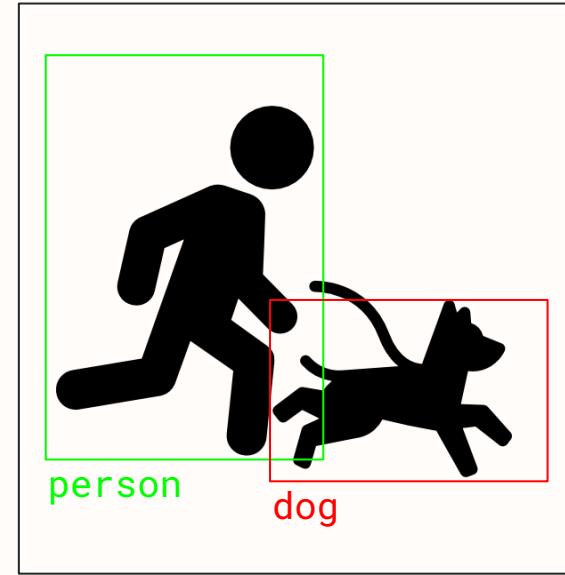
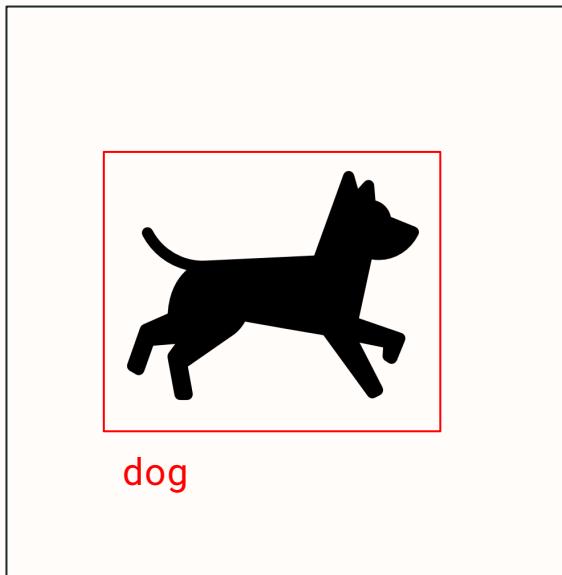


6: frog

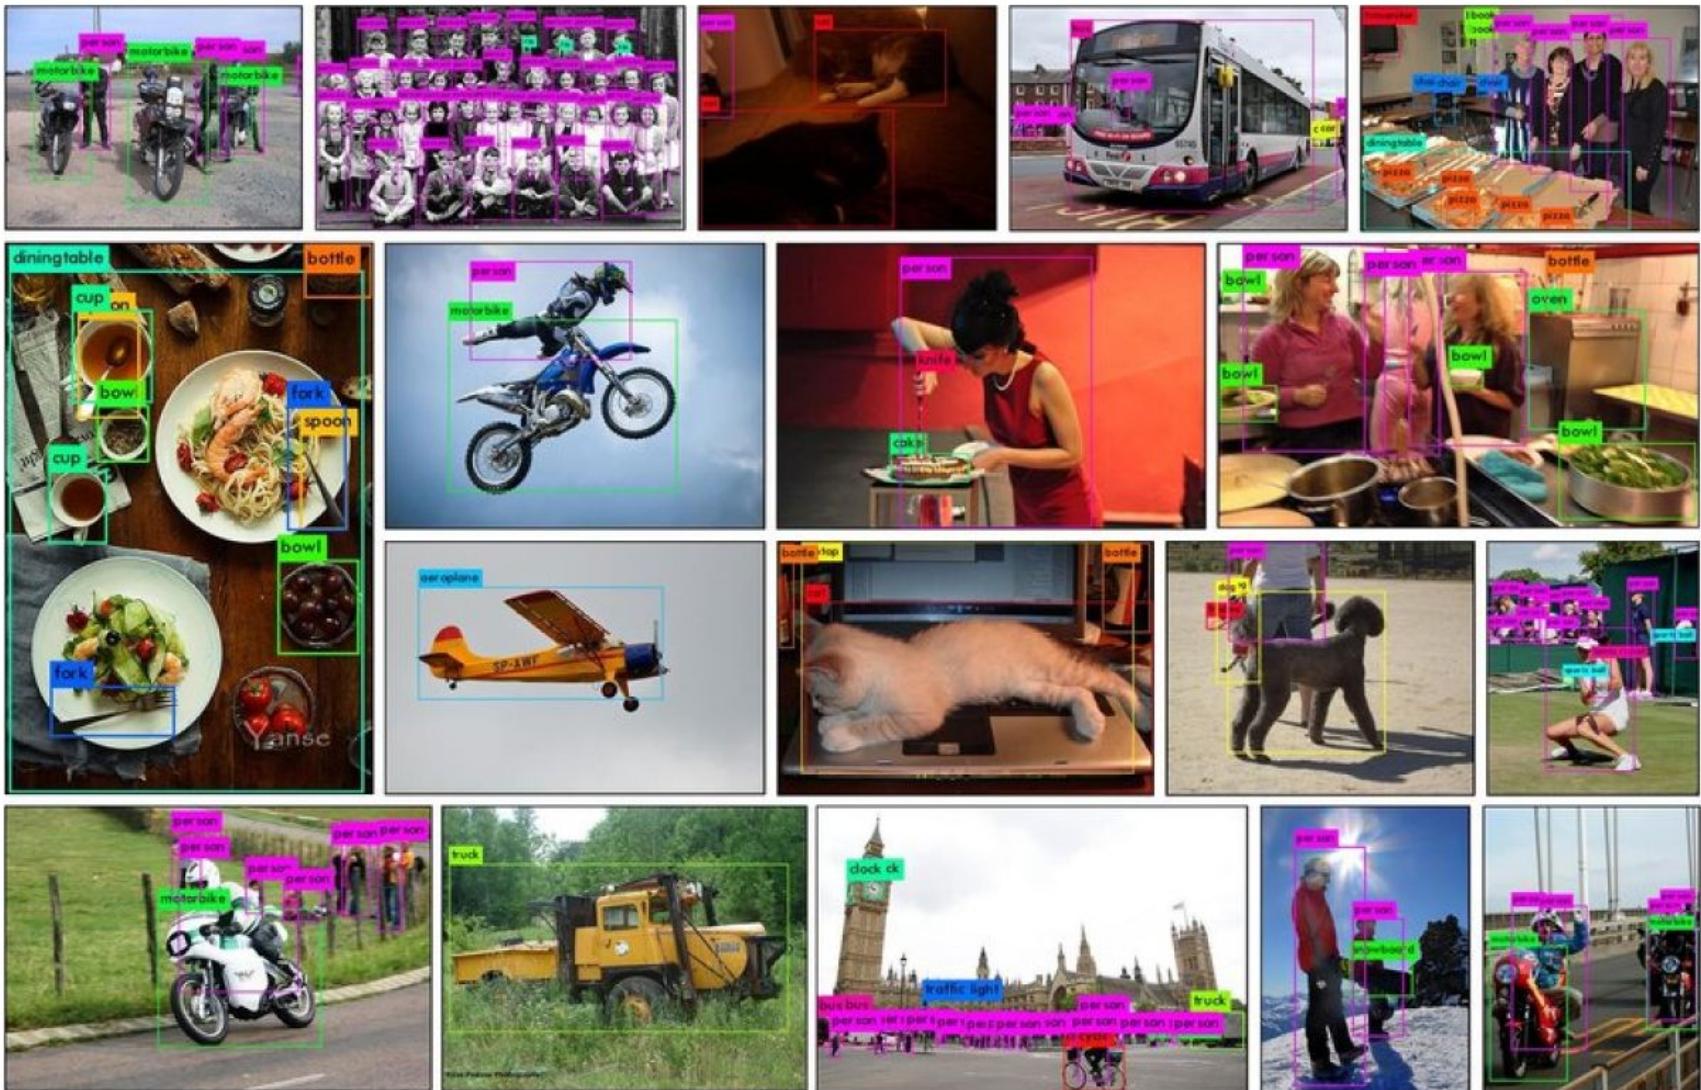


Detecção de objetos

- Algumas tarefas requerem o conhecimento da localização do objeto na imagem
 - ◆ Por exemplo, quando existem **múltiplos objetos** na imagem de entrada, inicialmente é necessário a identificação das **posições específicas** de cada objeto
 - ◆ Em seguida, podemos **categorizar** ou **classificar** cada objeto a partir da sua localização estimada
 - ◆ Chamamos de **detecção** a tarefa de **encontrar as coordenadas ou posição** do objeto na imagem

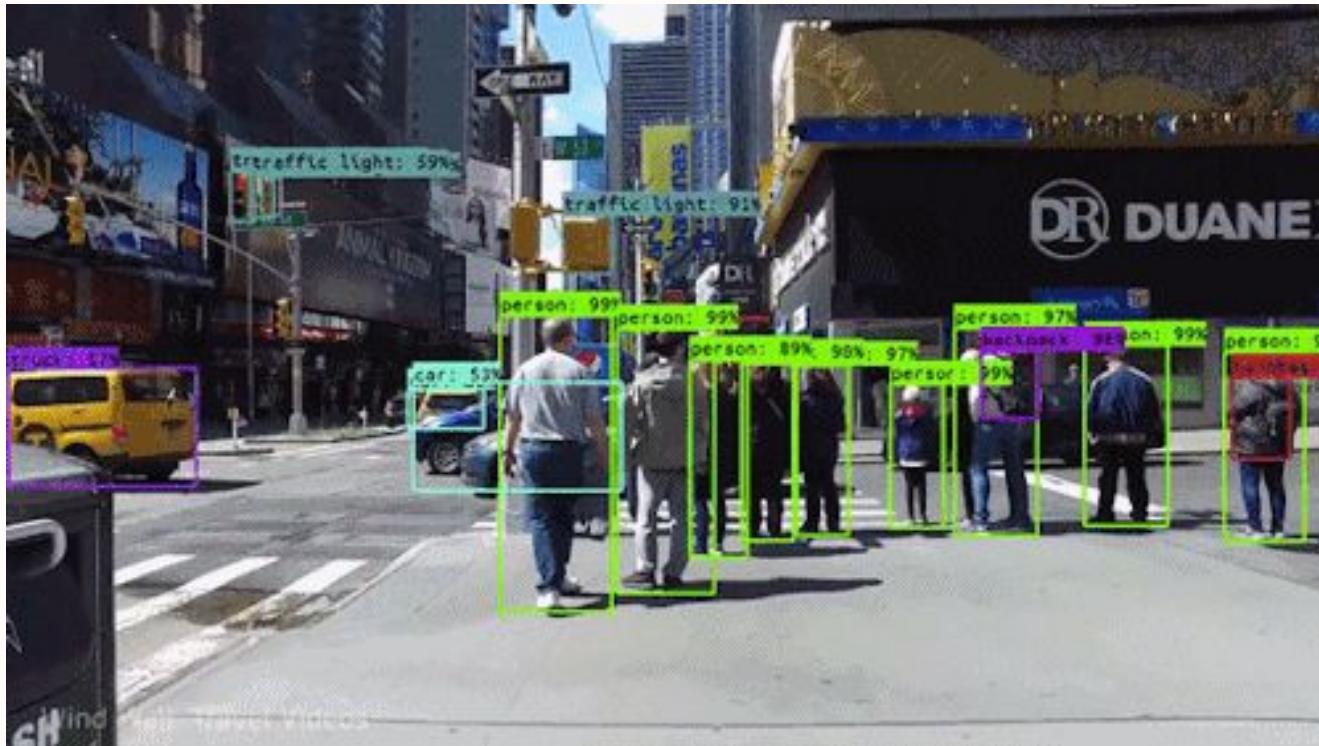


Detecção de objetos



Detecção de objetos

- Possui aplicações em diversas áreas que utilizam visão computacional
- Por exemplo: veículos autônomos, sistemas de vigilância, navegação de ambientes, manipulação robótica, entre outros.



Detecção de objetos

- Estratégias de detecção geralmente são divididas entre métodos que utilizam abordagens **tradicionais** e abordagens baseadas em **aprendizagem de máquina** e/ou **aprendizagem profunda**

Detecção de objetos

- Estratégias de detecção geralmente são divididas entre métodos que utilizam abordagens **tradicionais** e abordagens baseadas em **aprendizagem de máquina** e/ou **aprendizagem profunda**
- Exemplos de métodos baseados em características:
 - SIFT (Scale Invariant Feature Transform)
 - HOG (Histogram of Oriented Gradients)
 - SURF, ORB, BRISK, ...

Detecção de objetos



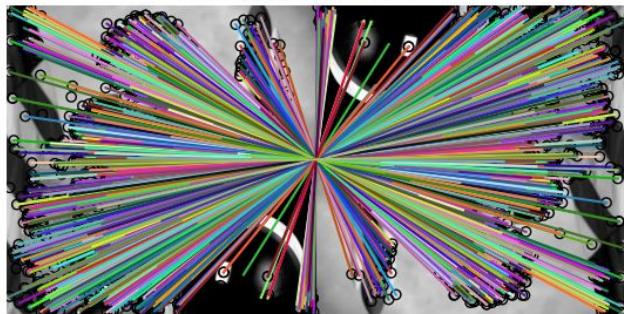
Entrada

Extração de features

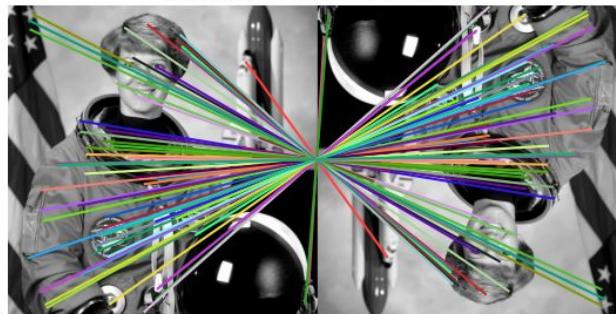
Matching

Saída

Original Image vs. Flipped Image
(all keypoints and matches)



Original Image vs. Flipped Image
(subset of matches for visibility)



Original Image vs. Transformed Image
(all keypoints and matches)

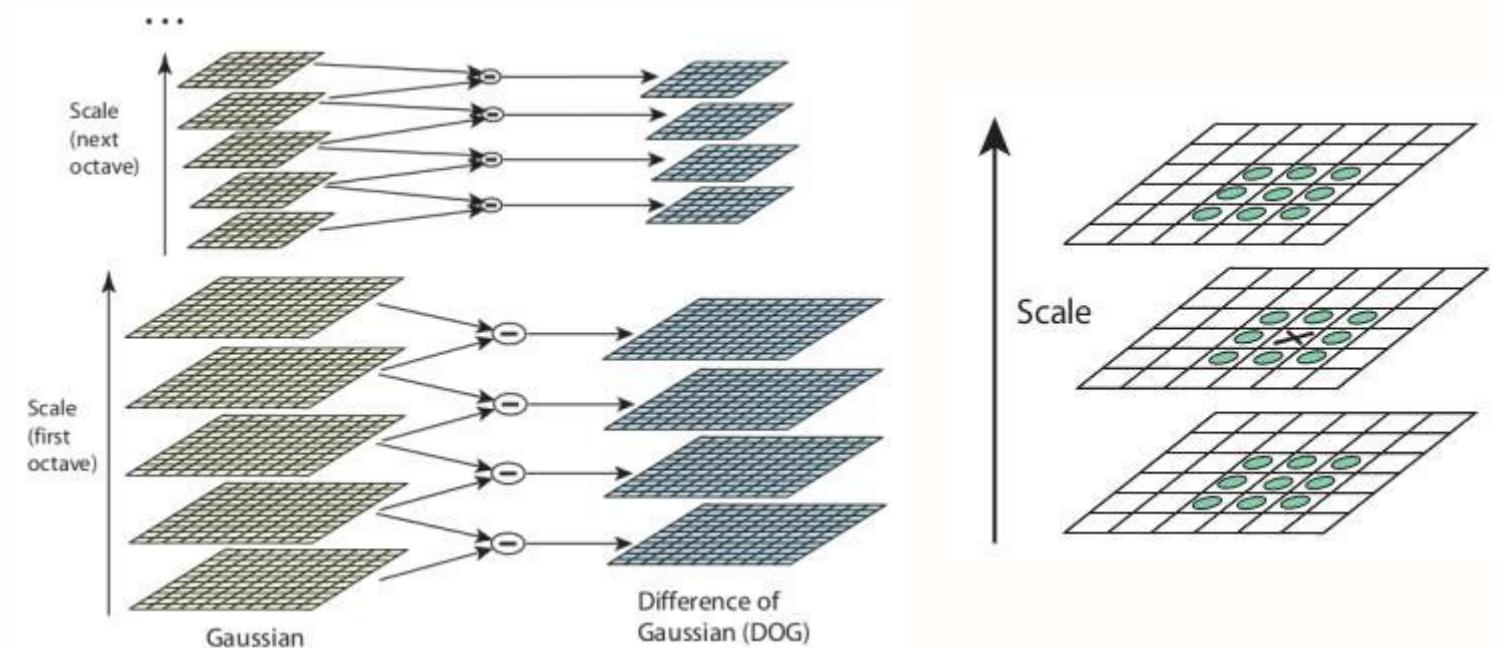


Original Image vs. Transformed Image
(subset of matches for visibility)

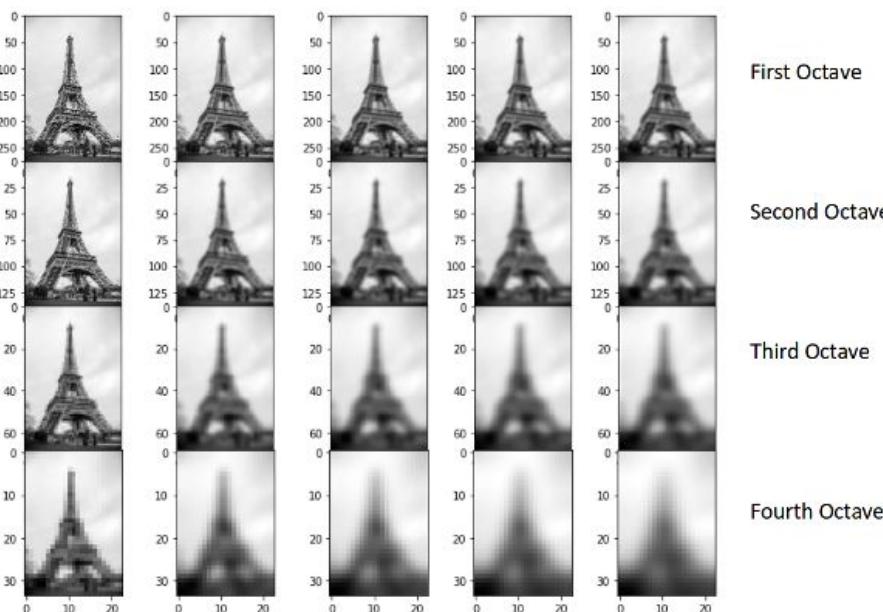


Detecção de objetos - SIFT

- Detecção Space-scale
- Localização dos keypoints
- Atribuição de orientação
- Criação dos descritores
- Matching



Detecção de objetos - SIFT

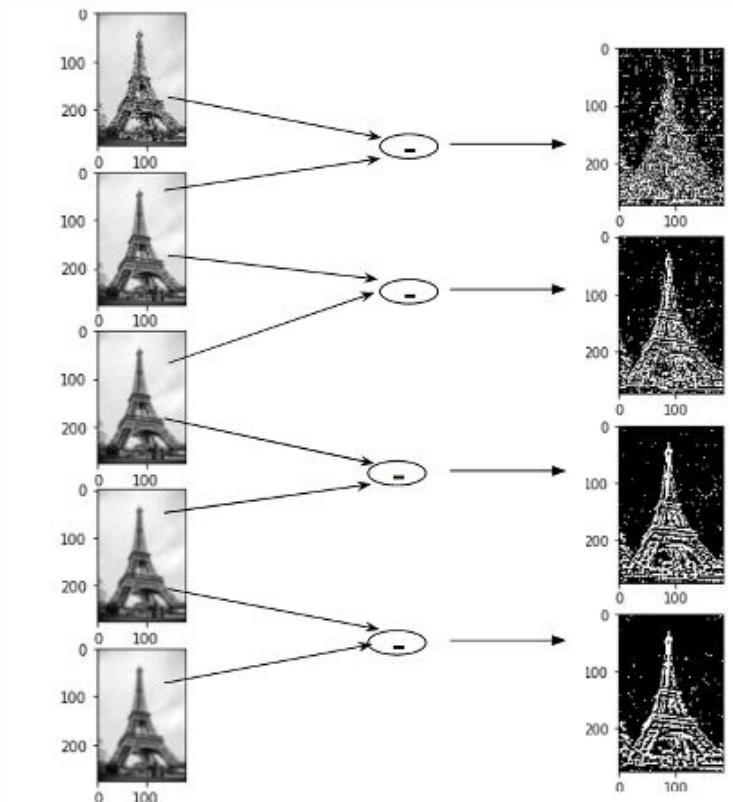


First Octave

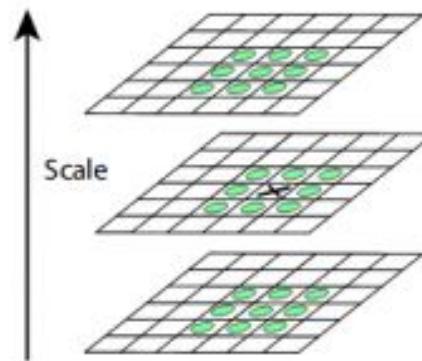
Second Octave

Third Octave

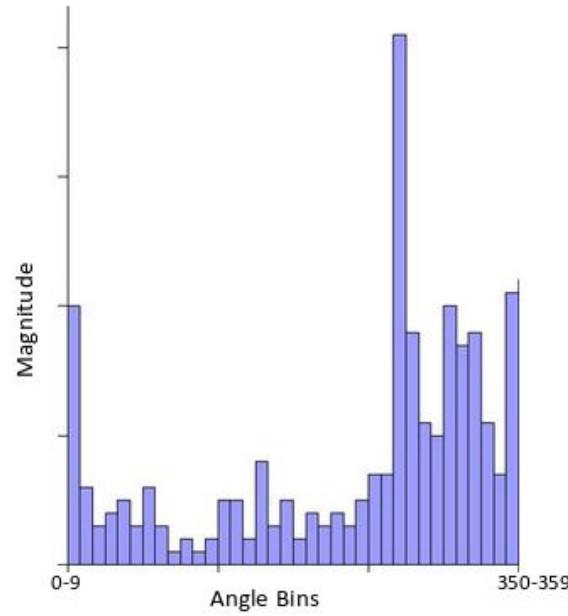
Fourth Octave



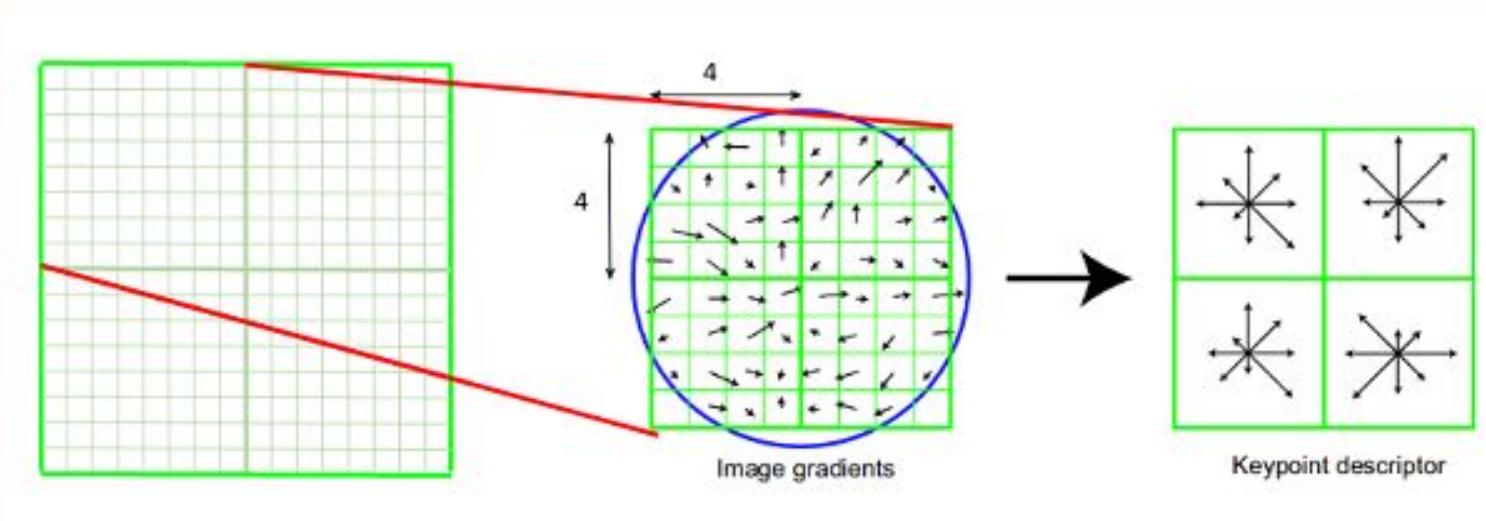
Detecção de objetos - SIFT



35	40	41	45	50
40	40	42	46	52
42	46	50	55	55
48	52	56	58	60
56	60	65	70	75



Detecção de objetos - SIFT



Detecção de objetos - SIFT

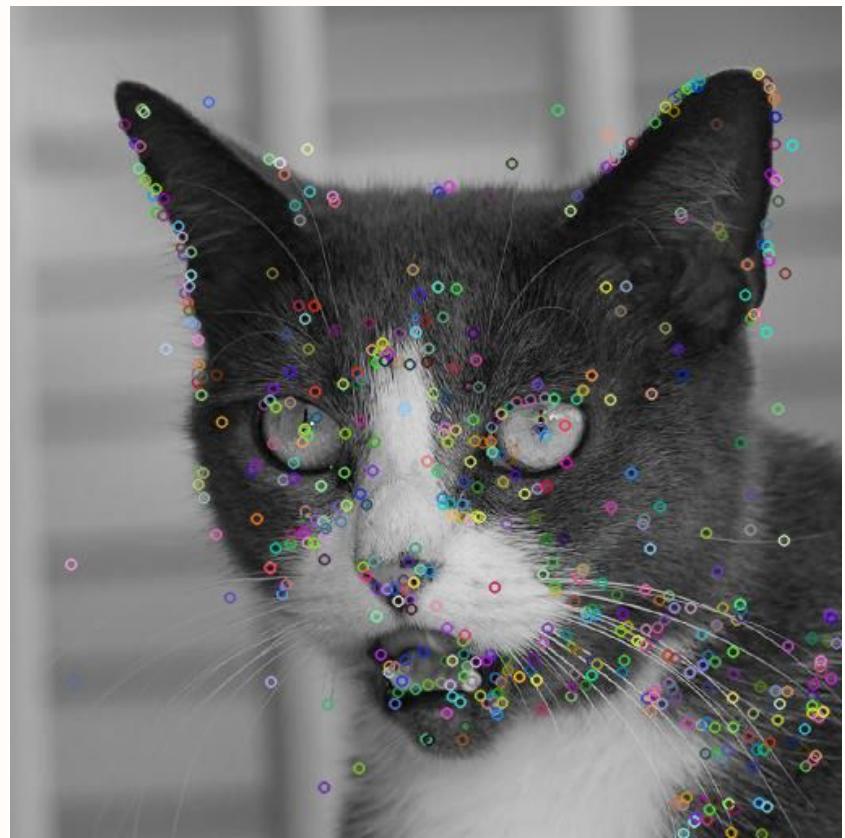
```
import cv2

if __name__ == '__main__':
    image = cv2.imread('./data/cat1.jpg')
    gray = cv2.cvtColor(image, cv2.COLOR_BGR2GRAY)
    sift = cv2.SIFT_create()
    kp = sift.detect(gray, None)

    img_sift = image.copy()
    img_sift = cv2.drawKeypoints(gray, kp, img_sift)
```



Detecção de objetos - SIFT



Detecção de objetos - SIFT

```
#Feature Matching

image2 = cv2.imread('./data/cat2.jpg')
image3 = cv2.imread('./data/cat3.jpg')

gray2 = cv2.cvtColor(image2, cv2.COLOR_BGR2GRAY)
gray3 = cv2.cvtColor(image3, cv2.COLOR_BGR2GRAY)

kp2, desc2 = sift.detectAndCompute(gray2, None)
kp3, desc3 = sift.detectAndCompute(gray3, None)

bf = cv2.BFMatcher(cv2.NORM_L1, crossCheck=True)

matches12 = bf.match(desc, desc2)
matches13 = bf.match(desc, desc3)

matches12 = sorted(matches12, key=lambda x: x.distance)
matches13 = sorted(matches13, key=lambda x: x.distance)

img_sift2 = image2.copy()
img_sift2 = cv2.drawMatches(gray, kp, gray2, kp2, matches12[:50], img_sift2, flags=2)

img_sift3 = image3.copy()
img_sift3 = cv2.drawMatches(gray, kp, gray3, kp3, matches13[:50], img_sift3, flags=2)
```

Detecção de objetos - SIFT

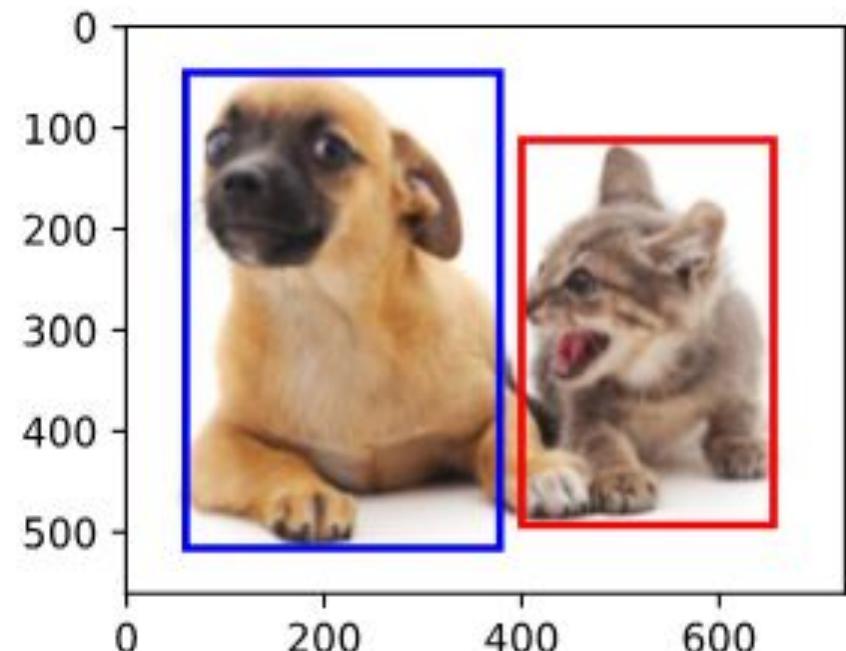
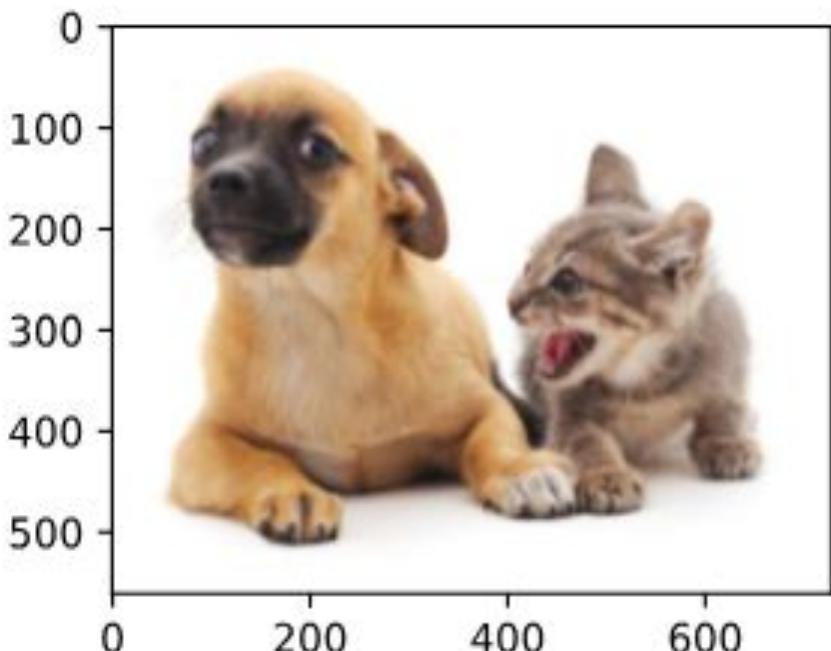


Detecção de objetos

- Estratégias de detecção geralmente são divididas entre métodos que utilizam abordagens **tradicionais** e abordagens baseadas em **aprendizagem de máquina** e/ou **aprendizagem profunda**
- Exemplos de métodos baseados em características:
 - ◆ SIFT (Scale Invariant Feature Transform)
 - ◆ HOG (Histogram of Oriented Gradients)
- Exemplos de métodos baseados em aprendizagem profunda:
 - ◆ Region-based CNN (R-CNN), Fast RCNN, Faster RCNN
 - ◆ YOLO, SSD, RetinaNet
 - ◆ EfficientNet, MobileNet

Detecção de objetos - Bounding box 2D

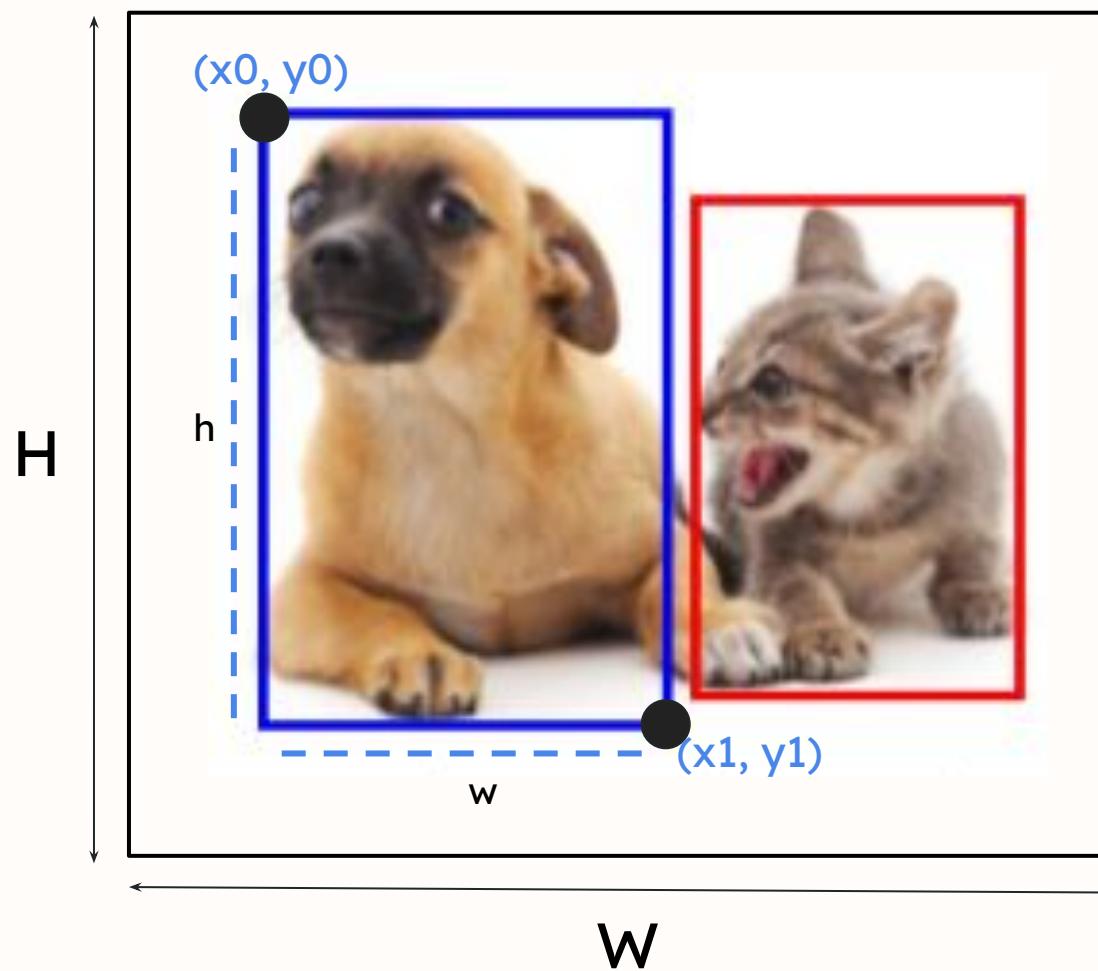
- O bounding box 2D é utilizado para representar a localização espacial de um objeto na imagem



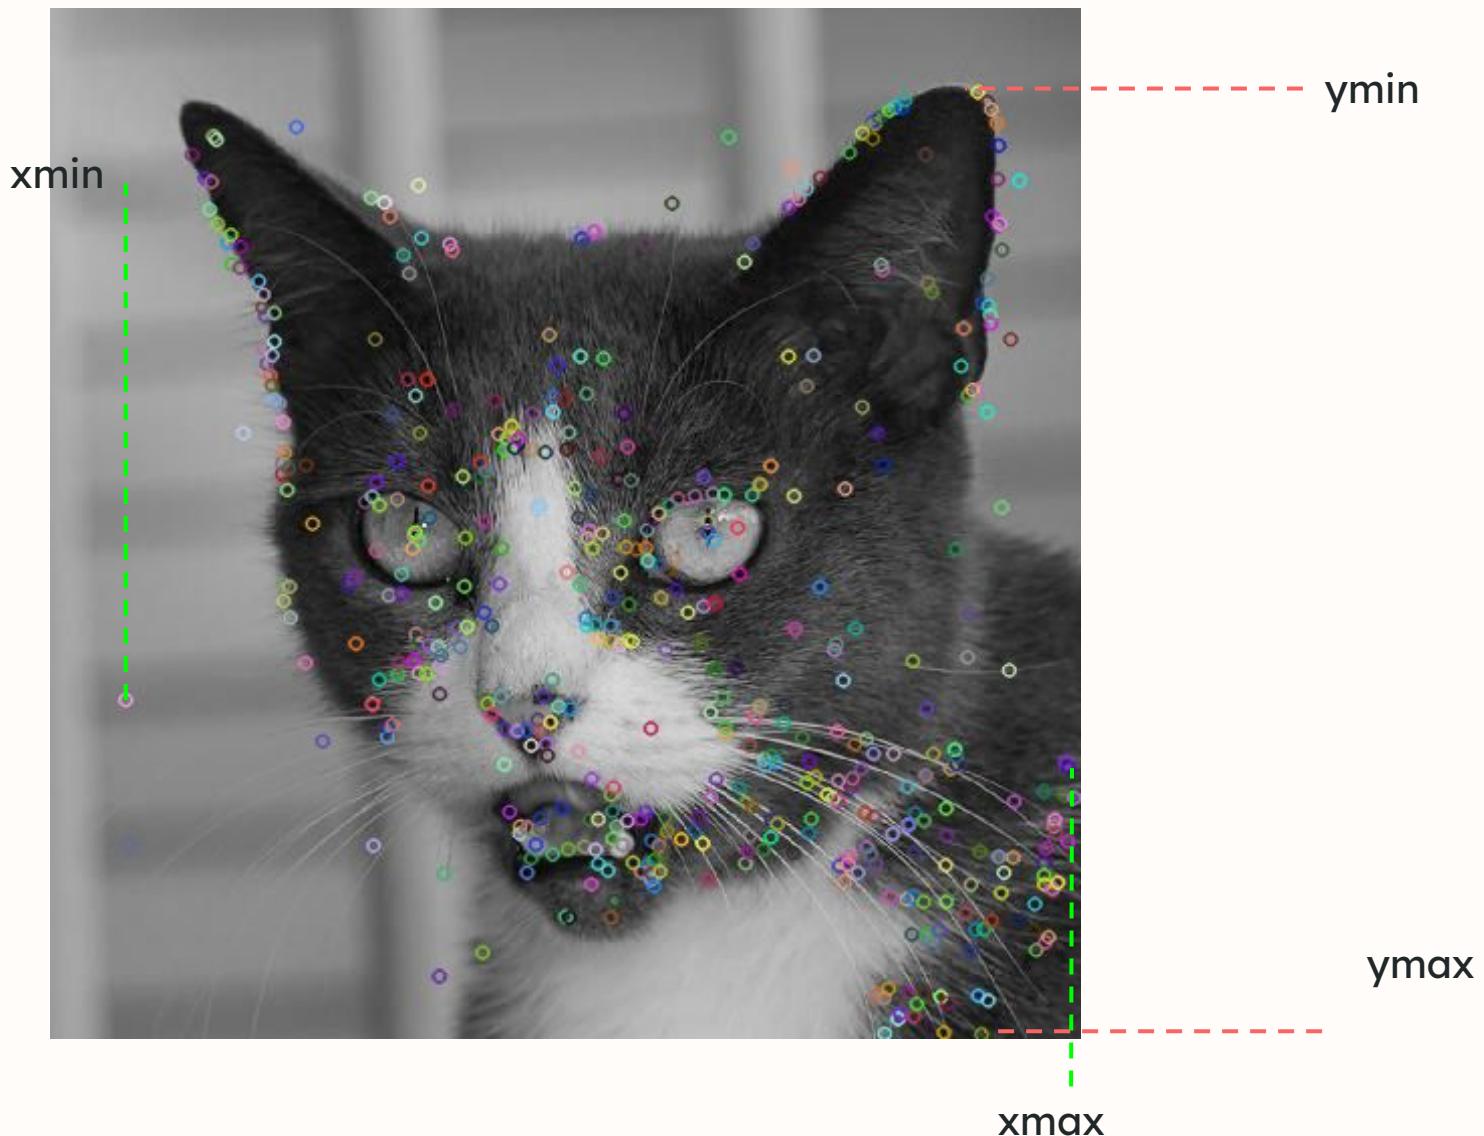
Detecção de objetos - Bounding box 2D

- Posições são determinadas pelas coordenadas do retângulo
- Considerando uma imagem de tamanho **W x H**, o bounding box 2D é comumente definido pelos parâmetros:
 - ◆ **x0**: coordenada no eixo horizontal da imagem [0, W]
 - ◆ **y0**: coordenada no eixo vertical da imagem [0, H]
 - ◆ **w**: largura do bounding box
 - ◆ **h**: altura do bounding box
- O bounding box também pode ser descrito através dos pontos superior à esquerda (**x0, y0**) e do ponto inferior à direita (**x1, y1**), onde **x1=x0+w** e **y1=y0+h**

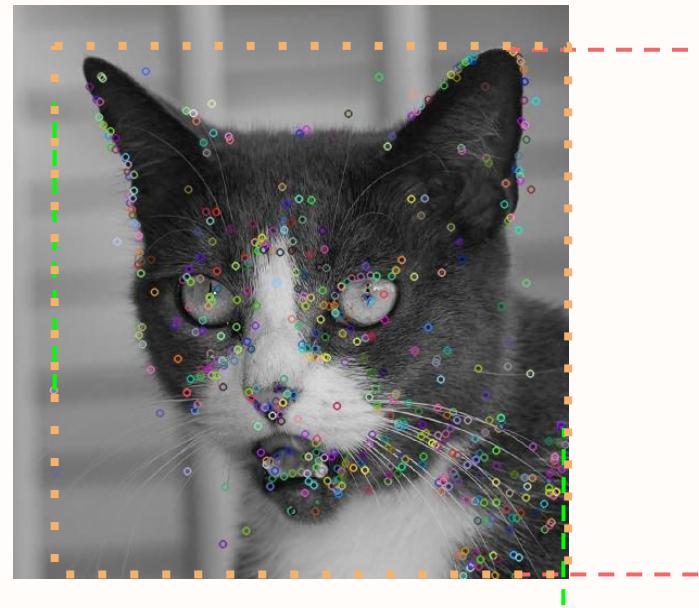
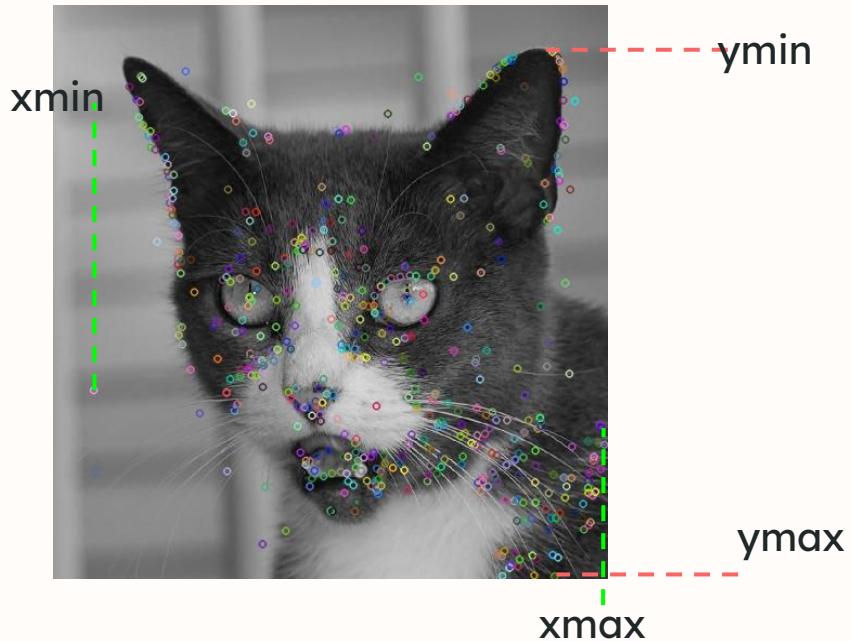
Detecção de objetos - Bounding box 2D



Detecção de objetos - Bounding box 2D



Detecção de objetos - Bounding box 2D



Detecção de objetos - Medindo a acurácia

- A **acurácia da detecção 2D** é definida através da porcentagem de sobreposição que a estimativa do bounding box tem com o bounding box de ground truth (anotação) do conjunto de treino

Detecção de objetos - Medindo a acurácia

- A **acurácia da detecção 2D** é definida através da porcentagem de sobreposição que a estimação do bounding box tem com o bounding box de ground truth (anotação) do conjunto de treino
- Ou seja, calculamos a **área do bounding box estimado e do bounding box da ground-truth**, e avaliamos se elas ocupam a **mesma posição** na imagem

Detecção de objetos - Medindo a acurácia

- A **acurácia da detecção 2D** é definida através da porcentagem de sobreposição que a estimação do bounding box tem com o bounding box de ground truth (anotação) do conjunto de treino
- Ou seja, calculamos a **área do bounding box estimado e do bounding box da ground-truth**, e avaliamos se elas ocupam a **mesma posição** na imagem
- Se o valor de sobreposição for **maior que um threshold definido** a priori, consideramos a estimativa correta

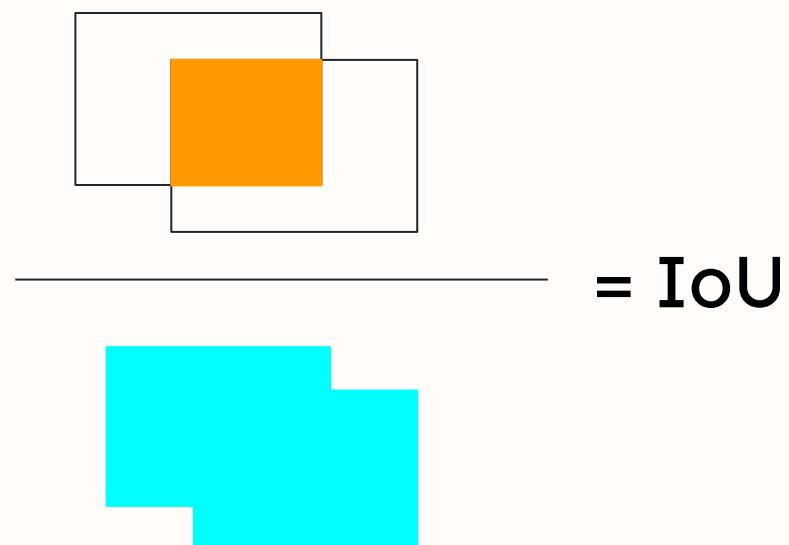
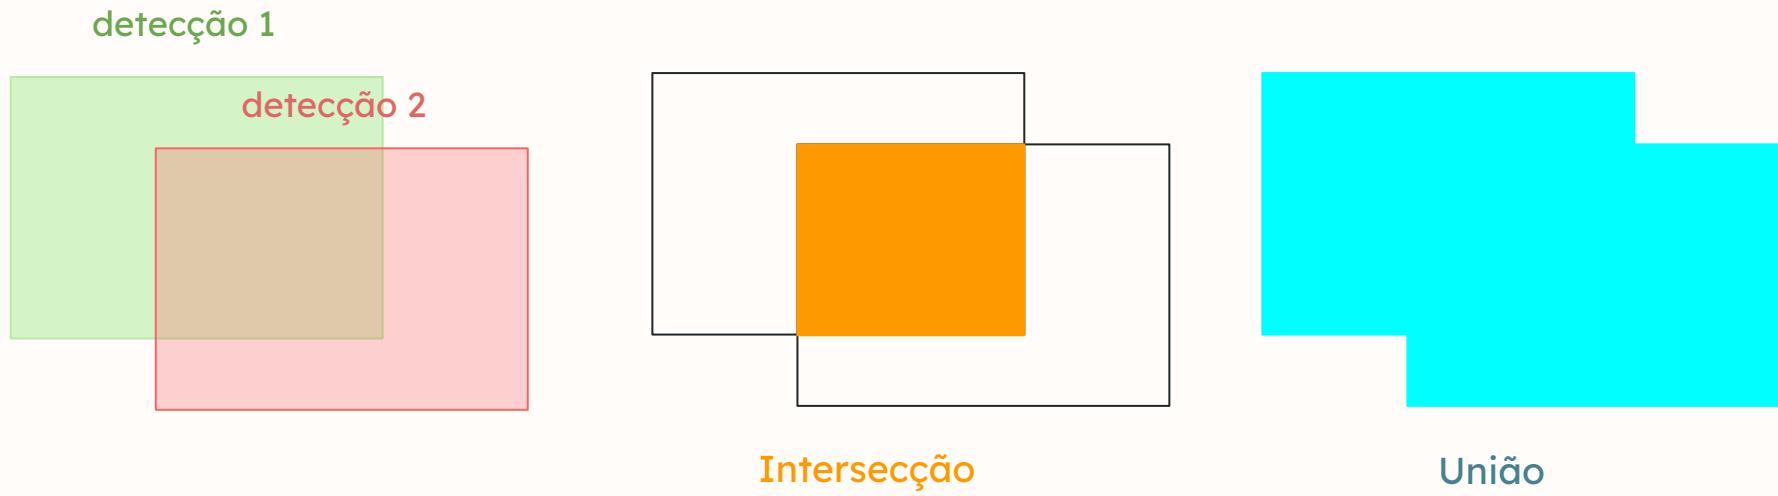
Detecção de objetos - Medindo a acurácia

- A **acurácia da detecção 2D** é definida através da porcentagem de sobreposição que a estimativa do bounding box tem com o bounding box de ground truth (anotação) do conjunto de treino
- Ou seja, calculamos a **área do bounding box estimado e do bounding box da ground-truth**, e avaliamos se elas ocupam a **mesma posição** na imagem
- Se o valor de sobreposição for **maior que um threshold definido a priori**, consideramos a estimativa correta
- A sobreposição é medida, geralmente, através da métrica **IoU (Intersection over Union)**

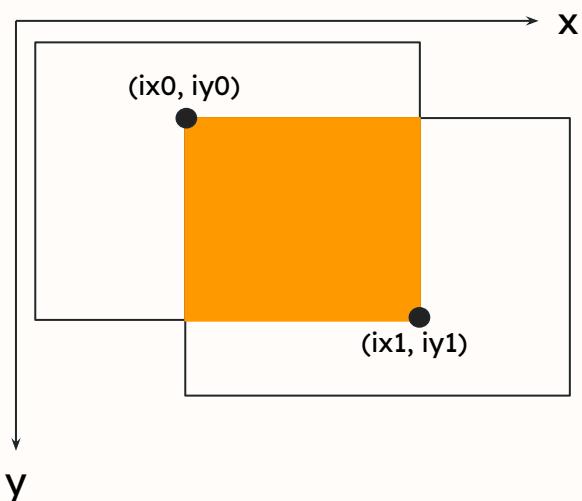
IoU (Intersection over Union)

- **IoU** é uma das principais métricas para utilizada como base para avaliar a **acurácia** da detecção
 - ◆ Computa a **proximidade** das detecções comparando a relação entre a **intersecção e união** dos bounding boxes
 - ◆ Também pode ser utilizada como o **fator para filtrar** detecções redundantes (e.g., detecções muito próximas)

IoU (Intersection over Union)

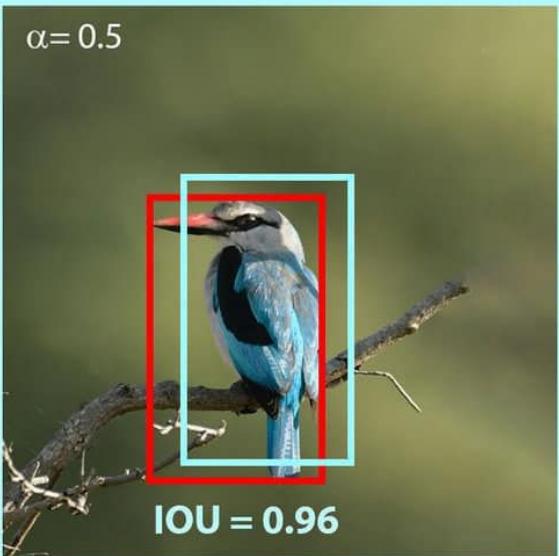


IoU (Intersection over Union)

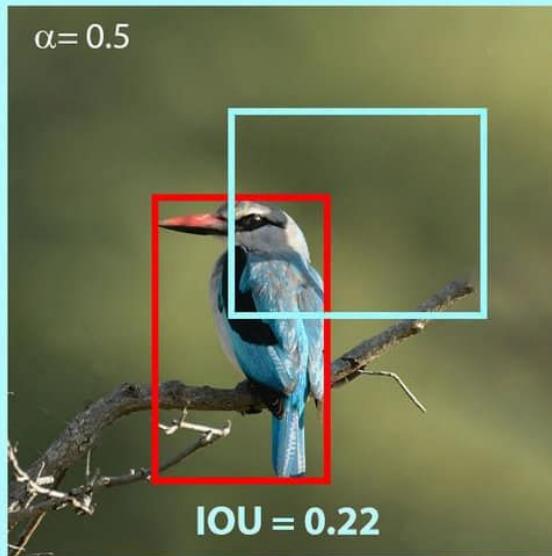


```
def iou(box1, box2):  
  
    areal = (box1[2] - box1[0]) * (box1[3] - box1[1])  
    area2 = (box2[2] - box2[0]) * (box2[3] - box2[1])  
  
    ix0 = max(box2[0], box1[0])  
    iy0 = max(box2[1], box1[1])  
    ix1 = min(box2[2], box1[2])  
    iy1 = min(box2[3], box1[3])  
  
    intersection_area = max(0, ix1 - ix0) * max(0, iy0, iy1)  
    union_area = areal + area2 - intersection_area  
  
    iou_value = intersection_area / union_area  
  
    return iou_value
```

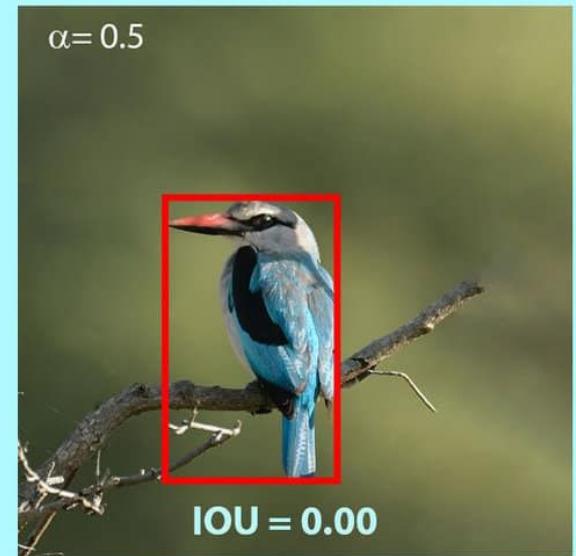
IoU (Intersection over Union)



True Positive



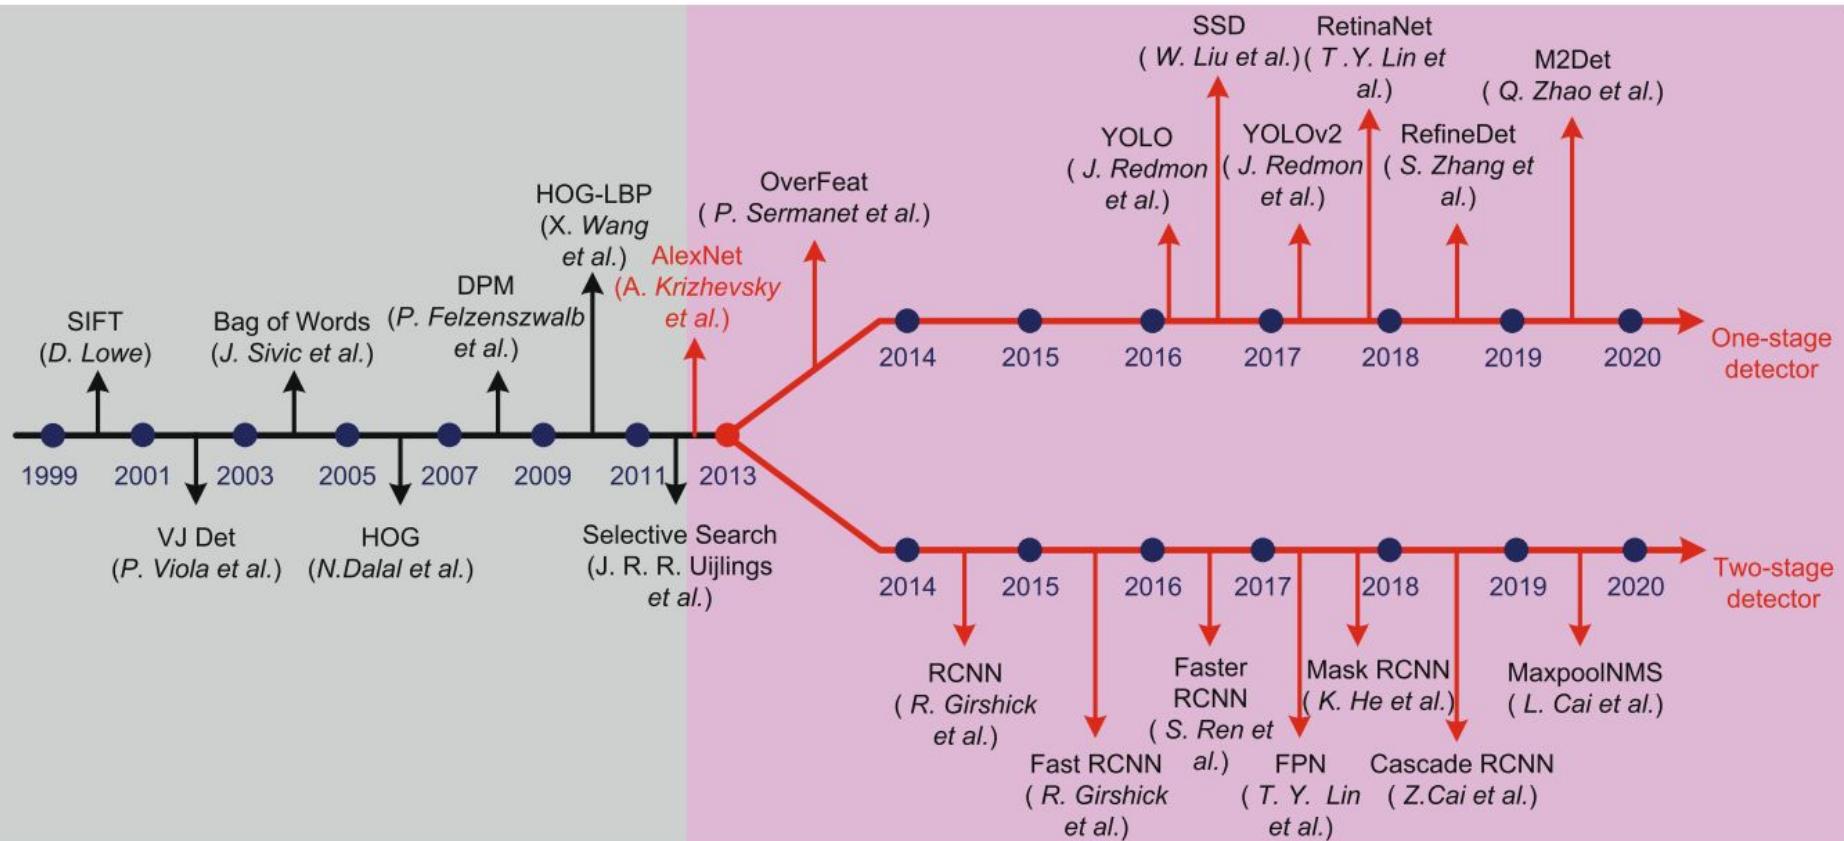
False Positive



False Negative

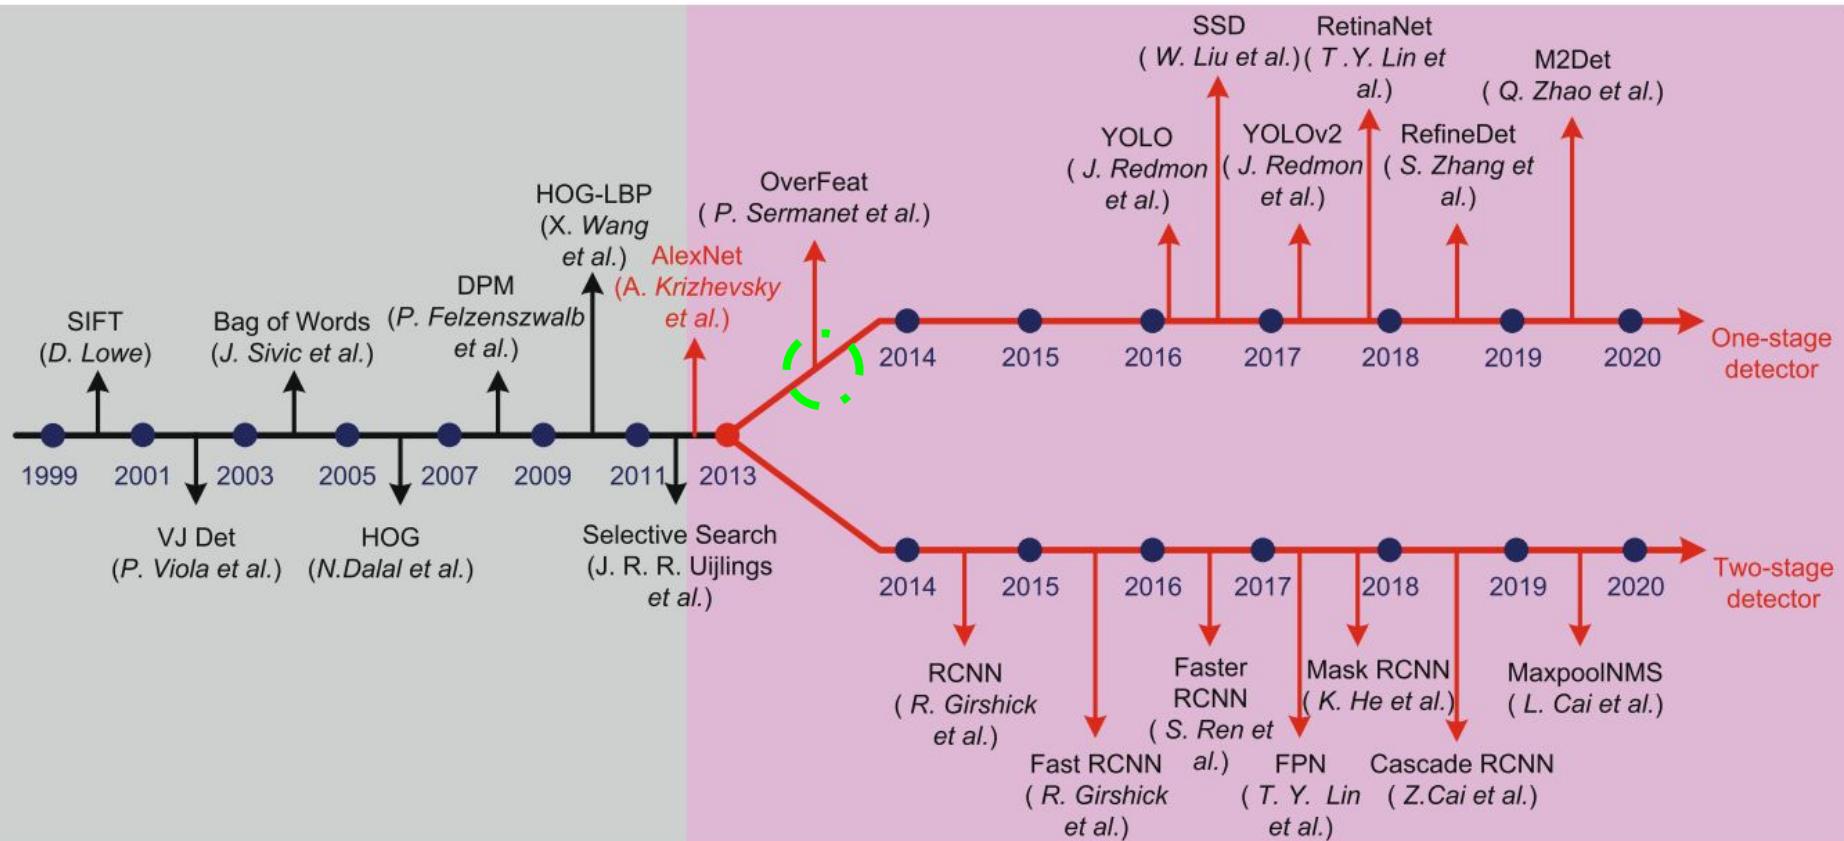
<https://learnopencv.com/intersection-over-union-iou-in-object-detection-and-segmentation/>

Evolução - detecção de objetos com deep learning



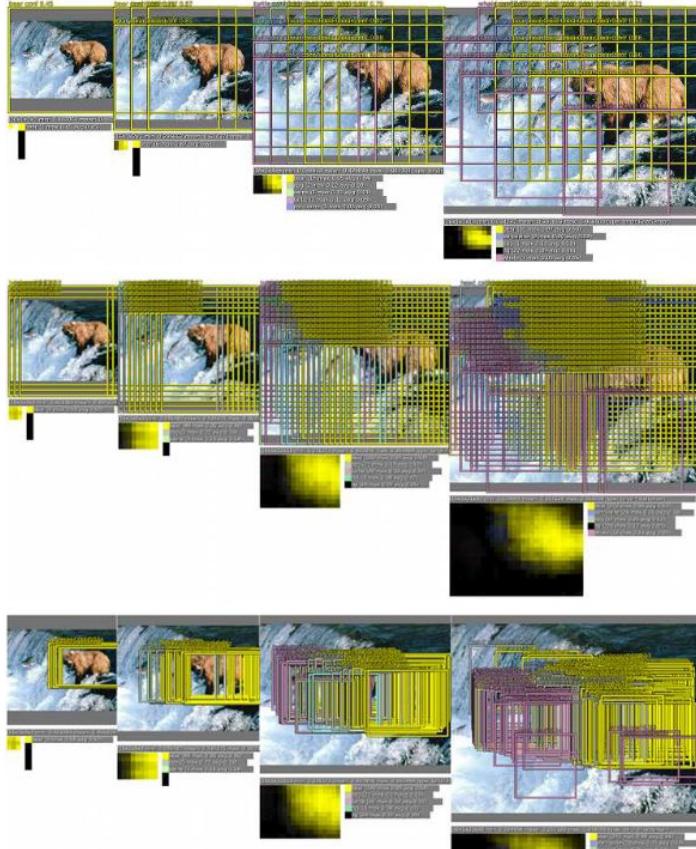
Xiao, Youzi, et al. "A review of object detection based on deep learning." *Multimedia Tools and Applications* 79 (2020): 23729-23791.

Evolução - detecção de objetos com deep learning



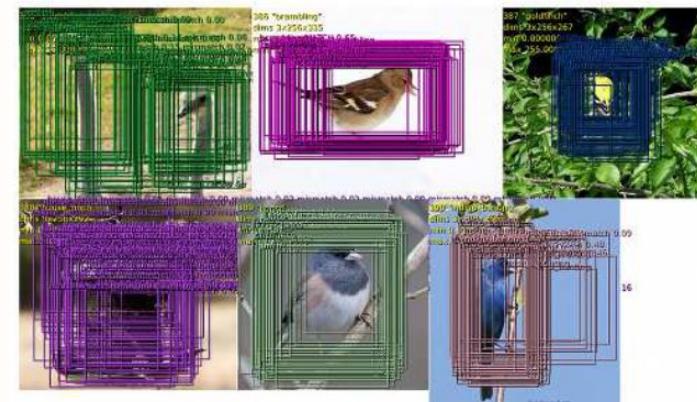
Xiao, Youzi, et al. "A review of object detection based on deep learning." *Multimedia Tools and Applications* 79 (2020): 23729-23791.

Detecção de objetos - Deep Learning (Overfeat)



Pierre Sermanet, et al. **Overfeat: Integrated Recognition, Localization and Detection using Convolutional Networks**
(arxiv.org/pdf/1312.6229)

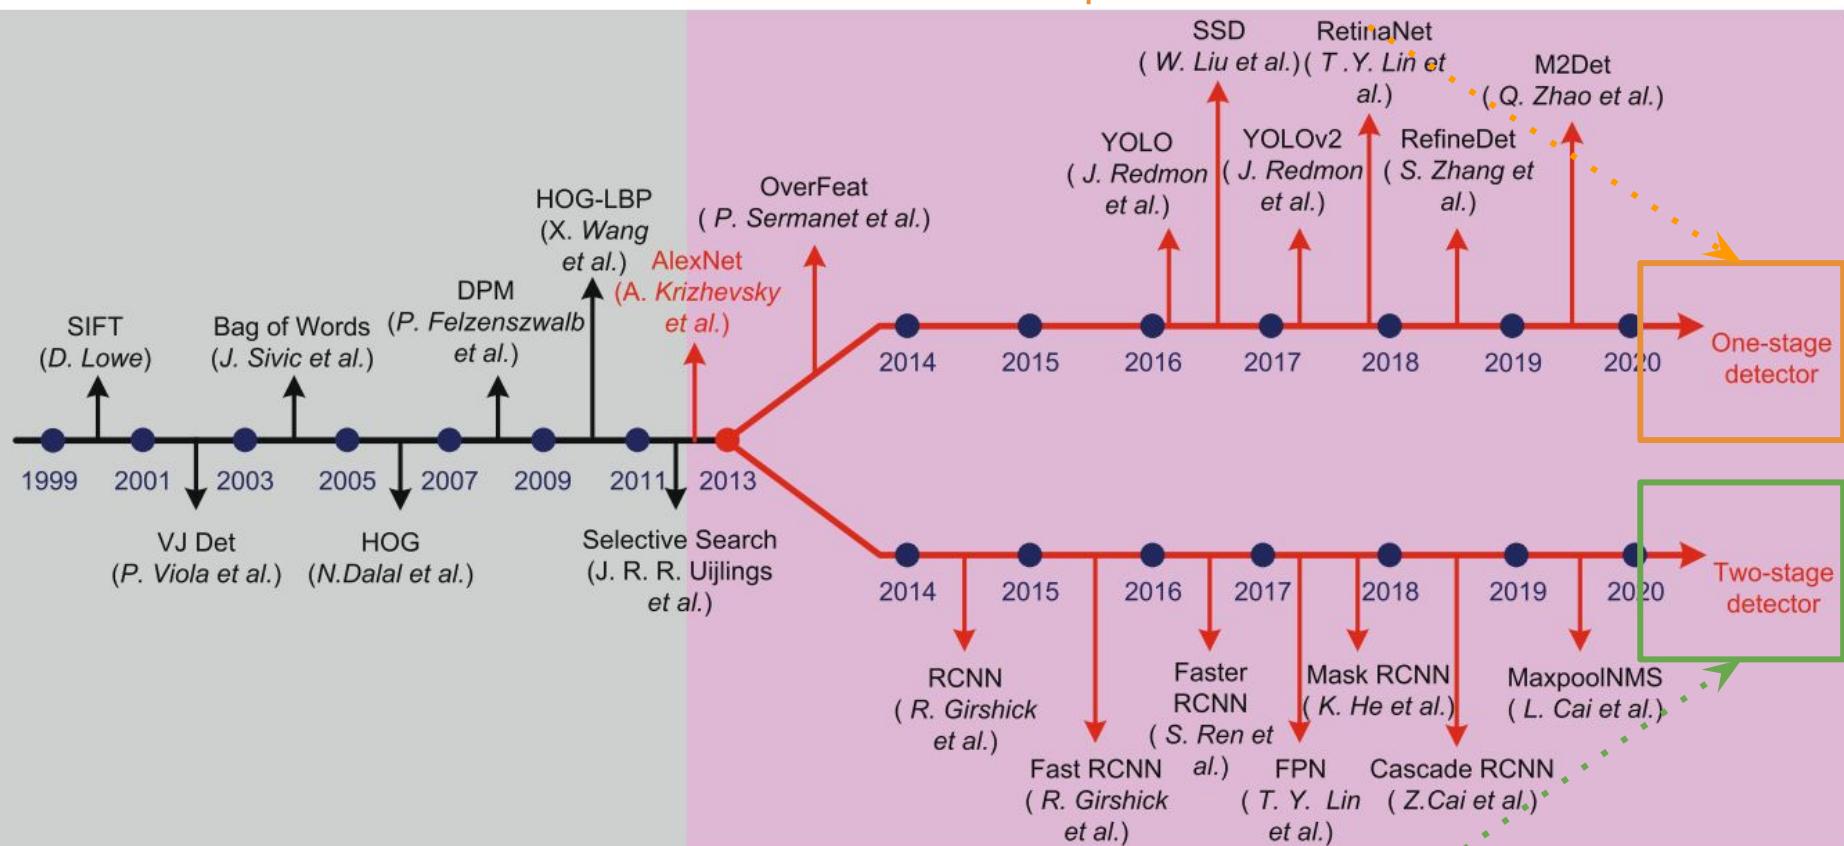
<https://github.com/sermanet/OverFeat/tree/master>



Layer	1	2	3	4	5	6	7	Output 8
Stage	conv + max	conv + max	conv	conv	conv + max	full	full	full
# channels	96	256	512	1024	1024	3072	4096	1000
Filter size	11x11	5x5	3x3	3x3	3x3	-	-	-
Conv. stride	4x4	1x1	1x1	1x1	1x1	-	-	-
Pooling size	2x2	2x2	-	-	2x2	-	-	-
Pooling stride	2x2	2x2	-	-	2x2	-	-	-
Zero-Padding size	-	-	1x1x1x1	1x1x1x1	1x1x1x1	-	-	-
Spatial input size	231x231	24x24	12x12	12x12	12x12	6x6	1x1	1x1

Evolução - detecção de objetos com deep learning

Realiza a detecção e classificação em um único passo

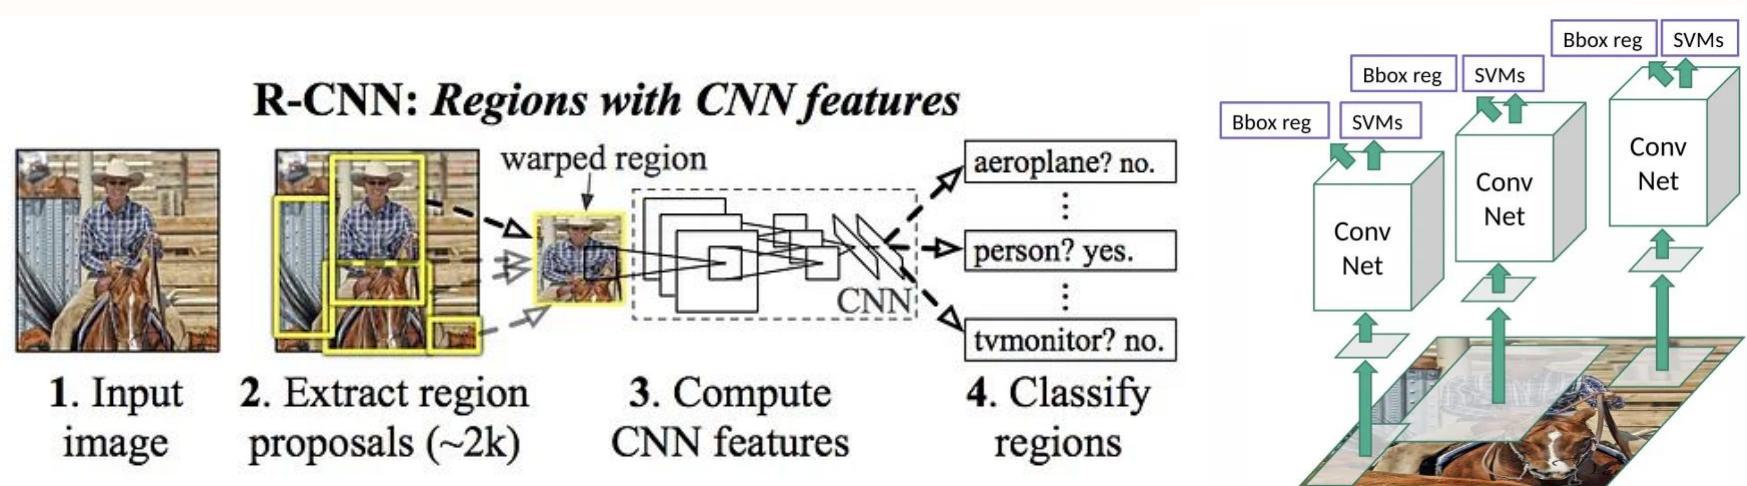


Primeiro faz a detecção do objeto na imagem e em seguida realiza a classificação

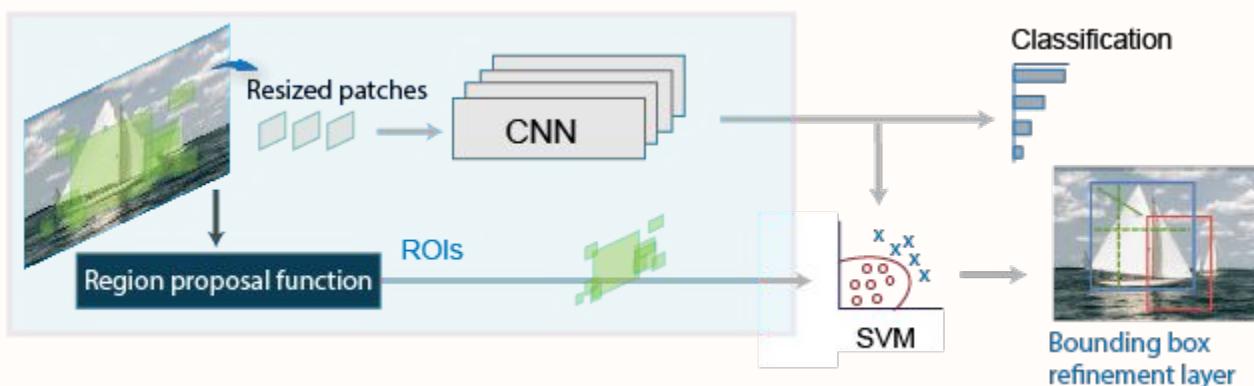
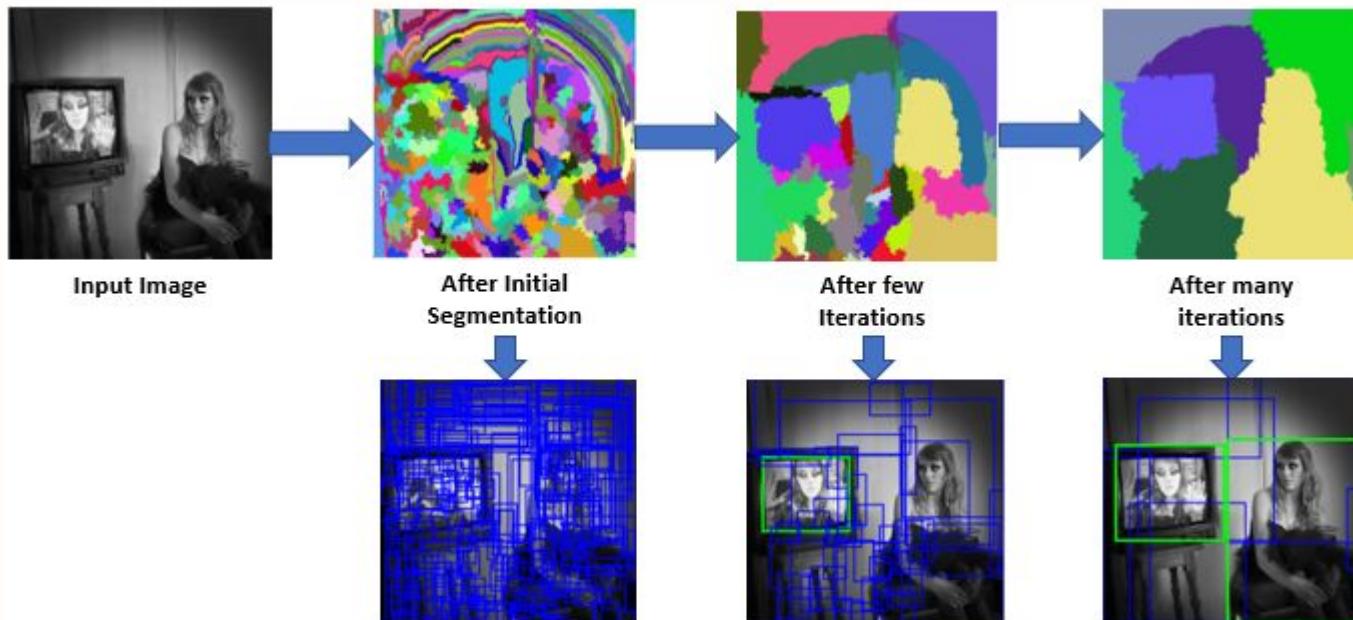
Two stage detection: RCNN

Two-stage detection - RCNN

- Detecção de objetos em duas etapas com RCNN
 - ◆ Seleciona um número pré-definido de regiões com selective search (2000)
 - ◆ Avalia cada região com uma SVM, utilizando features extraídas pela CNN



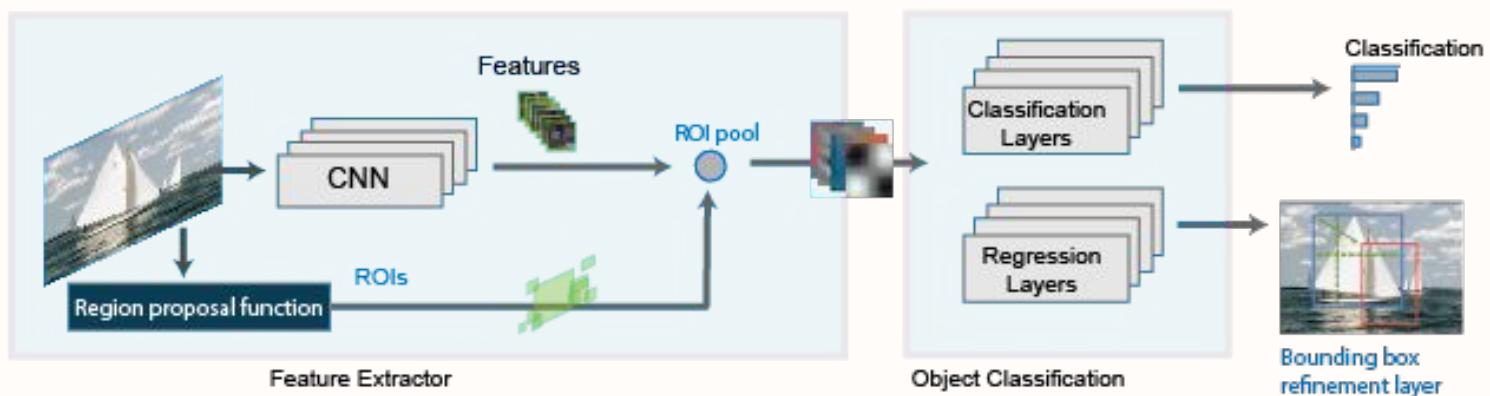
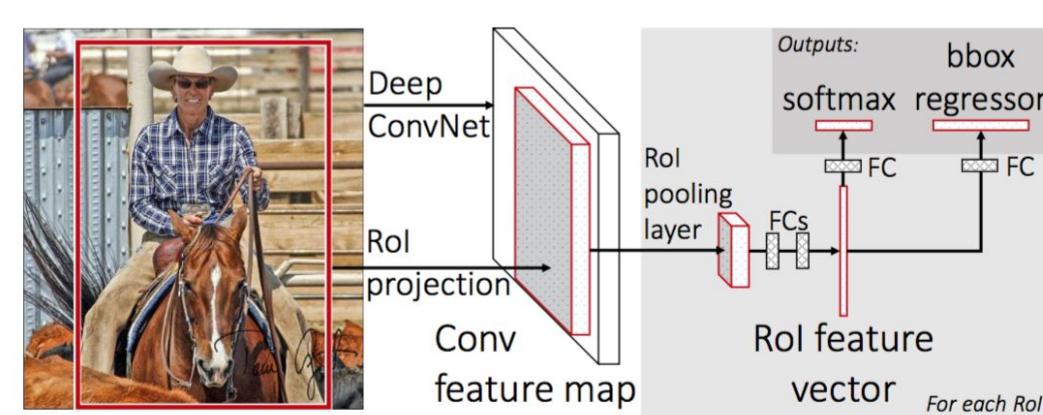
Two-stage detection - RCNN



Two-stage detection - RCNN

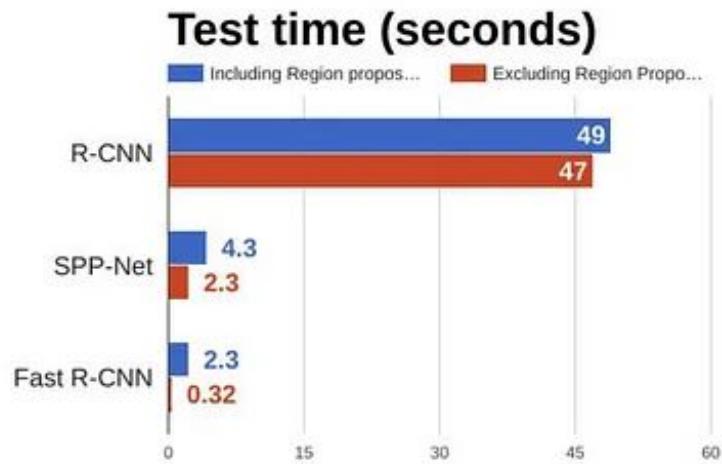
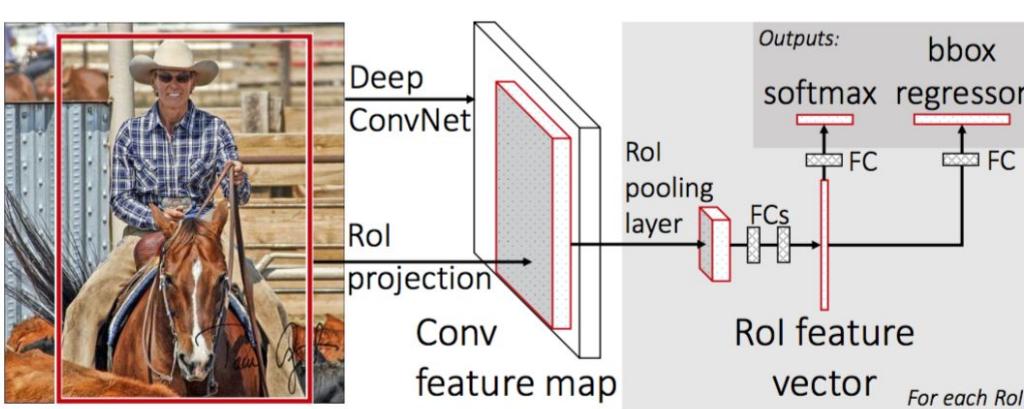
- Leva muito tempo para treinar (sempre classifica 2000 regiões)
- Inferência também é lenta (~47s)
- Selective search é um algoritmo que não utiliza aprendizado, consequentemente, a proposição de regiões nunca é melhorada

Two-stage detection - Fast-RCNN



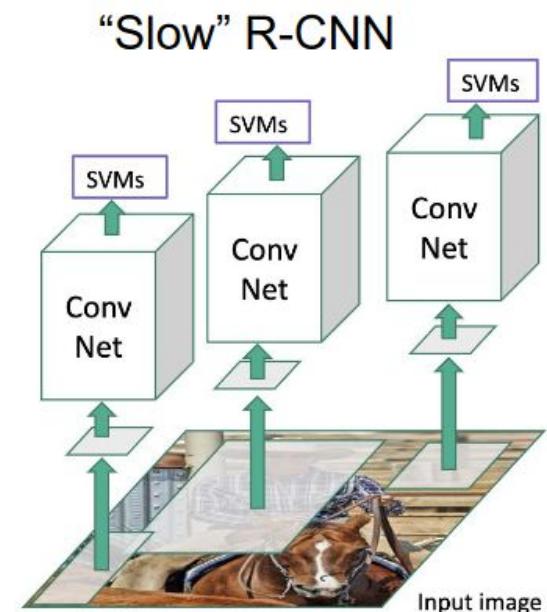
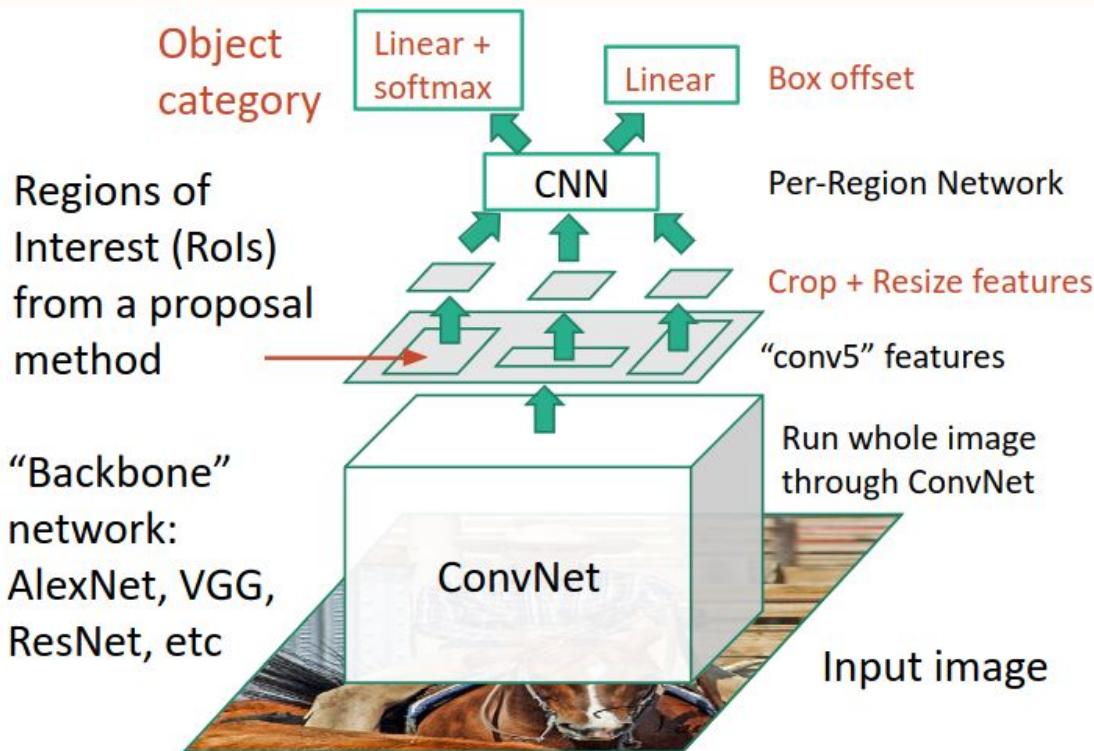
Girshick. "Fast R-CNN", ICCV 2015. Girshick, Ross. "Fast r-cnn." *Proceedings of the IEEE international conference on computer vision*. 2015.

Two-stage detection - Fast-RCNN



Girshick. "Fast R-CNN", ICCV 2015. Girshick, Ross. "Fast r-cnn." *Proceedings of the IEEE international conference on computer vision*. 2015.

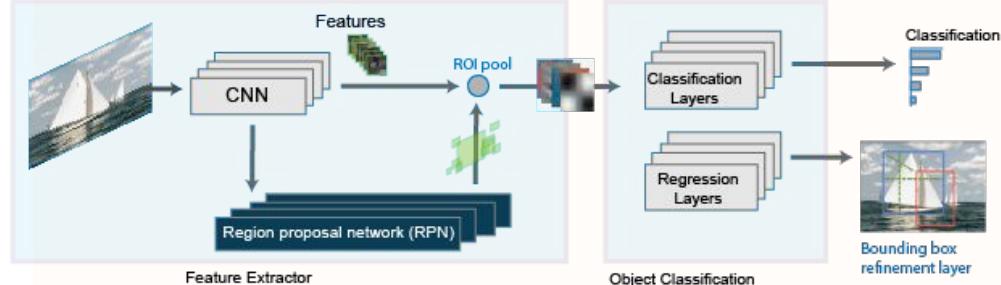
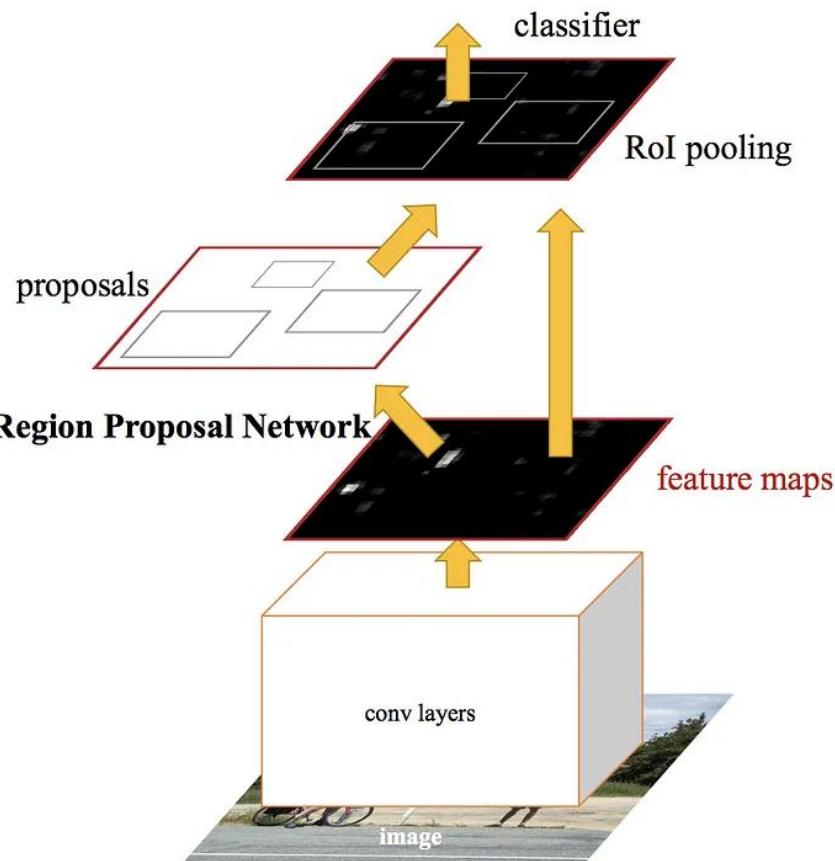
Two-stage detection - Fast-RCNN



Girshick. “Fast R-CNN”, ICCV 2015. Girshick, Ross. “Fast r-cnn.” *Proceedings of the IEEE international conference on computer vision*. 2015.

Two-stage detection - Faster-RCNN

- Faster R-CNN
 - ◆ Region Proposal Network - Prediz regiões a partir das features
 - Treina 4 funções de custo em conjunto (classificação e regressão com RPN e bounding box e scores finais)



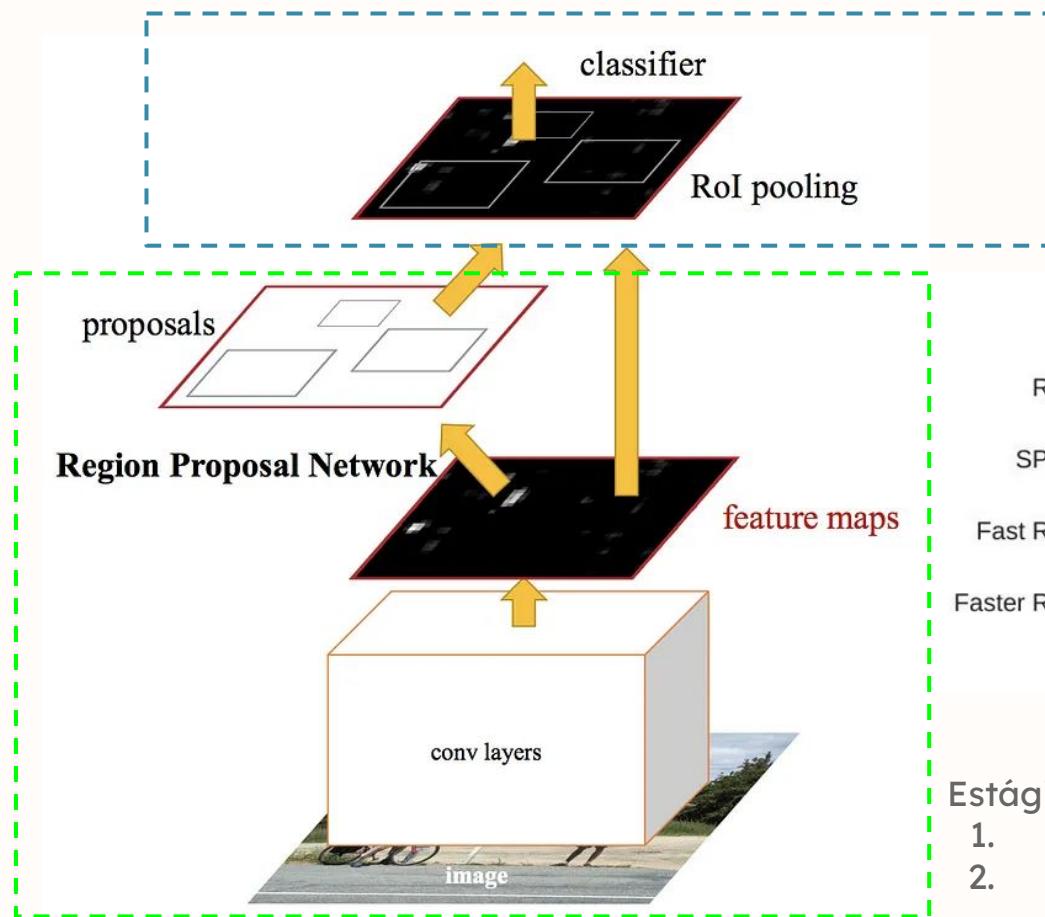
Ren, Shaoqing, et al. "**Faster r-cnn: Towards real-time object detection with region proposal networks.**" *Advances in neural information processing systems* 28 (2015).

Two-stage detection - Faster-RCNN

→ Faster R-CNN

◆ Region Proposal Network - Prediz regiões a partir das features

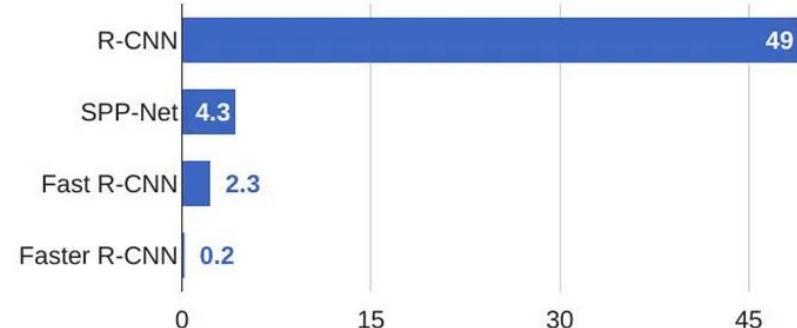
- Treina 4 funções de custo em conjunto (classificação e regressão com RPN e bounding box e scores finais)



Estágio 2 - Para cada região

1. Alinha as features
2. Prediz a classe dos objetos
3. Prediz o offset do box

R-CNN Test-Time Speed



Estágio 1 - Para cada imagem

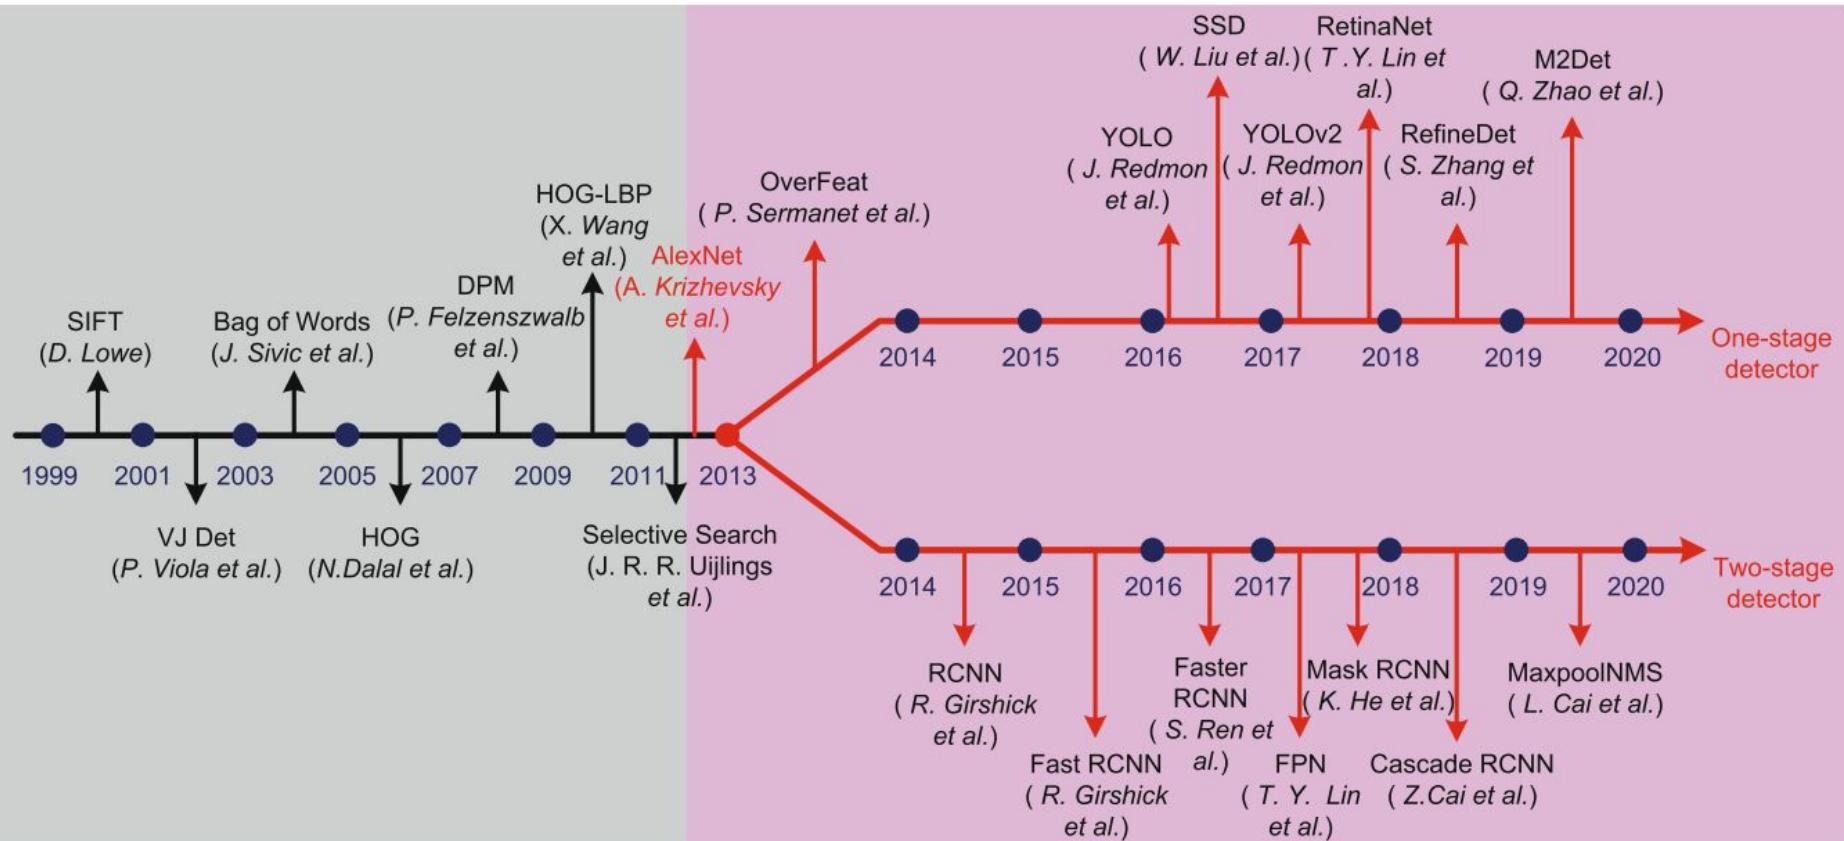
1. Extrai as features
2. Propõe regiões de interesse

Two-stage detection - Faster-RCNN

RCNN	<ul style="list-style-type: none">→ Treinamento lento→ RoIs definidas de acordo com a função utilizada→ predição utilizando svm
Fast-RCNN	<ul style="list-style-type: none">→ Utiliza toda imagem→ Detector utiliza features da CNN→ Substitui svm por softmax
Faster-RCNN	<ul style="list-style-type: none">→ Melhor desempenho de inferência e treinamento→ RoIs são aprendidas→ Remove necessidade de utilizar selective search

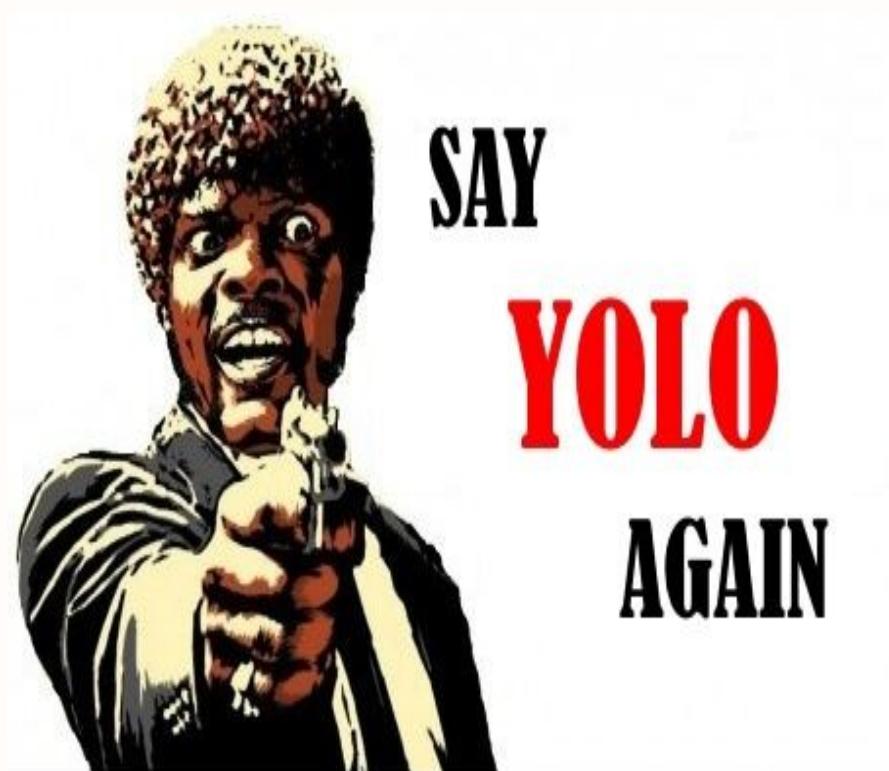
One-stage detection: YOLO

Evolução - detecção de objetos com deep learning



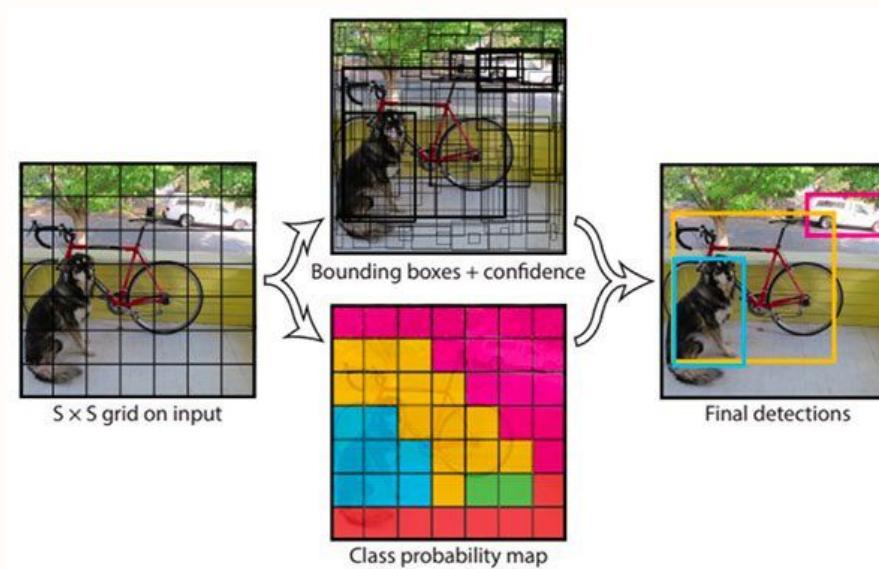
One Stage Detection - YOLO

- You Only Look Once: Unified, Real-Time Object Detection
 - YOLO é uma técnica do estado-da-arte de **detecção de objetos**
 - Correspondem à uma família de modelos *end-to-end* desenvolvidos com o intuito de realizar a detecção de objetos de forma **rápida** e com **alta acurácia**



YOLO - Características

- Utiliza uma rede neural para estimar a **localização** e **classificação** de objetos em um **único passo**
- Possui alta tolerância a **ocluções** e **sobreposições**
- Olha para a imagem inteira de uma vez, o que possibilita a utilização de **informações contextuais** ao realizar a detecção
- É altamente **eficiente** para aplicações em tempo-real



YOLO vs R-CNN

Real-Time Detectors	Train	mAP	FPS
100Hz DPM [31]	2007	16.0	100
30Hz DPM [31]	2007	26.1	30
Fast YOLO	2007+2012	52.7	155
YOLO	2007+2012	63.4	45
Less Than Real-Time			
Fastest DPM [38]	2007	30.4	15
R-CNN Minus R [20]	2007	53.5	6
Fast R-CNN [14]	2007+2012	70.0	0.5
Faster R-CNN VGG-16[28]	2007+2012	73.2	7
Faster R-CNN ZF [28]	2007+2012	62.1	18
YOLO VGG-16	2007+2012	66.4	21

YOLO - “Algoritmo”

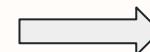
1. Inicialmente divide-se a imagem em grades de tamanho $S \times S$



$S \times S$ grid

YOLO - “Algoritmo”

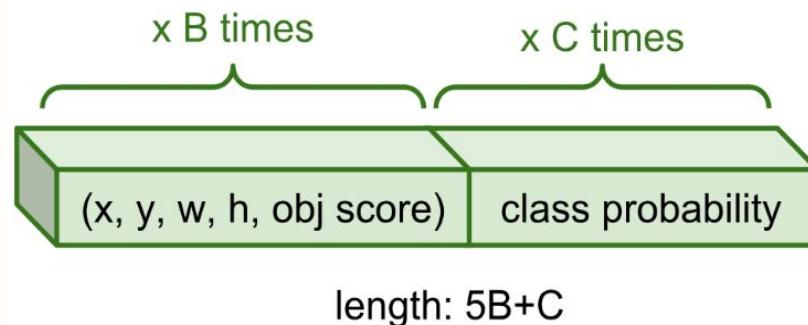
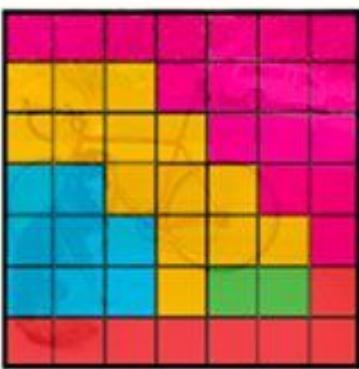
1. Inicialmente divide-se a imagem em grades de tamanho $S \times S$
2. Para cada célula da grade geram-se B bounding boxes



$S \times S$ grid

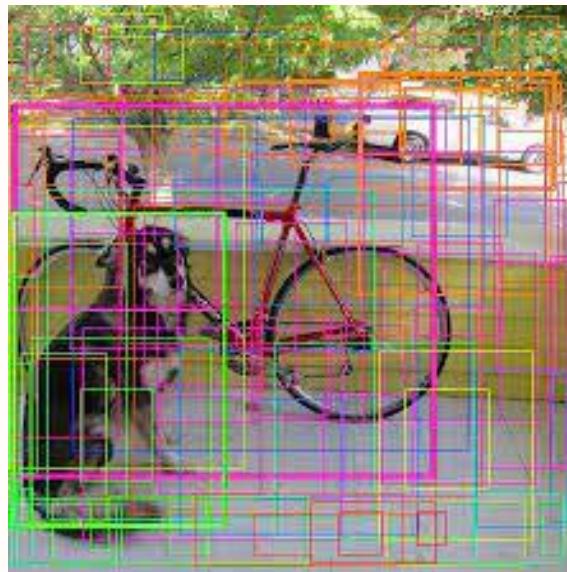
YOLO - “Algoritmo”

1. Inicialmente divide-se a imagem em grades de tamanho **SxS**
2. Para cada célula da grade geram-se **B** bounding boxes
3. Para cada retângulo **B** realizam-se as previsões das coordenadas **bx**, **by**, **bw** e **bh** e de uma **object score** que indica a probabilidade da célula conter um objeto

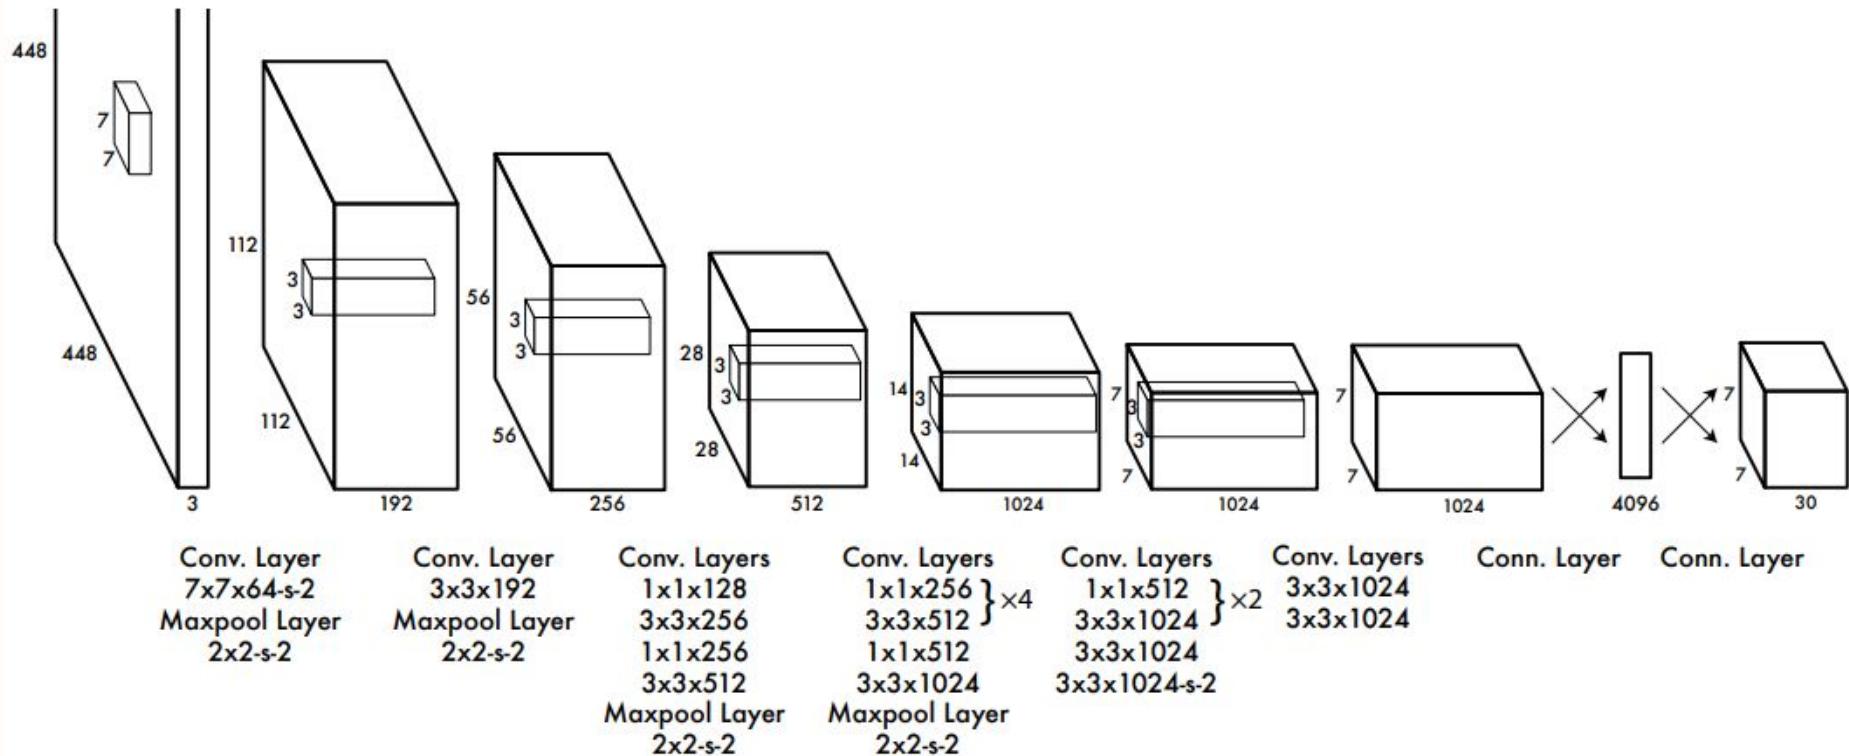


YOLO - “Algoritmo”

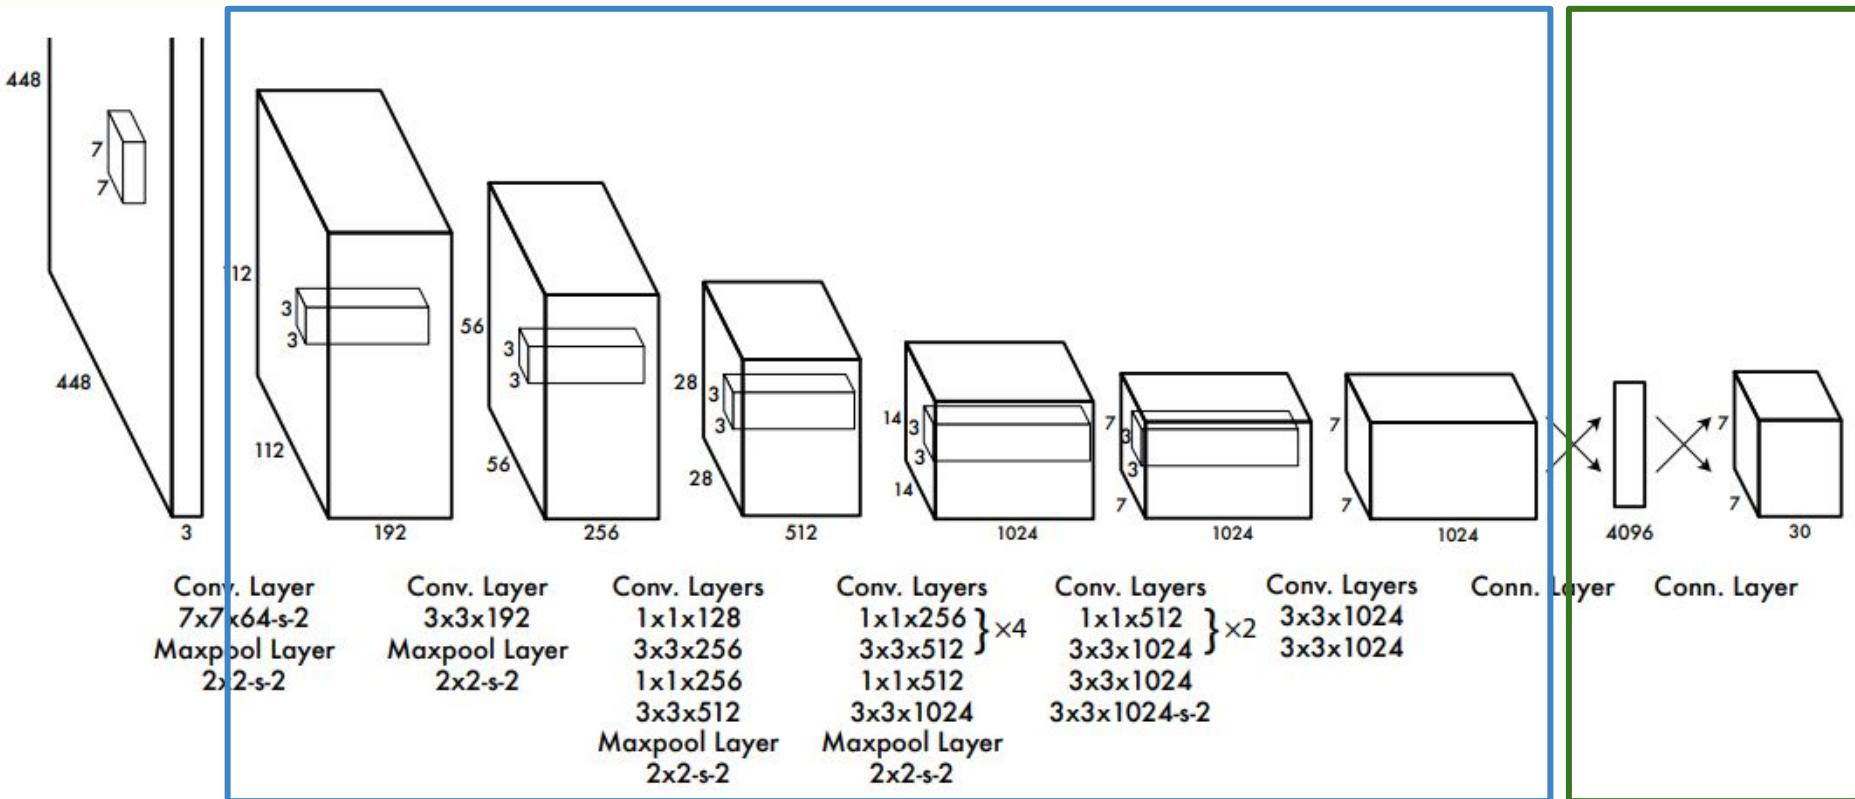
1. Inicialmente divide-se a imagem em grades de tamanho **SxS**
2. Para cada célula da grade geram-se **B** bounding boxes
3. Para cada retângulo **B** realizam-se as predições das coordenadas **bx**, **by**, **bw** e **bh** e de uma **object score** que indica a probabilidade da célula conter um objeto conhecido
4. Se a bounding box contiver um objeto, então teremos também uma predição da **classe** correspondente ao objeto



YOLO - Arquitetura (DarkNet)

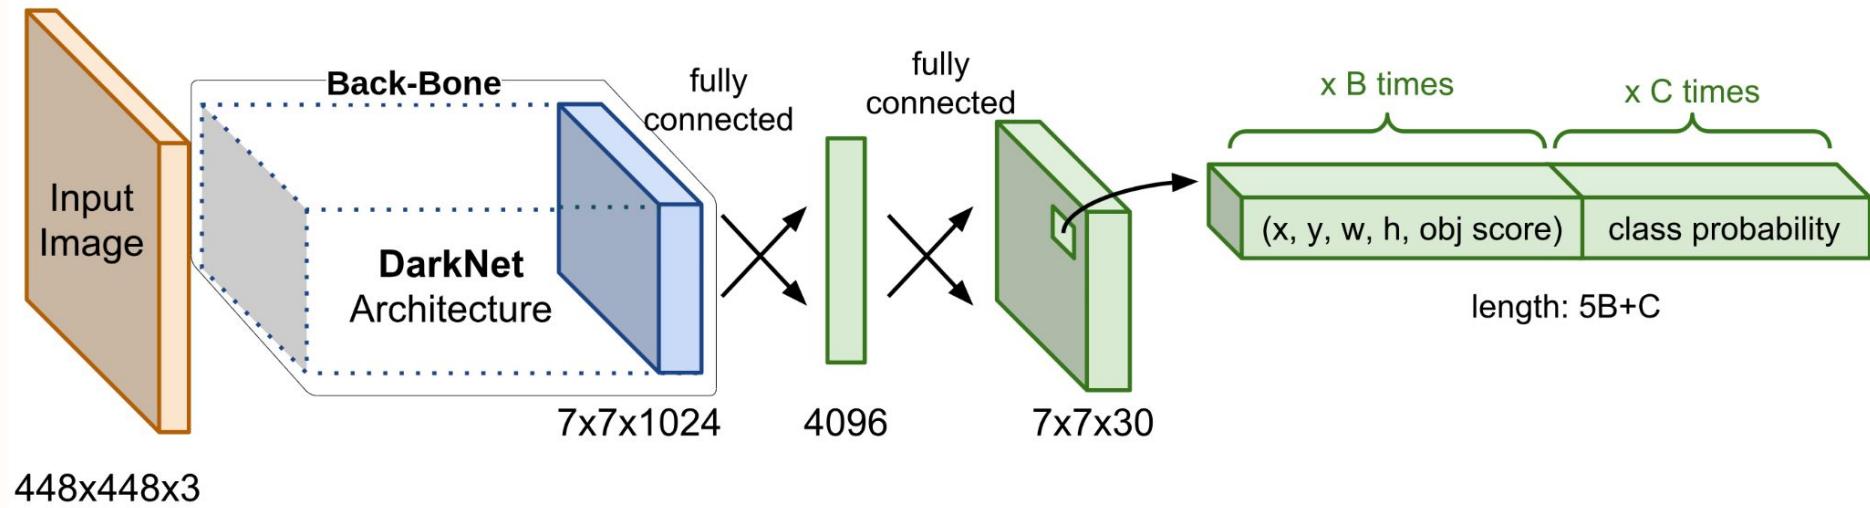


YOLO - Arquitetura (DarkNet)



DarkNet

YOLO - Arquitetura

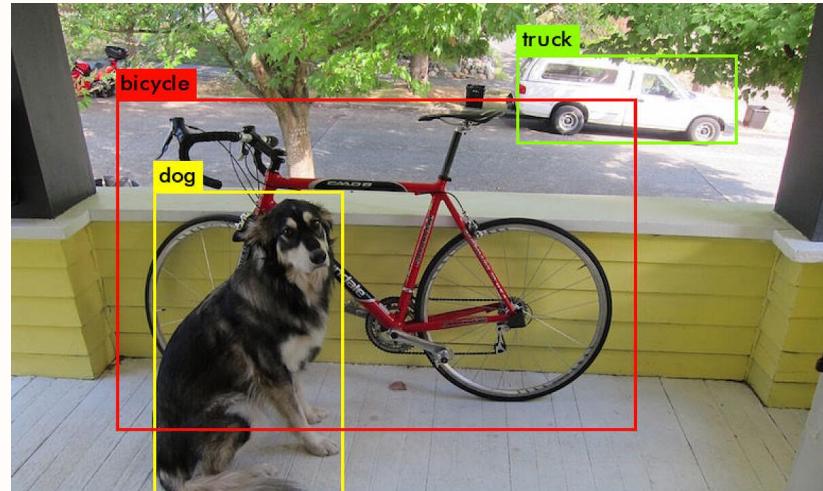
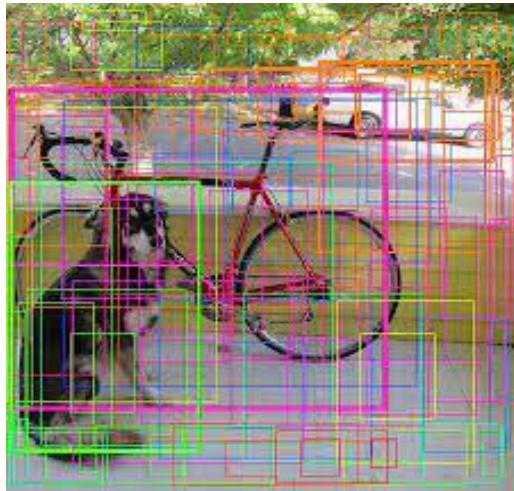


YOLO - Loss

$$\begin{aligned} & \lambda_{\text{coord}} \sum_{i=0}^{S^2} \sum_{j=0}^B \mathbb{1}_{ij}^{\text{obj}} \left[(x_i - \hat{x}_i)^2 + (y_i - \hat{y}_i)^2 \right] \\ & + \lambda_{\text{coord}} \sum_{i=0}^{S^2} \sum_{j=0}^B \mathbb{1}_{ij}^{\text{obj}} \left[\left(\sqrt{w_i} - \sqrt{\hat{w}_i} \right)^2 + \left(\sqrt{h_i} - \sqrt{\hat{h}_i} \right)^2 \right] \\ & + \sum_{i=0}^{S^2} \sum_{j=0}^B \mathbb{1}_{ij}^{\text{obj}} \left(C_i - \hat{C}_i \right)^2 \\ & + \lambda_{\text{noobj}} \sum_{i=0}^{S^2} \sum_{j=0}^B \mathbb{1}_{ij}^{\text{noobj}} \left(C_i - \hat{C}_i \right)^2 \\ & + \sum_{i=0}^{S^2} \mathbb{1}_i^{\text{obj}} \sum_{c \in \text{classes}} (p_i(c) - \hat{p}_i(c))^2 \end{aligned}$$

YOLO - NMS

- Non-Maximum Suppression (NMS) é utilizado para eliminar detecções redundantes
 - ◆ Se baseia nos valores de IoU para cada detecção realizada



YOLO - NMS (Algoritmo)

- Non-Maximum Suppression (NMS) é utilizado para eliminar detecções redundantes
 - 1. Ordenar os bounding boxes de acordo com seu valor de confiança
 - 2. Selecionar os bounding boxes com maiores scores
 - 3. Remover bounding boxes com alto valor de IoU
 - 4. Repetir os passos 2-3 até não restar bounding boxes a serem comparados

YOLO - NMS (Algoritmo)

- Non-Maximum Suppression (NMS) é utilizada para eliminar detecções redundantes

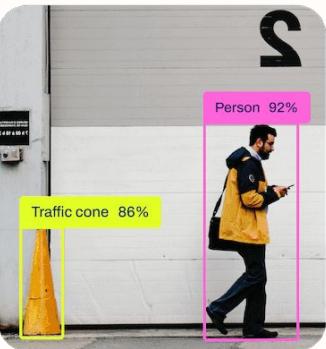
```
def iou(box1, box2):  
  
    def nms(bounding_boxes, confidence_threshold=.8, iou_threshold=.5):  
        # bounding box: xl, yl, x2, y2, confidence  
  
        bounding_boxes = sorted(bounding_boxes, reverse=True, key = lambda x: x[5])  
  
        bbox_filtered = [box for box in bounding_boxes if box[5] > confidence_threshold]  
  
        has_box = True  
  
        bbox_supressed = list()  
  
        while has_box:  
            current_box = bbox_filtered.pop(0)  
  
            bbox_supressed.append(current_box)  
  
            for box in bbox_filtered:  
                iou_value = iou(current_box[:4], box[:4])  
                if iou_value > iou_threshold: bbox_filtered.remove(box)  
  
            if len(bbox_filtered) == 0: has_box = False  
  
        return bbox_supressed
```

YOLO Aplicações

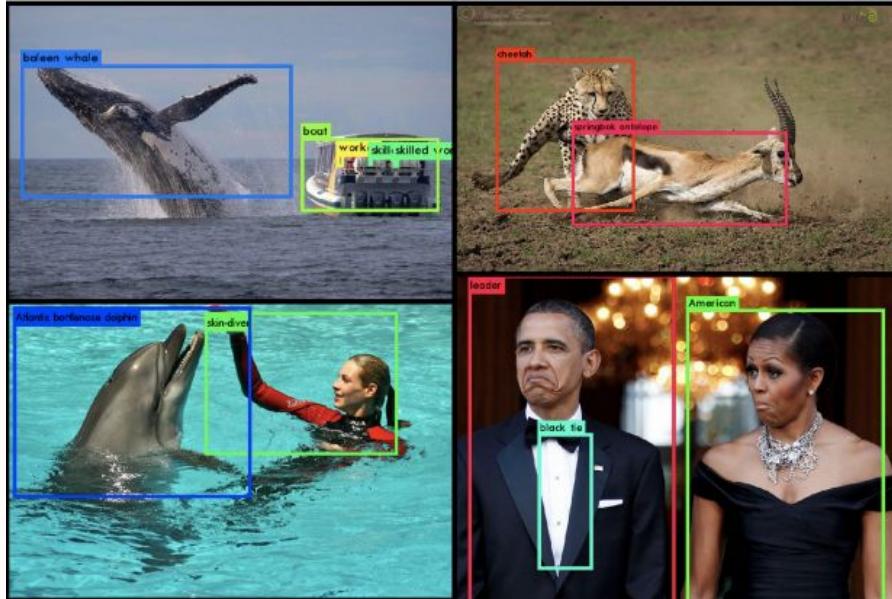
Classify



Detect



Backbone	Top-1	Top-5	Bn Ops	BFLOP/s	FPS
Darknet-19 [15]	74.1	91.8	7.29	1246	171
ResNet-101[5]	77.1	93.7	19.7	1039	53
ResNet-152 [5]	77.6	93.8	29.4	1090	37
Darknet-53	77.2	93.8	18.7	1457	78

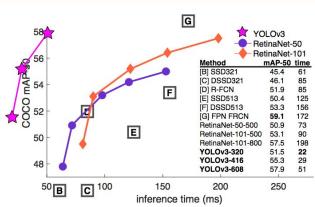


- Utilizado em diversas aplicações de visão (detecção veículos, pessoas, objetos)
- Eficiente (rápido e leve)

Evolução YOLO



YOLOv1: Concepção da arquitetura YOLO, popularizado por suas características (e.g., singleshot, rápido e preciso); Disponibilização do darknet e cfgs



YOLOv3: Melhoria da performance do modelo, utilizando múltiplas anchors e spatial pyramid pooling; Último modelo implementado na darknet;



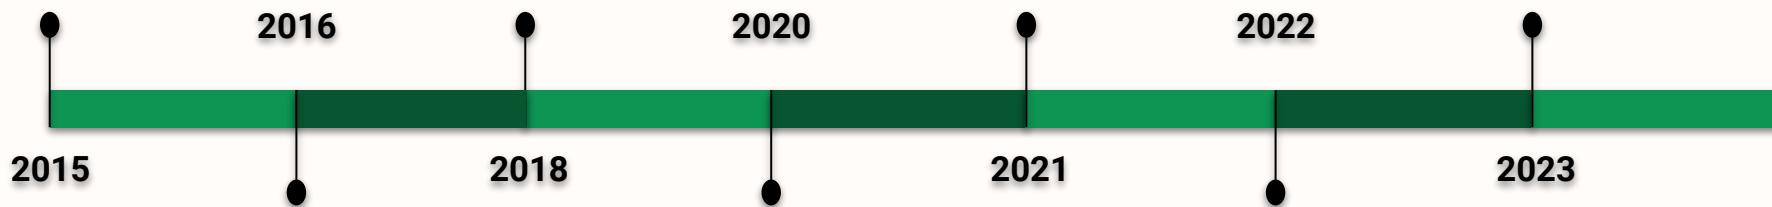
YOLOS: Integração de transformers e detecção sequencial



YOLOv8

Atualização do modelo v5 da ultralytics; Framework unificado para treinamento e avaliação do modelo; integração com principais ferramentas de exp. tracking;

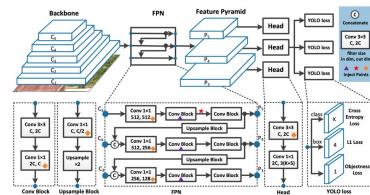
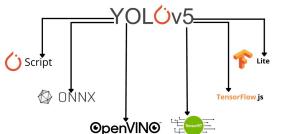
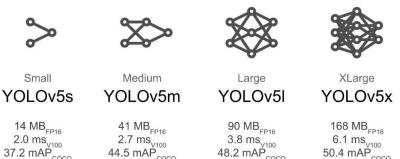
YOLO-NAS: Utilização do NAS para desing da arquitetura; Novas estratégias de treinamento e quantização do modelo;



YOLOv2, YOLO9000: Melhoria do modelo original, incorporando os conceitos de batch normalization, anchor boxes e clusters de dimensão



YOLOv4: Novas estratégias utilizando mosaic augmentation, nova função de loss e a eliminação de anchors;
YOLOv5: Esforço de integração com otimização de hiperparâmetros, experiment tracking e conversão para diferentes formatos dos frameworks mais populares



DarkNet (2015 - 2018)

home darknet cog tactics publications projects résumé



Darknet: Open Source Neural Networks in C

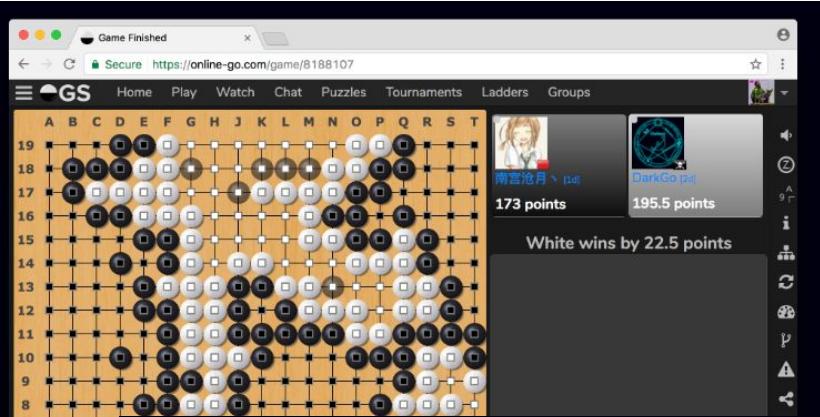
Darknet is an open source neural network framework written in C and CUDA. It is fast, easy to install, and supports CPU and GPU computation. You can find the source on [GitHub](#) or you can read more about what Darknet can do right here:

Installing Darknet
Darknet is easy to install and run. This post will guide you through it.

YOLO: Real-Time Object Detection
You only look once (YOLO) is a state-of-the-art, real-time object detection system.

ImageNet Classification
Classify images with popular models like ResNet and ResNeXt.

Nightmare
Use Darknet's black magic to conjure ghosts, ghouls, and wild badgermoles. But be warned, ye who enter here: no one is safe in the land of nightmares.



Once upon a time, in a University building almost, but not quite, entirely unlike the one you are sitting in right now, Simonyan, Vedaldi, and Zisserman had a great idea. They thought, hey we've been running these neural networks forward and they work pretty well, why not run them backward too? That way we can figure out what the computer is actually thinking about in there...

The resulting images were so horrific, so grotesque, that their screams could be heard all the way to Templeton.



<https://pjreddie.com/darknet/>
<https://online-go.com/user/view/434218>

DarkNet - Arquivos CFG

- Definição dos parâmetros de treino, camadas do modelo e valores de threshold

```
1 [net]
2 # how many images are in each batch
3 batch=1
4 # into how many sub-batches shall
5 subdivisions=1
6 # input size of the network
7 height=448
8 width=448
9 channels=3
10 # learning parameters
11 momentum=0.9
12 decay=0.0005
13 b_debug=0
14
15 # base learning rate
16 learning_rate=0.001
17 # change learning rate after the
18 policy=steps
19 # need to have as many steps as s
20 steps=200,400,600,20000,30000
21 # re-scale the current learning r
22 scales=2.5,2,2,.1,.1
23 # max number of "iterations"
24 max_batches = 40000
25 # snapshot the learned weights af
26 i_snapshot_iteration=1000
27 #
28 #
29 c_ending_gt_files=.txt
```

```
33 # thereby, we can use the tea
34 #
35 [convolutional]
36 filters=64
37 size=7
38 stride=2
39 pad=1
40 activation=leaky
41
42 [maxpool]
43 size=2
44 stride=2
45
46 [convolutional]
47 filters=192
48 size=3
49 stride=1
50 pad=1
51 activation=leaky
52
53 [maxpool]
54 size=2
55 stride=2
56
57 [convolutional]
58 filters=128
59 size=1
60 stride=1
61 pad=1
62 activation=leaky
63
```

```
[connected]
#needs to be side*side*((1 + l.coord
# l.coords -- 4 coordinates to speci
# l.n -- how many bounding boxes are
# e.g., 20 classes, side 7 -> 1470
# e.g., 20 class, side 9 -> 2430
output= 1470
activation=linear

[detection]
# 20 for pascal voc (l.classes)
classes=20
# bounding boxes -> 4 parameters (l.
coords=4
rescore=1
b_debug=1
# number of cell in x and y direction
side=7
# number of predicted boxes per cell
num=2
softmax=0
# adapt loss function on bounding bo
sqrt=1
jitter=.2

# relative weights for the combined
object_scale=1
noobject_scale=.5
class_scale=1
coord_scale=5
```

YOLO9000 (YOLOv2) - Arquitetura (DarkNet19)

Type	Filters	Size/Stride	Output
Convolutional	32	3×3	224×224
Maxpool		$2 \times 2/2$	112×112
Convolutional	64	3×3	112×112
Maxpool		$2 \times 2/2$	56×56
Convolutional	128	3×3	56×56
Convolutional	64	1×1	56×56
Convolutional	128	3×3	56×56
Maxpool		$2 \times 2/2$	28×28
Convolutional	256	3×3	28×28
Convolutional	128	1×1	28×28
Convolutional	256	3×3	28×28
Maxpool		$2 \times 2/2$	14×14
Convolutional	512	3×3	14×14
Convolutional	256	1×1	14×14
Convolutional	512	3×3	14×14
Convolutional	256	1×1	14×14
Convolutional	512	3×3	14×14
Maxpool		$2 \times 2/2$	7×7
Convolutional	1024	3×3	7×7
Convolutional	512	1×1	7×7
Convolutional	1024	3×3	7×7
Convolutional	512	1×1	7×7
Convolutional	1024	3×3	7×7
Convolutional	1000	1×1	7×7
Avgpool		Global	1000
Softmax			

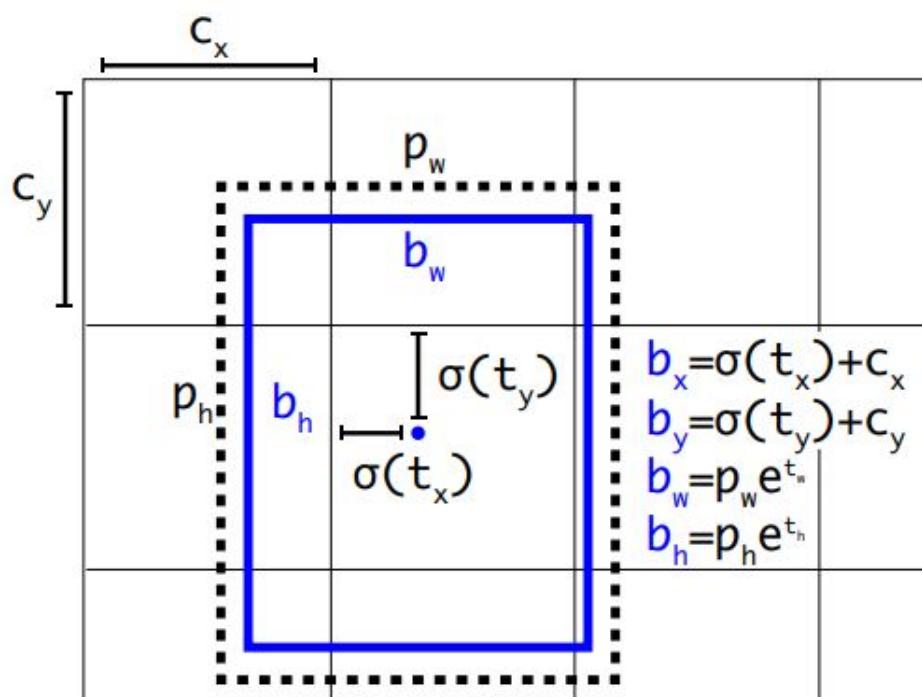
→ YOLO9000: Better, Faster,
Stronger

- ◆ Batch Normalization
- ◆ Variação de resolução no treino
(Multi-scale training)
- ◆ Anchors boxes
- ◆ Dimension clusters

<https://arxiv.org/pdf/1612.08242.pdf>

YOLO9000 (YOLOv2)

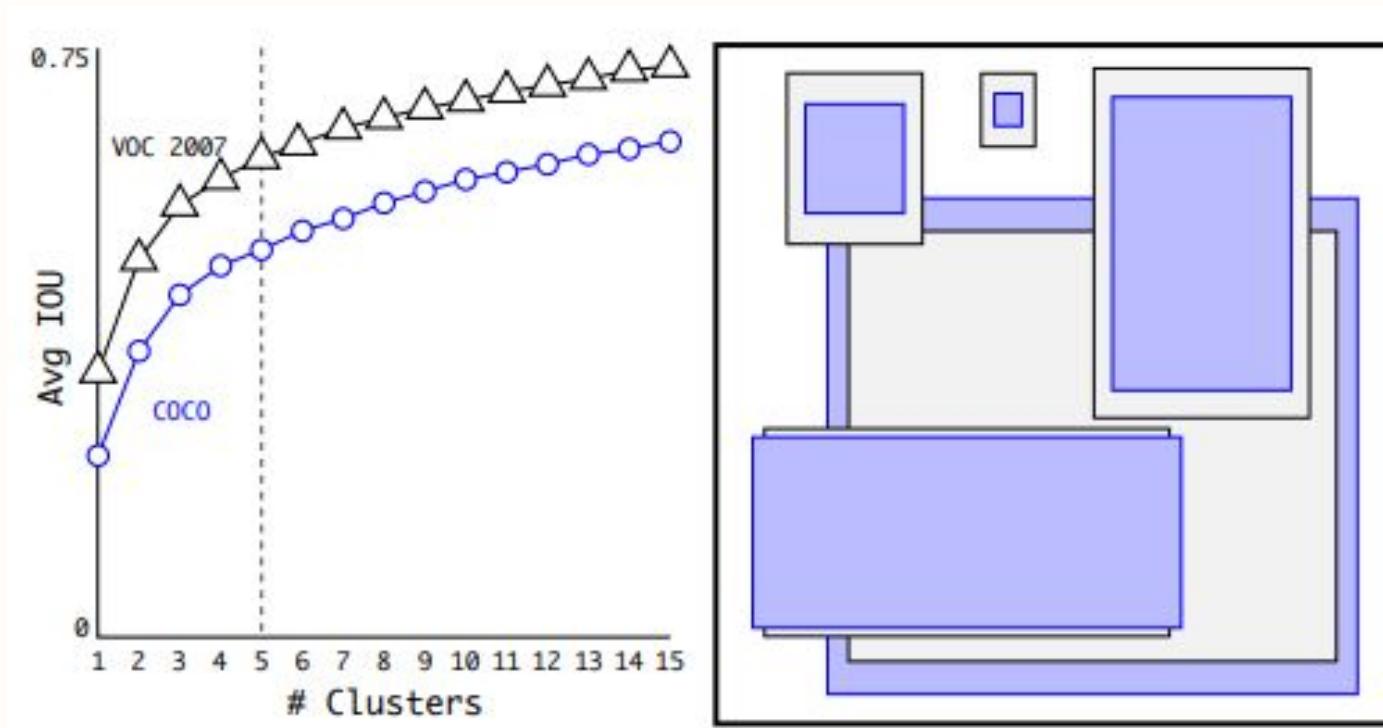
- A predição é realizada através da estimação do ponto central e dos valores que definem a dimensão do objeto na posição avaliada
- A rede retorna $N \times B$ predições, onde N é o valor de âncoras previamente definido e B o número de predições máxima realizada em cada célula/posição da imagem



$$x = (t_x * w_a) - x_a$$
$$y = (t_y * h_a) - y_a$$

YOLO9000 (YOLOv2) - Clustering Dimensions

- K-means é utilizado no conjunto de treino para gerar grupos de bounding boxes com dimensões similares
 - ◆ Número de grupos define dimensões válidas de referência para as âncoras



YOLOv3: An incremental Improvement

Type	Filters	Size	Output	
1x	Convolutional	32	3×3	256×256
	Convolutional	64	$3 \times 3 / 2$	128×128
	Convolutional	32	1×1	
	Convolutional	64	3×3	
	Residual			128×128
2x	Convolutional	128	$3 \times 3 / 2$	64×64
	Convolutional	64	1×1	
	Convolutional	128	3×3	
	Residual			64×64
8x	Convolutional	256	$3 \times 3 / 2$	32×32
	Convolutional	128	1×1	
	Convolutional	256	3×3	
	Residual			32×32
	Convolutional	512	$3 \times 3 / 2$	16×16
8x	Convolutional	256	1×1	
	Convolutional	512	3×3	
	Residual			16×16
	Convolutional	1024	$3 \times 3 / 2$	8×8
4x	Convolutional	512	1×1	
	Convolutional	1024	3×3	
	Residual			8×8
	Avgpool		Global	
	Connected		1000	
	Softmax			

Table 1. Darknet-53.

Backbone	Top-1	Top-5	Bn Ops	BFLOP/s	FPS
Darknet-19 [15]	74.1	91.8	7.29	1246	171
ResNet-101 [5]	77.1	93.7	19.7	1039	53
ResNet-152 [5]	77.6	93.8	29.4	1090	37
Darknet-53	77.2	93.8	18.7	1457	78

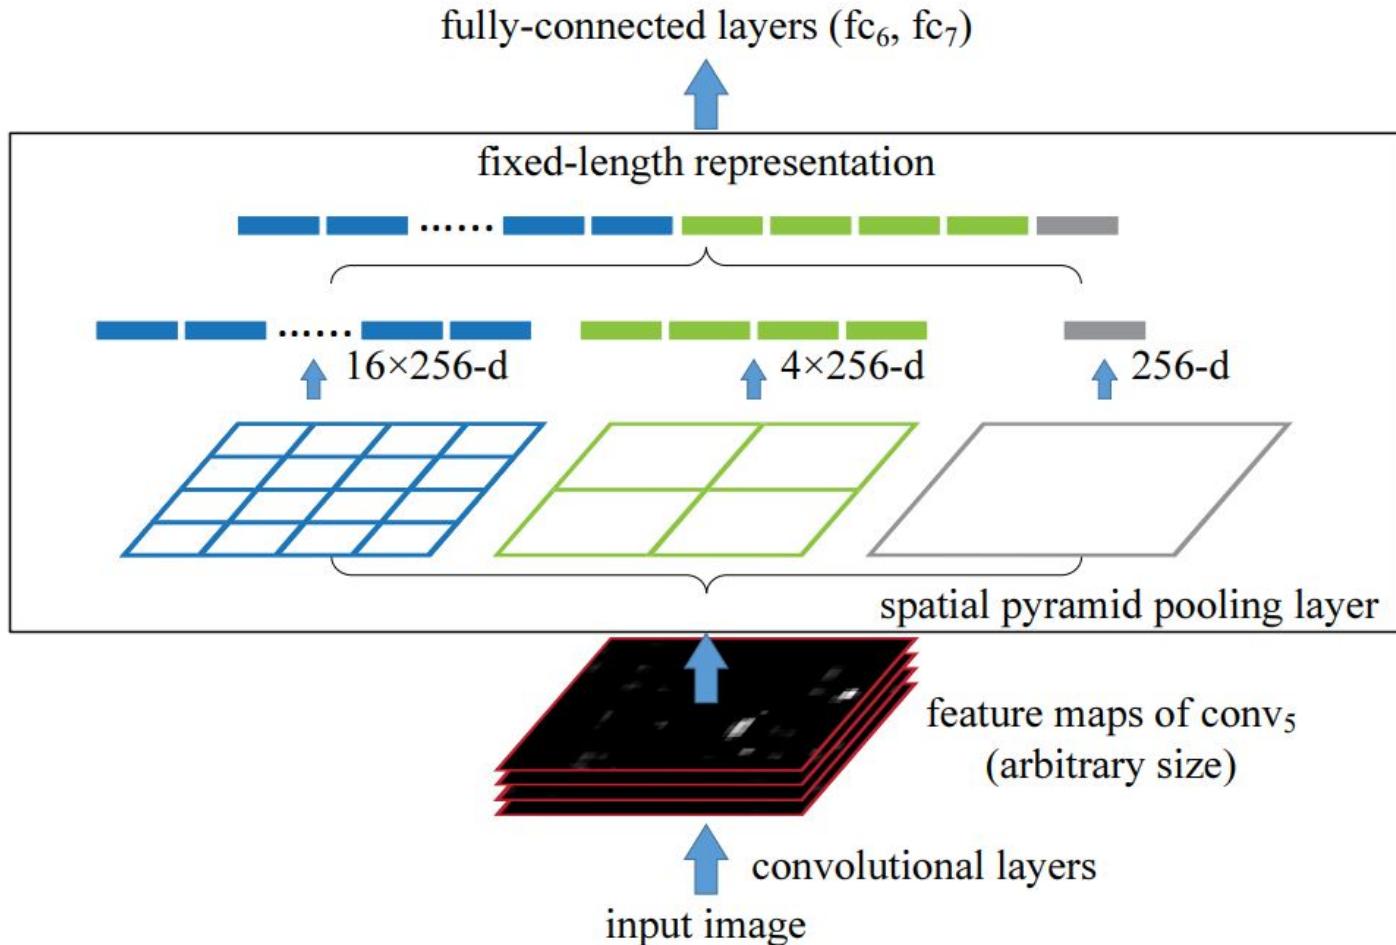
Abstract

We present some updates to YOLO! We made a bunch of little design changes to make it better. We also trained this new network that's pretty swell. It's a little bigger than last time but more accurate. It's still fast though, don't worry. At 320×320 YOLOv3 runs in 22 ms at 28.2 mAP, as accurate as SSD but three times faster. When we look at the old .5 IOU mAP detection metric YOLOv3 is quite good. It achieves 57.9 AP₅₀ in 51 ms on a Titan X, compared to 57.5 AP₅₀ in 198 ms by RetinaNet, similar performance but 3.8× faster. As always, all the code is online at <https://pjreddie.com/yolo/>.

2. The Deal

So here's the deal with YOLOv3: We mostly took good ideas from other people. We also trained a new classifier network that's better than the other ones. We'll just take you through the whole system from scratch so you can understand it all.

SPFF



YOLOv3

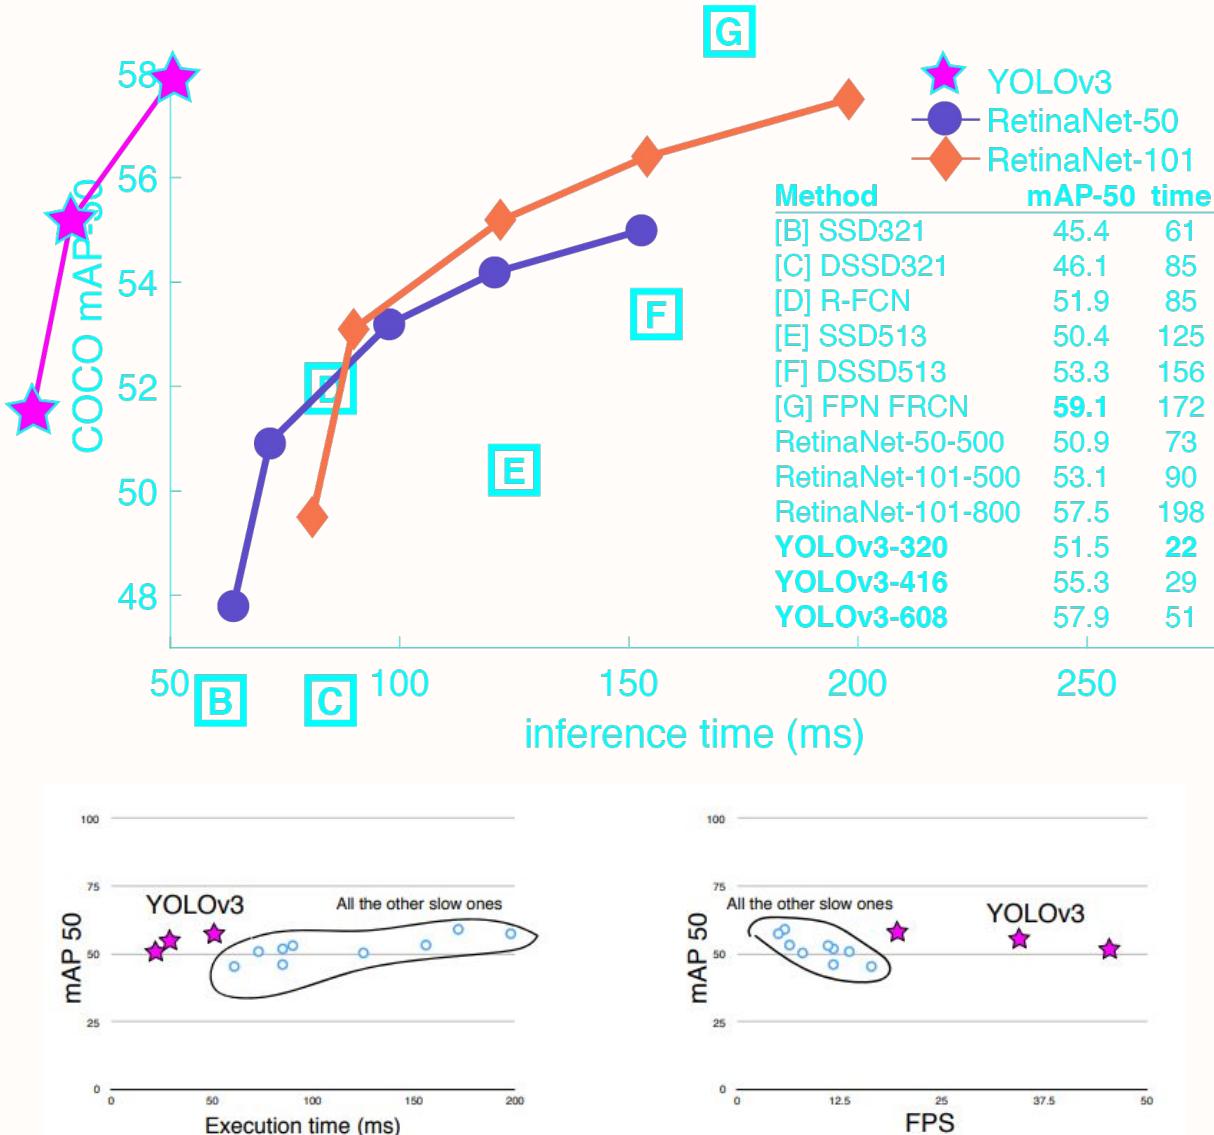
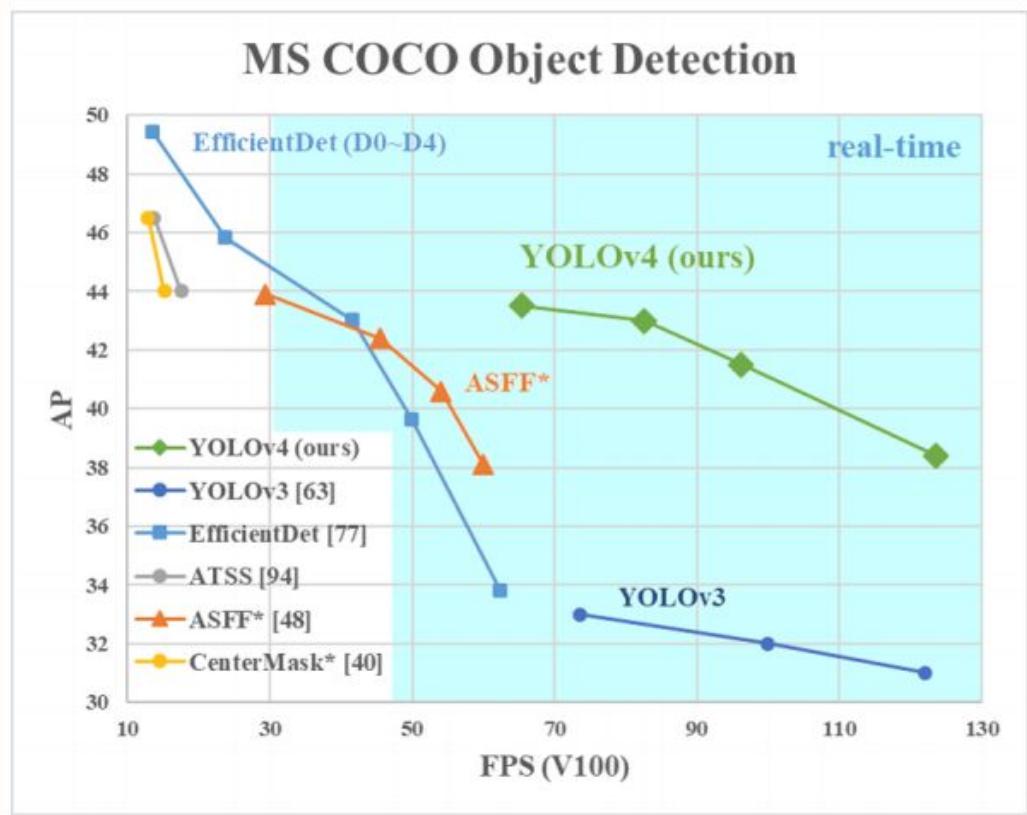


Figure 4. Zero-axis charts are probably more intellectually honest... and we can still screw with the variables to make ourselves look good!

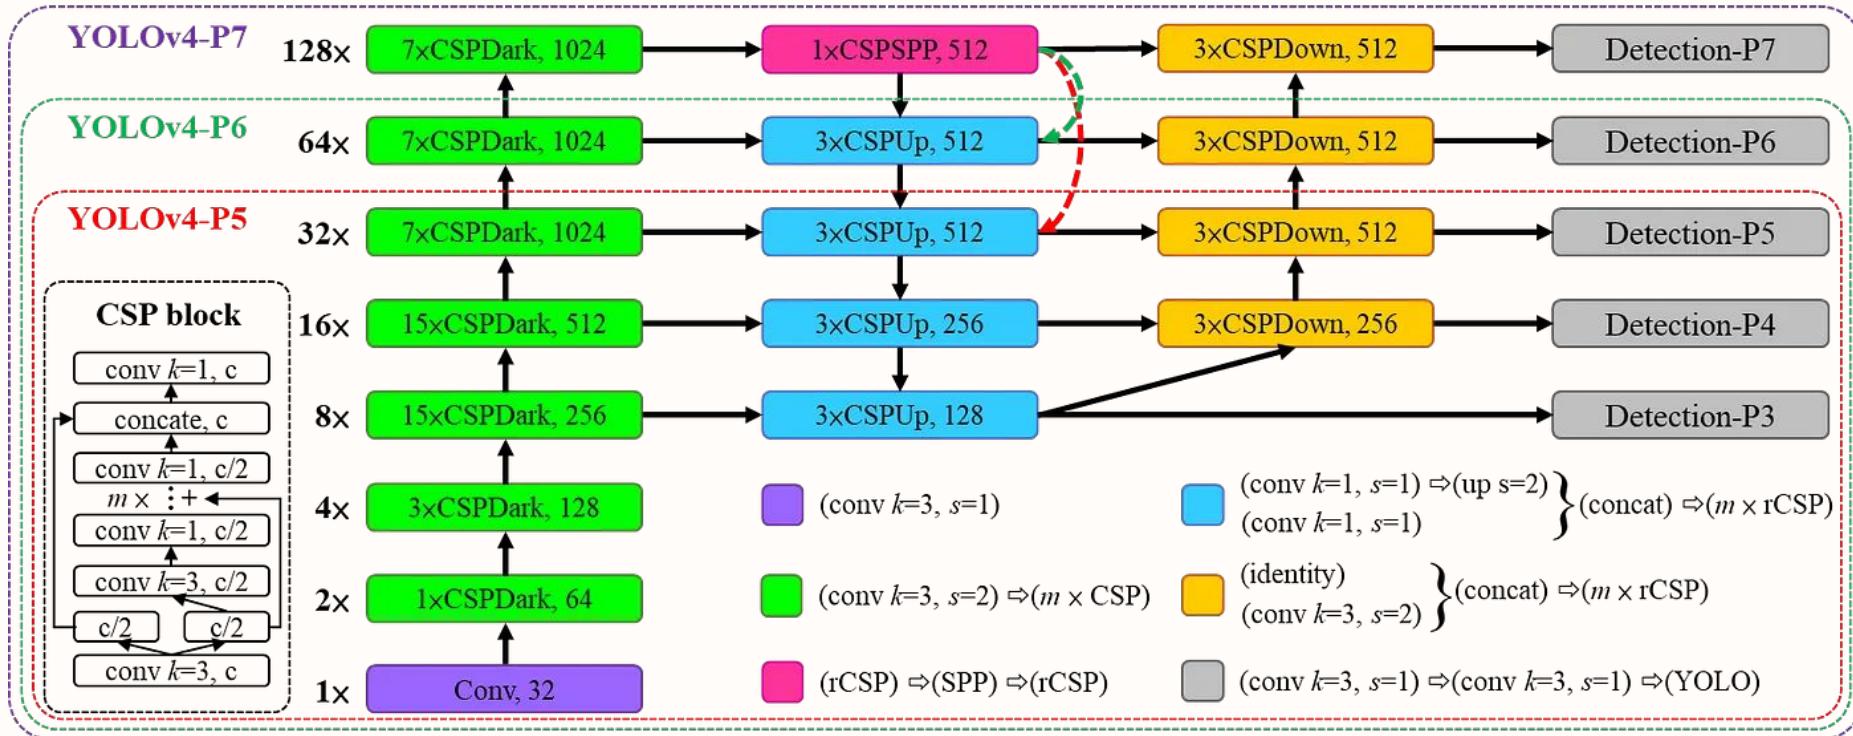
YOLOv4

- Novo backbone CSPDarknet53, melhorando acurácia e performance
- YOLOv4 otimizado para melhorar o uso de recursos (bom para edges device)
- Otimização de hiperparâmetros com algoritmos genéticos, novas estratégias de augmentation

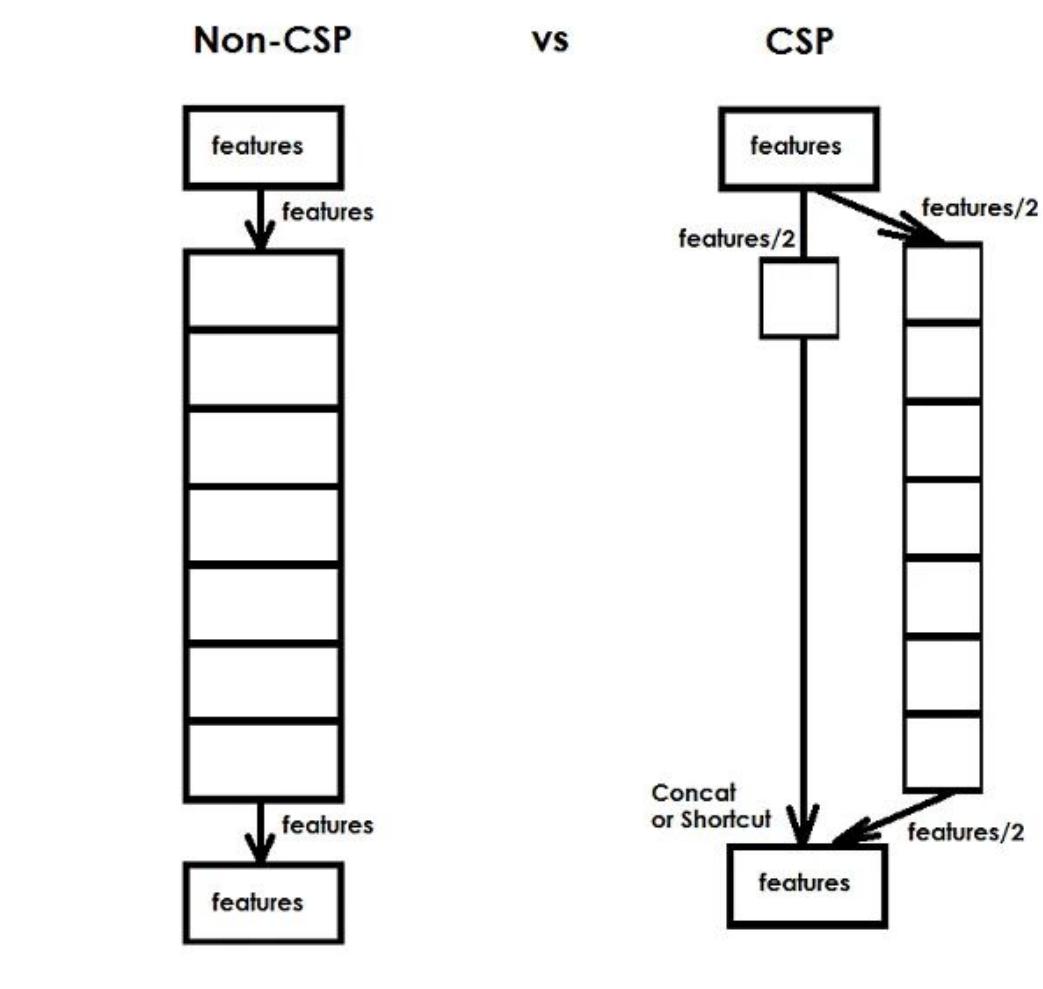


YOLOv4: Optimal Speed and Accuracy for object detection
<https://arxiv.org/pdf/2004.10934.pdf>

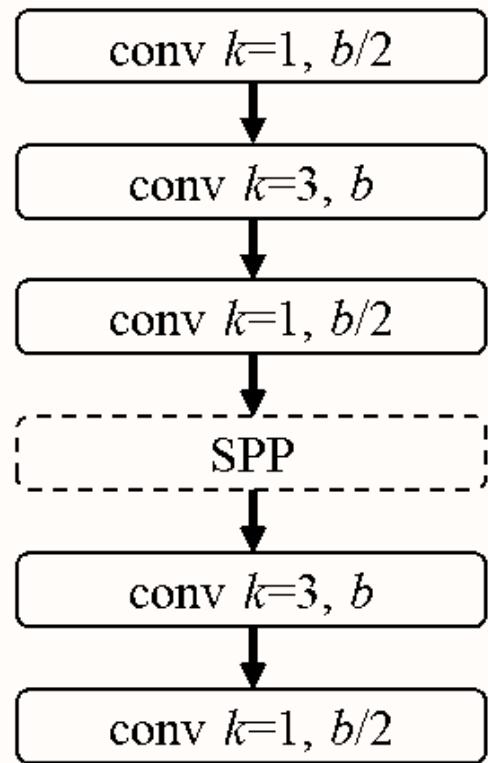
YoloV4



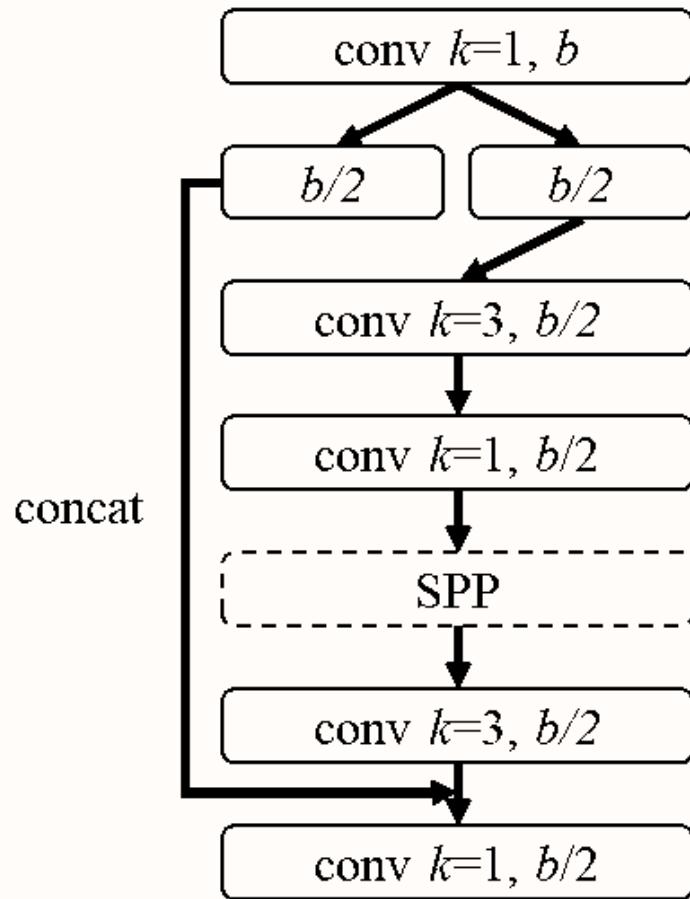
Yolov4



Yolov4



(a) reversed dark layers (SPP)



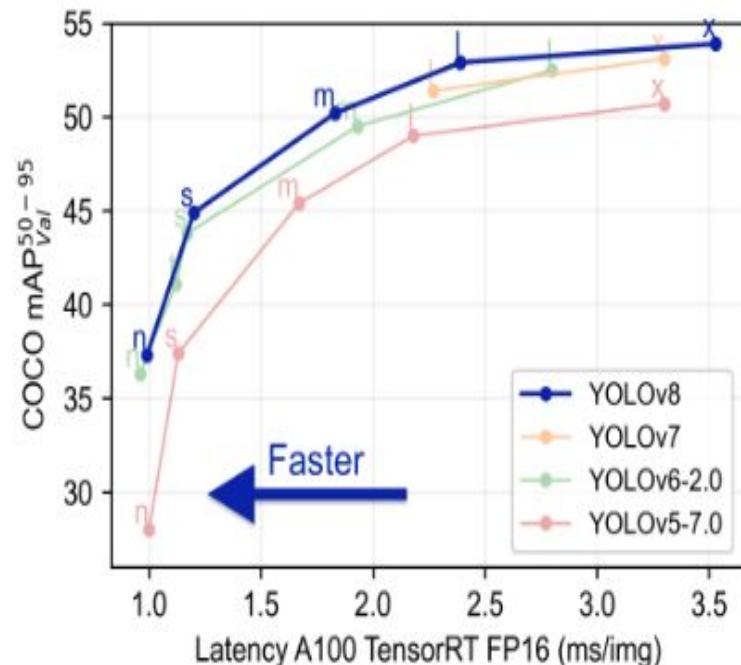
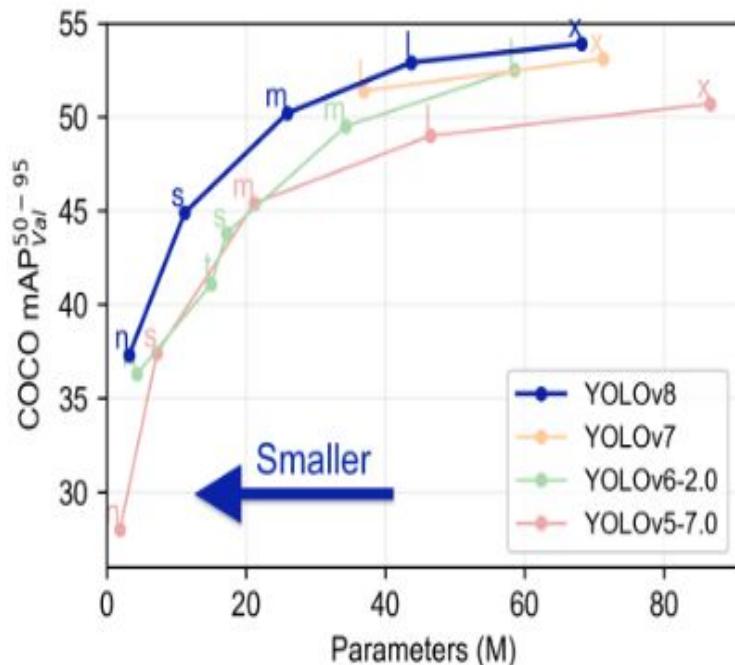
(b) reversed CSP dark layers (SPP)

YOLOv5, YOLOv8

Ultralytics YOLOv8 is a cutting-edge, state-of-the-art (SOTA) model that builds upon the success of previous YOLO versions and introduces new features and improvements to further boost performance and flexibility. YOLOv8 is designed to be fast, accurate, and easy to use, making it an excellent choice for a wide range of object detection and tracking, instance segmentation, image classification and pose estimation tasks.

We hope that the resources here will help you get the most out of YOLOv8. Please browse the YOLOv8 [Docs](#) for details, raise an issue on [GitHub](#) for support, and join our [Discord](#) community for questions and discussions!

To request an Enterprise License please complete the form at [Ultralytics Licensing](#).



YOLOv5, YOLOv8

Classify



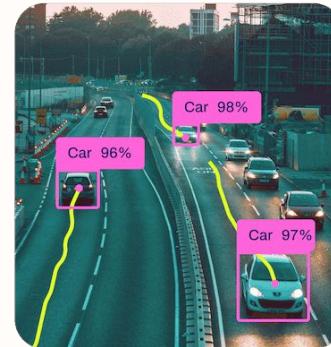
Detect



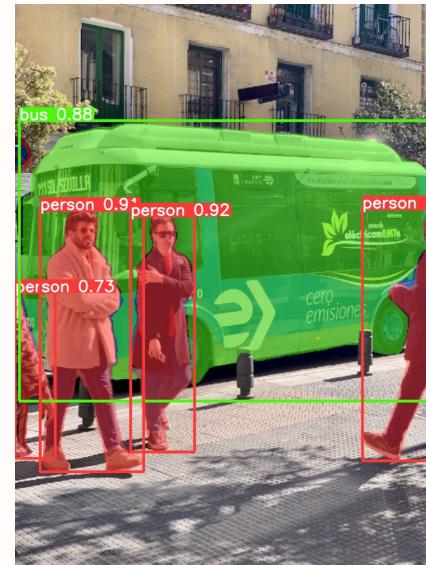
Segment



Track

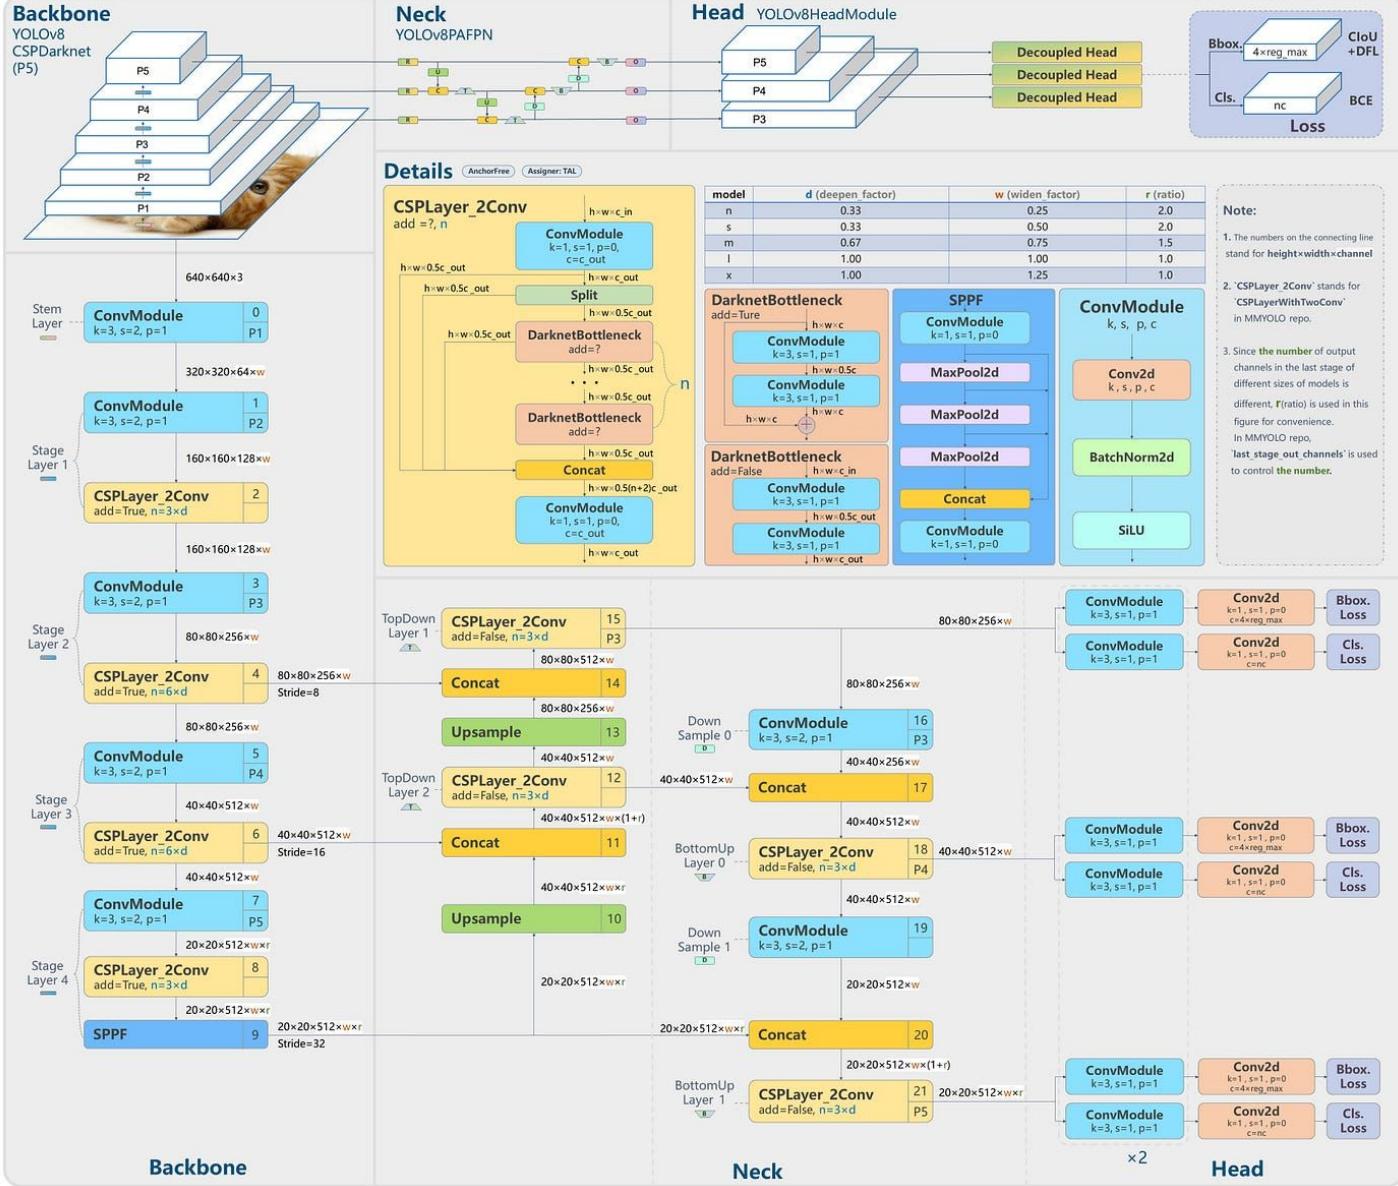


Pose

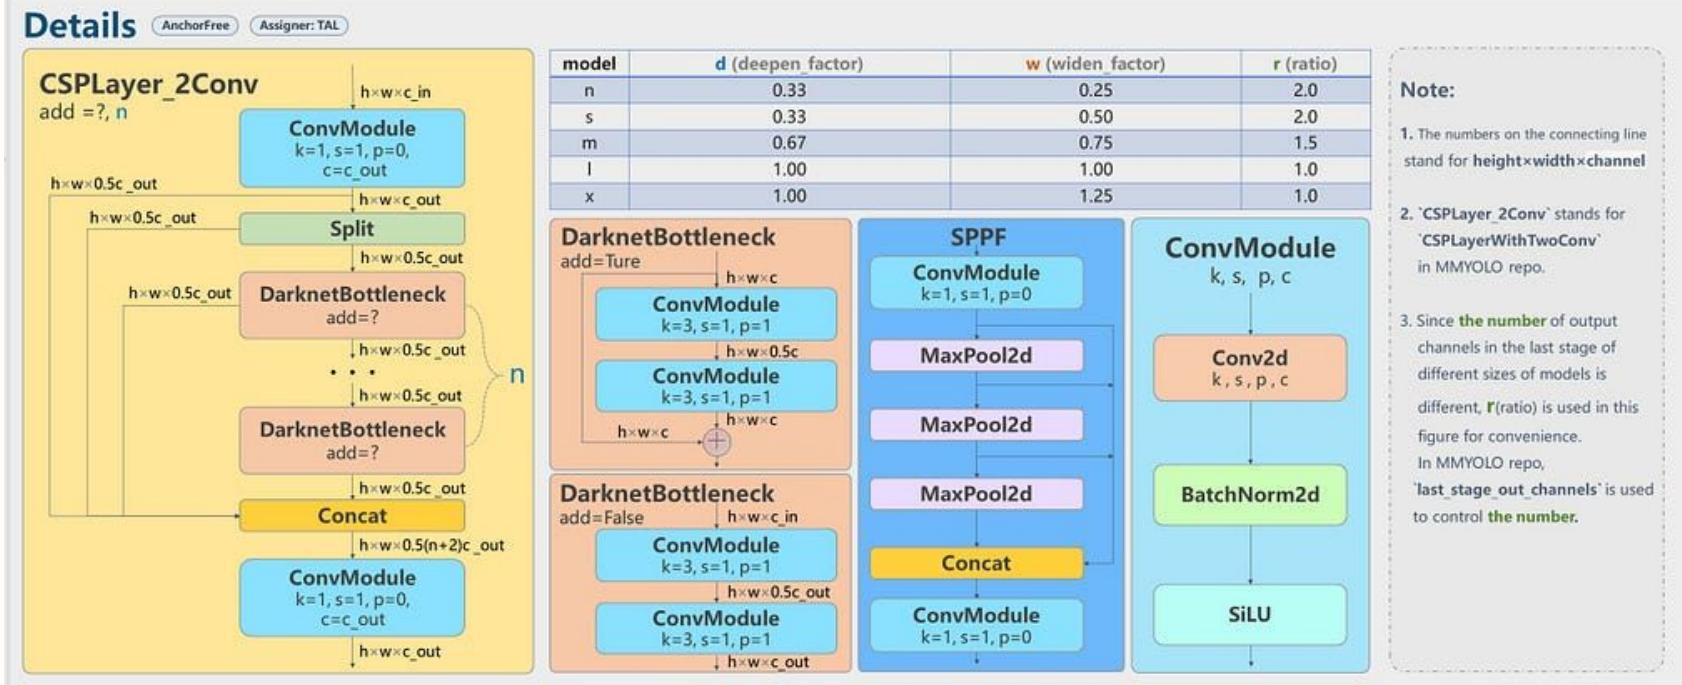


YOLOv8

YOLOv8

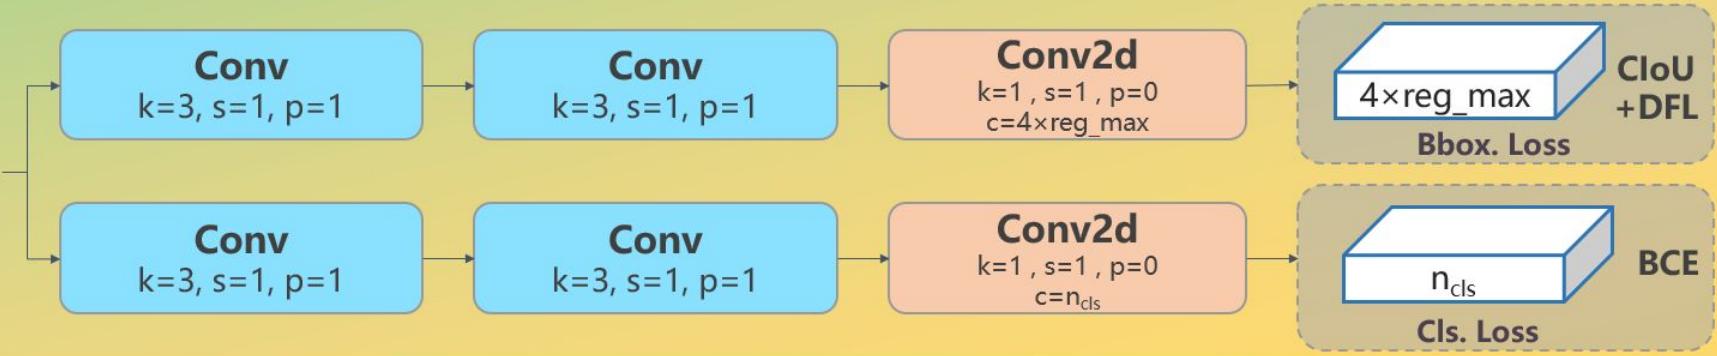


CSPLayer

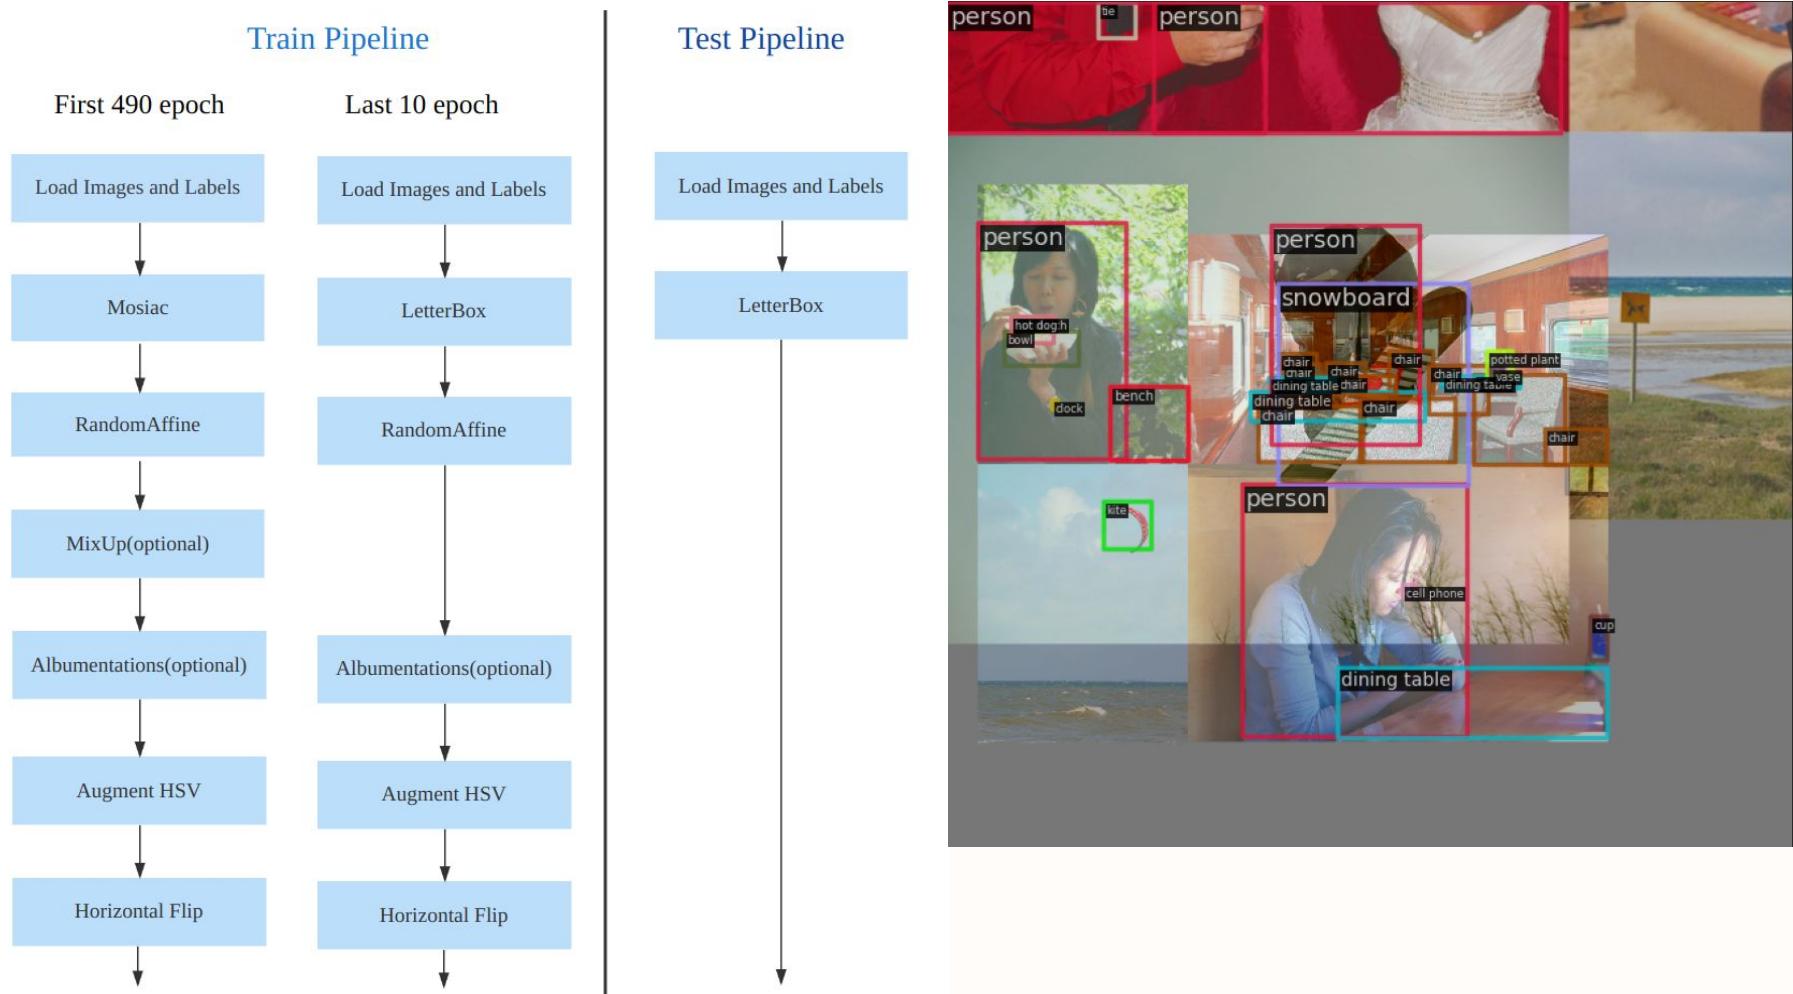


Decoupled Head

YOLOv8 Decoupled Head



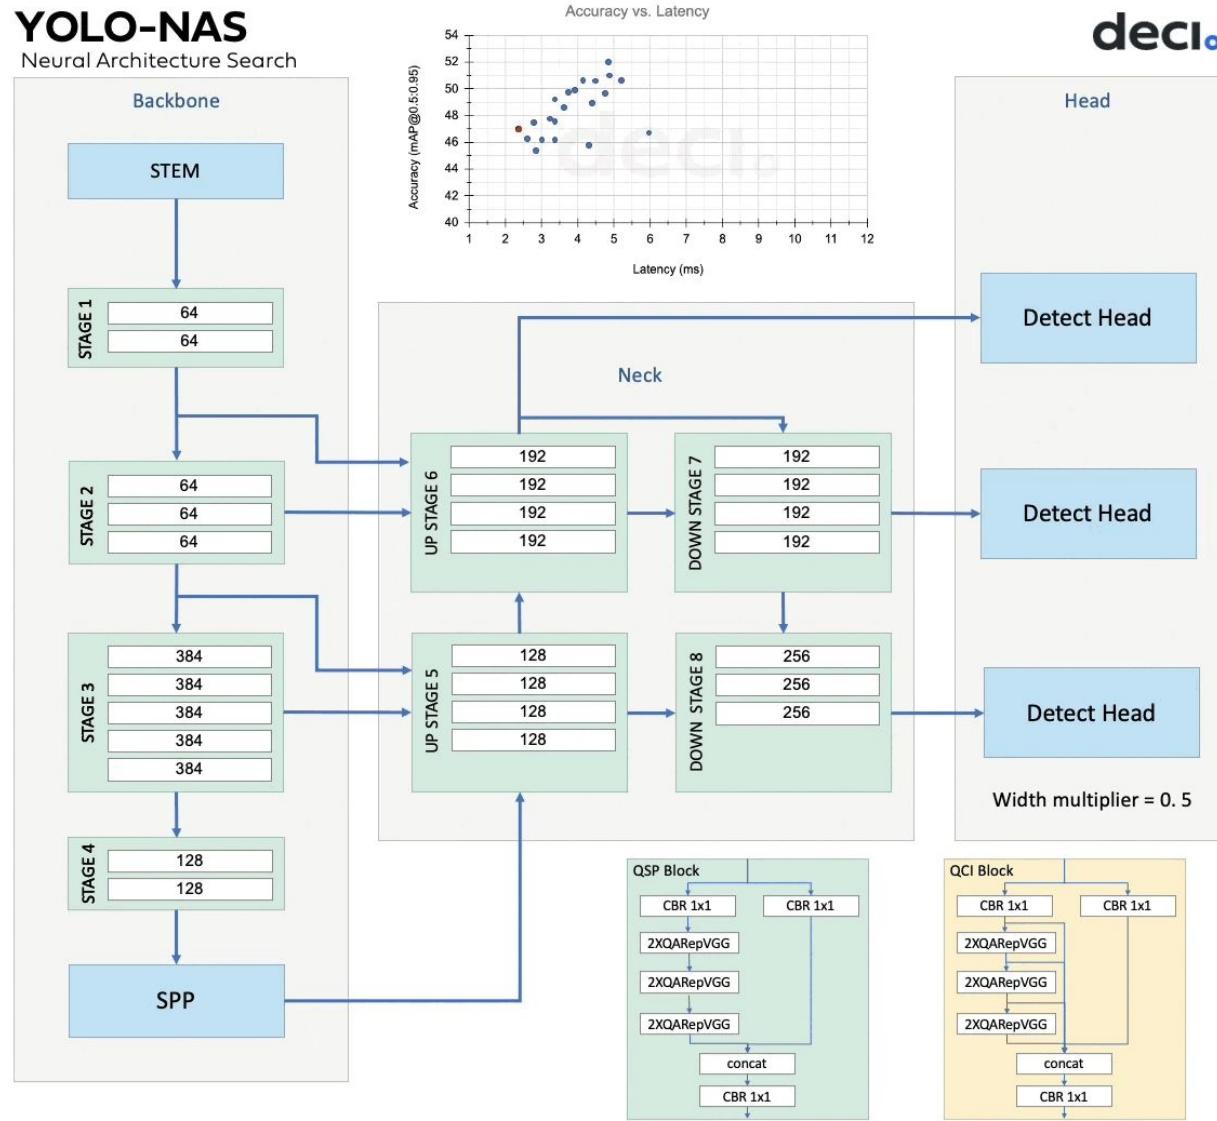
Augmentations



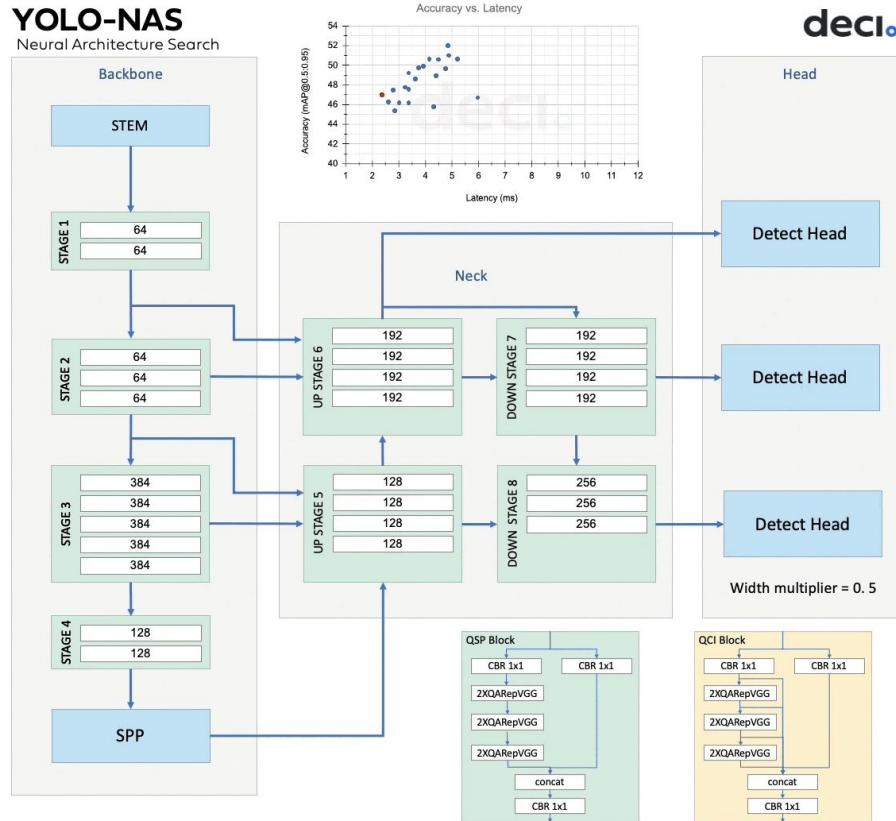
YOLOv8

Model	size (pixels)	mAP ^{val} 50-95	Speed CPU ONNX (ms)	Speed A100 TensorRT (ms)	params (M)	FLOPs (B)
<u>YOLOv8n</u>	640	37.3	80.4	0.99	3.2	8.7
<u>YOLOv8s</u>	640	44.9	128.4	1.20	11.2	28.6
<u>YOLOv8m</u>	640	50.2	234.7	1.83	25.9	78.9
<u>YOLOv8l</u>	640	52.9	375.2	2.39	43.7	165.2
<u>YOLOv8x</u>	640	53.9	479.1	3.53	68.2	257.8

YOLO-NAS (SOTA Object Detection)



YOLO-NAS (SOTA Object Detection)

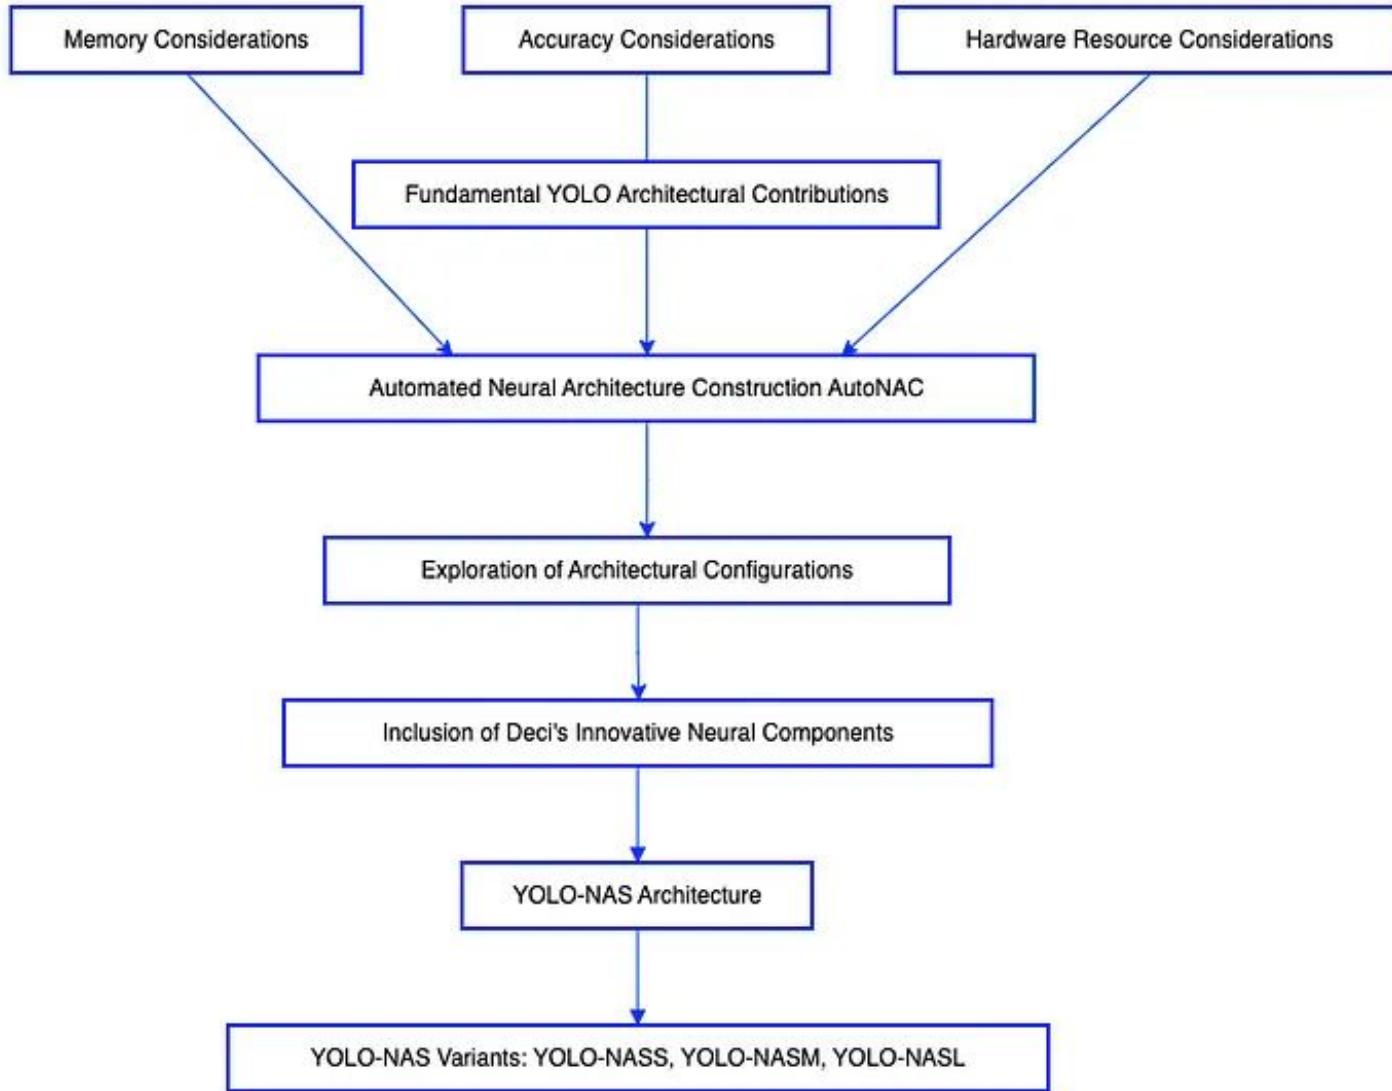


→ Modelo proposto pela Deci, utilizando o autoNAC (tecnologia NAS proprietária que facilita a busca e design de modelos)

YOLO-NAS - Network Architecture Search

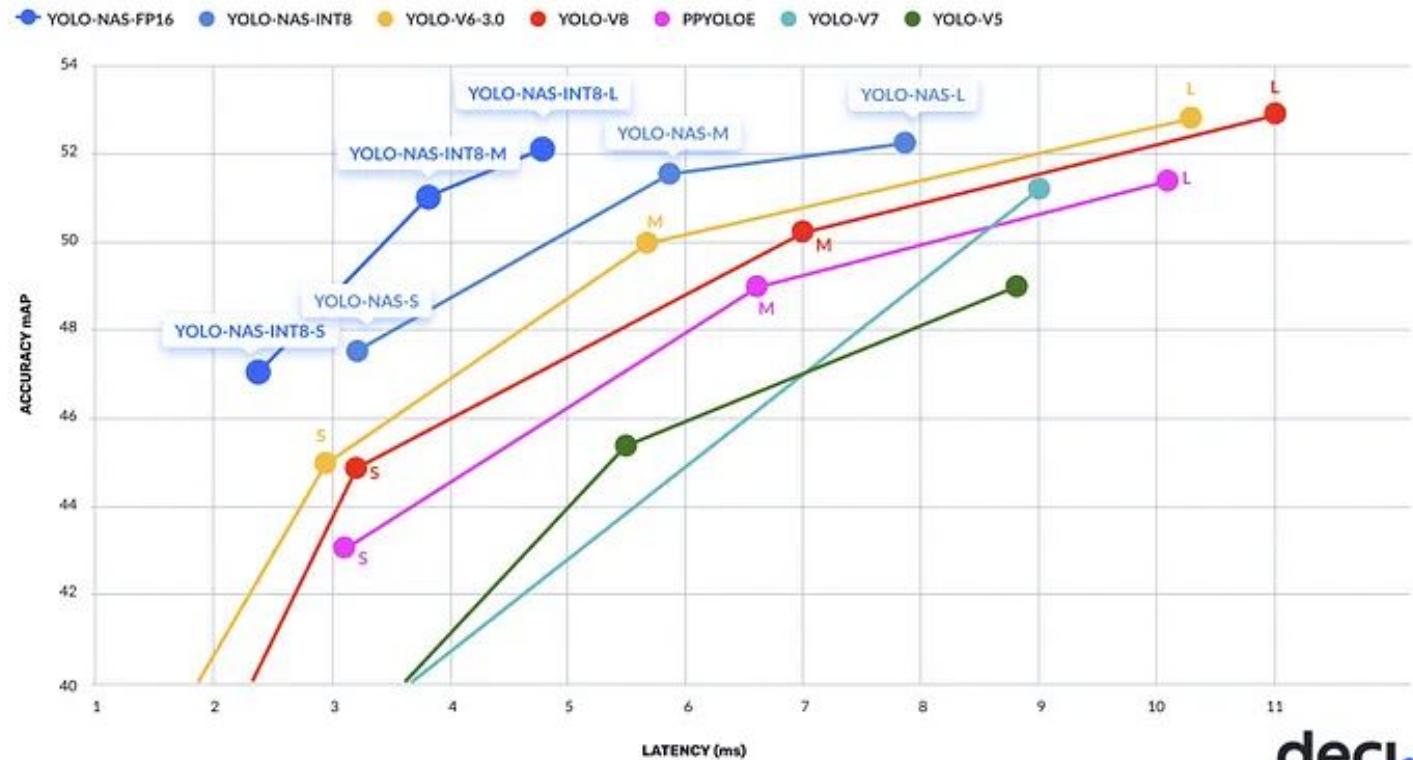
- NAS envolve o desenvolvimento e design de modelos de machine learning de forma automática, encontrando melhores configurações que superem o desempenho obtido pelo modelo original
 - ◆ Fatores de melhoria incluem tempo de inferência, recursos computacionais, complexidade da arquitetura e acurácia

YOLO-NAS - Network Architecture Search



YOLO-NAS - Resultados e variações

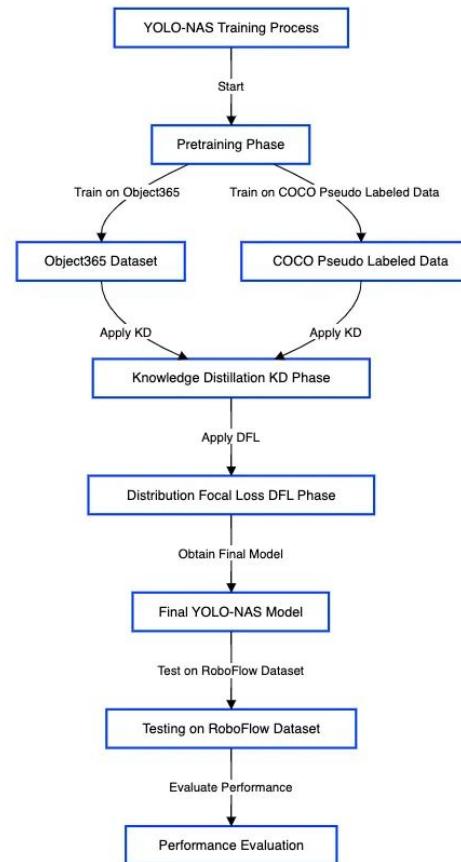
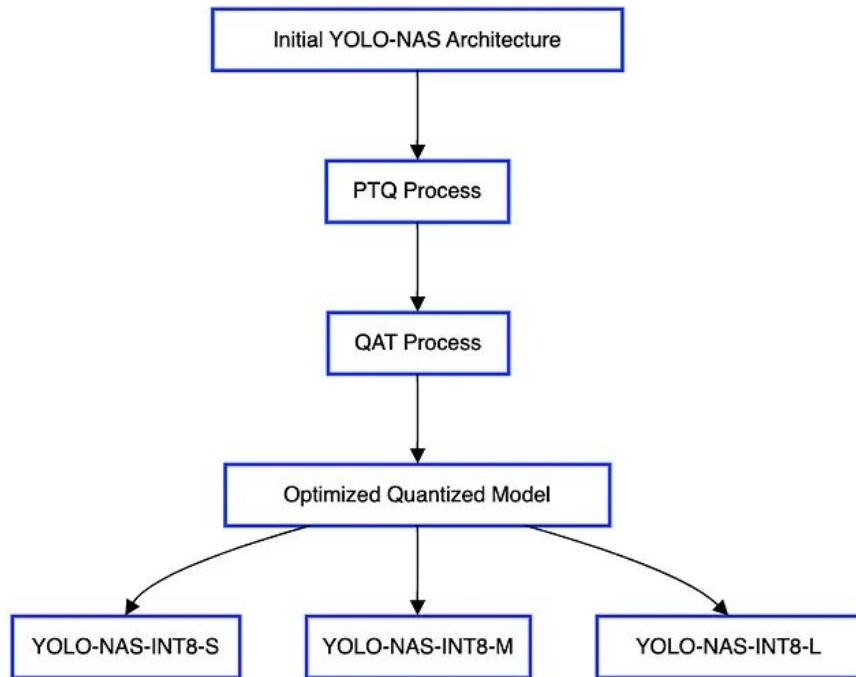
Efficient Frontier of Object Detection on COCO, Measured on NVIDIA T4



deci.^o

YOLO-NAS: Treinamento e otimização

- A arquitetura da Deci também propõe contribuições para melhoria do treinamento com estratégias de labeling e quantization



YOLO architectures review

Juan R. Terven, Diana M. Cordova-Esparza. **A COMPREHENSIVE REVIEW OF YOLO: FROM YOLOV1 AND BEYOND.** Oct. 2023.

<https://arxiv.org/pdf/2304.00501.pdf>

Datasets Detecção 2D

Detecção de objetos - Principais datasets

IMAGENET

14,197,122 images, 21841 synsets indexed

Home Download Challenges About

Not logged in. Login | Signup

ImageNet is an image database organized according to the **WordNet** hierarchy (currently only the nouns), in which each node of the hierarchy is depicted by hundreds and thousands of images. The project has been **instrumental** in advancing computer vision and deep learning research. The data is available for free to researchers for non-commercial use.

KITTI-360
http://www.cvlibs.net/datasets/kitti-360



KITTI Vision Benchmark Suite!

driving platform **Annieway** to develop novel challenging real-world computer vision benchmarks. Our tasks of interest are stereo, optical flow, visual odometry, 3D object detection and 3D tracking. For this purpose, we equipped a standard station wagon with two high-resolution color and grayscale video cameras. Accurate ground truth is provided by a Velodyne laser scanner and a GPS localization system. Our datasets are captured by driving around the mid-size city of **Karlsruhe**, in rural areas and on highways. Up to 15 cars and 30 pedestrians are visible per image. Besides providing all data in raw format, we extract benchmarks for each task. For each of our benchmarks, we also provide an evaluation metric and this evaluation website. Preliminary experiments show that methods ranking high on established benchmarks such as **Middlebury** perform below average when being moved outside the laboratory to the real world. Our goal is to reduce this bias and complement existing benchmarks by providing real-world benchmarks with novel difficulties to the community.

360° Velodyne Laserscanner
Stereo Camera Rig
Monochrome Camera
GPS
Odometer



COCO
Common Objects in Context

Home People Dataset Tasks Evaluate

info@cocodataset.org

News

- We are pleased to announce the **LVIS 2021 Challenge and Workshop**.
- Please note that there will not be a COCO 2021 Challenge, instead, participate in the LVIS 2021 Challenge.
- We have partnered with the team behind the open-source tool **FiftyOne** to download, visualize, and evaluate COCO.
- FiftyOne** is an open-source tool facilitating visualization and access to datasets and serves as an evaluation tool for model analysis on COCO.

Visual Object Classes Challenge 2012 (VOC2012)

PASCAL2
Pattern Analysis, Statistical Modelling and Computational Learning



[click on an image to see the annotation]

Detecção de objetos - Datasets

kaggle  Hugging Face

Datasets

Tasks 1 Sizes Sub-tasks Languages Licenses Other

Filter Tasks by name

All datasets Computer Science Education Classification Computer Vision Multimodal

Feature Extraction Text-to-Image

972 Datasets

Car Object Detection

8,528 machine learning datasets

Share your dataset with the ML community!

242 dataset results for Object Detection

ImageNet
The ImageNet dataset contains 14,197,122 annotated images. Since 2010 the dataset is used in the ImageNet Large Scale Annotation. 11,800 PAPERS • 107 BENCHMARKS

COCO (Microsoft Common Objects in Context)
The MS COCO (Microsoft Common Objects in Context) dataset contains images, segmentation, key-point detection, and captioning data.

Datasets 237

- zzliang/GRIT
- visual_genome
- MCG-NJU/MultiSport
- mrtoy/mobile-ui-d
- foduocom/table-de

Segmentação

Segmentação de objetos - Introdução

Segmentação de objetos

- Classificação: Identifica um ou mais objetos na imagem, retornando uma label específica para cada região na imagem
- Detecção: Identifica a posição do objeto na imagem, retornando uma região de interesse definida pela caixa que delimita o objeto na imagem
- Segmentação: Identifica a área que um objeto ocupa na imagem, fracionando a região do objeto em segmentos com base em suas características visíveis.

Segmentação de objetos

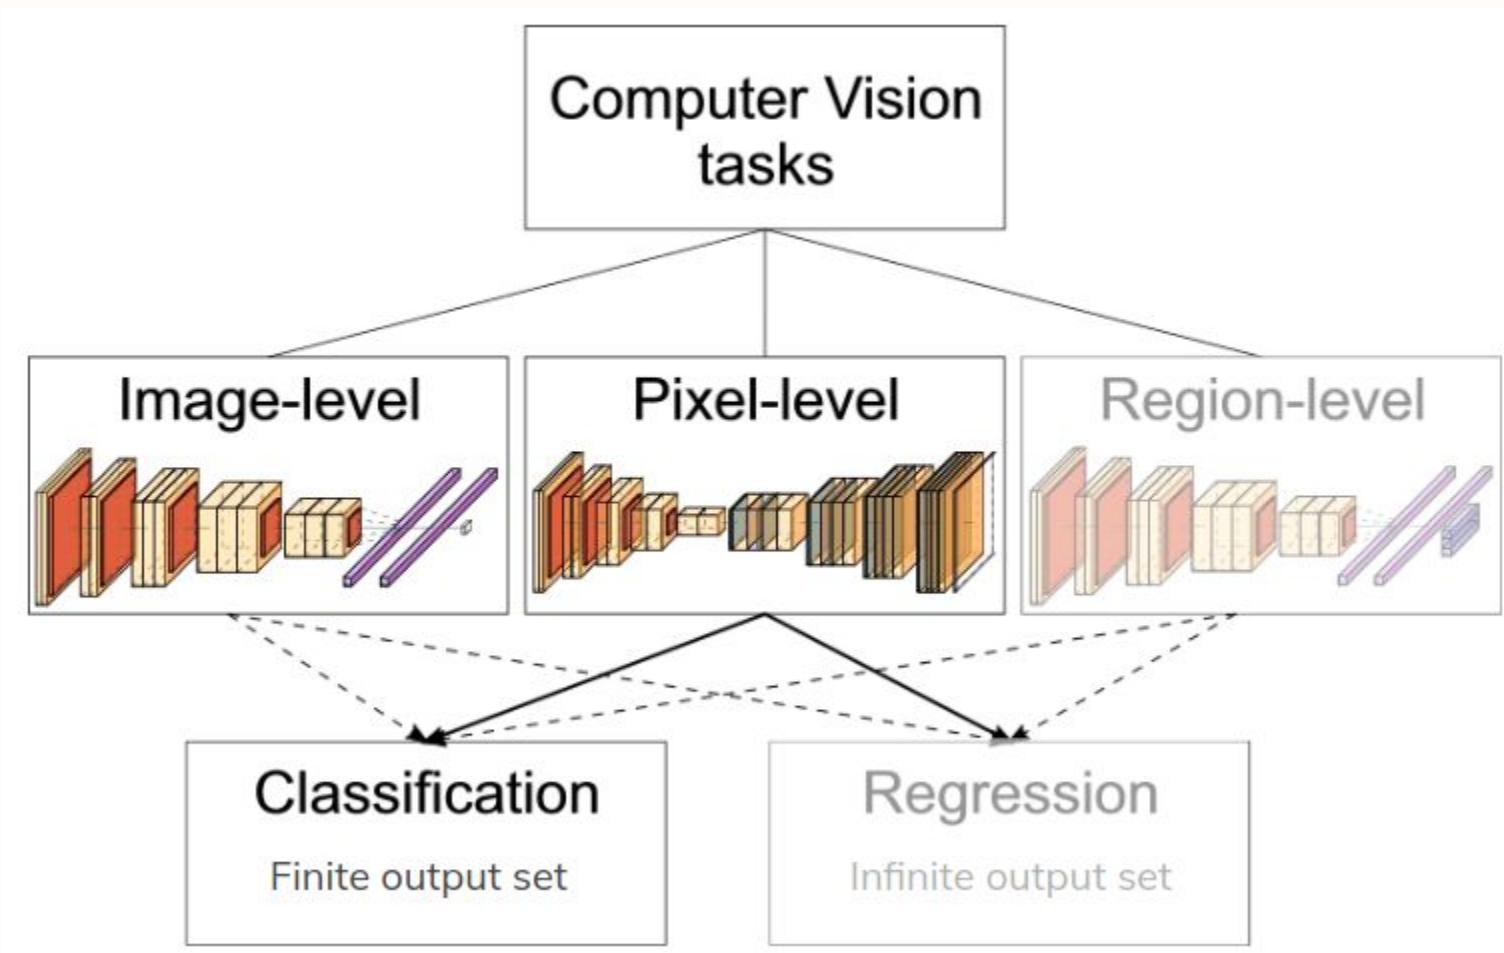
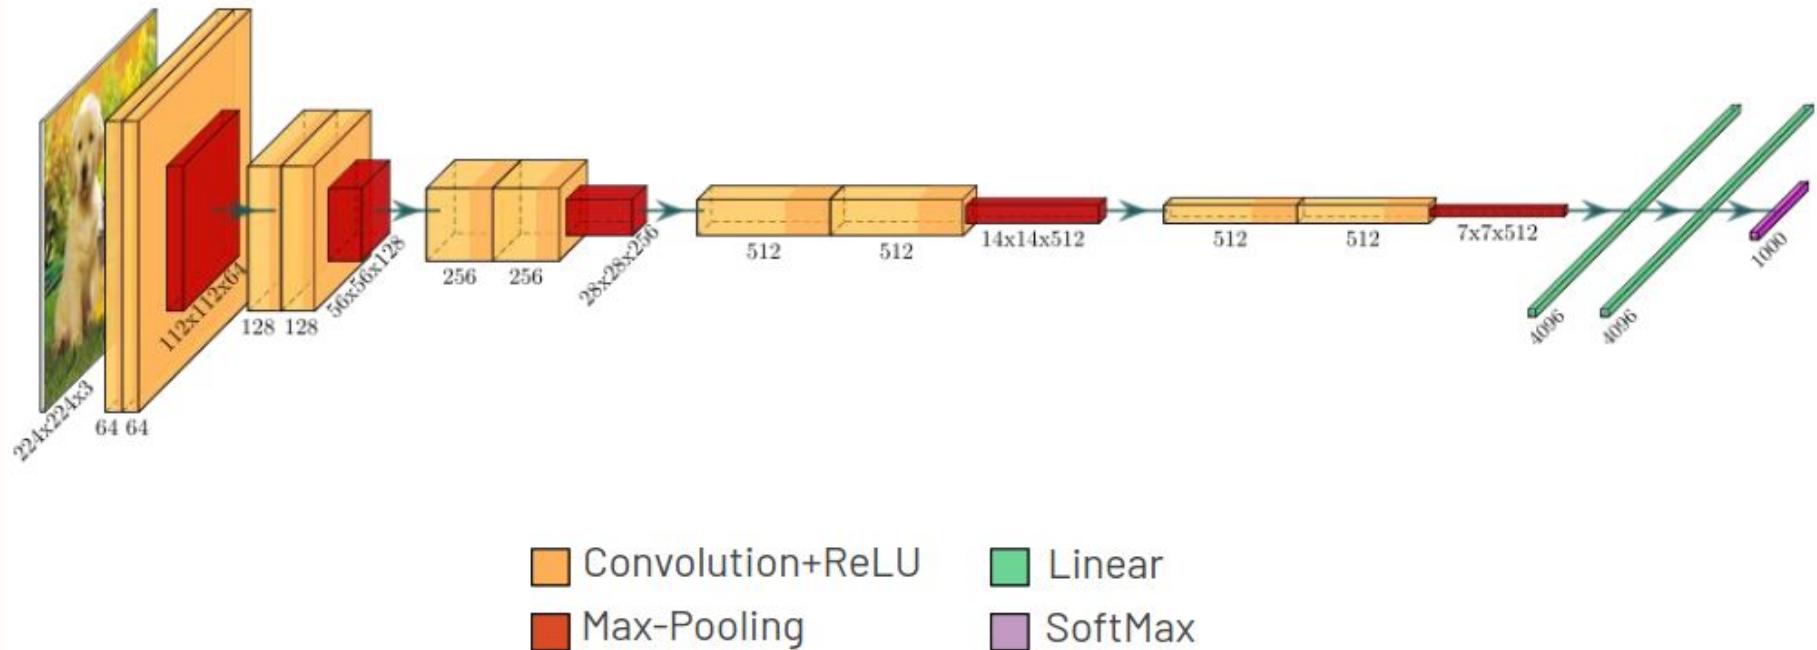


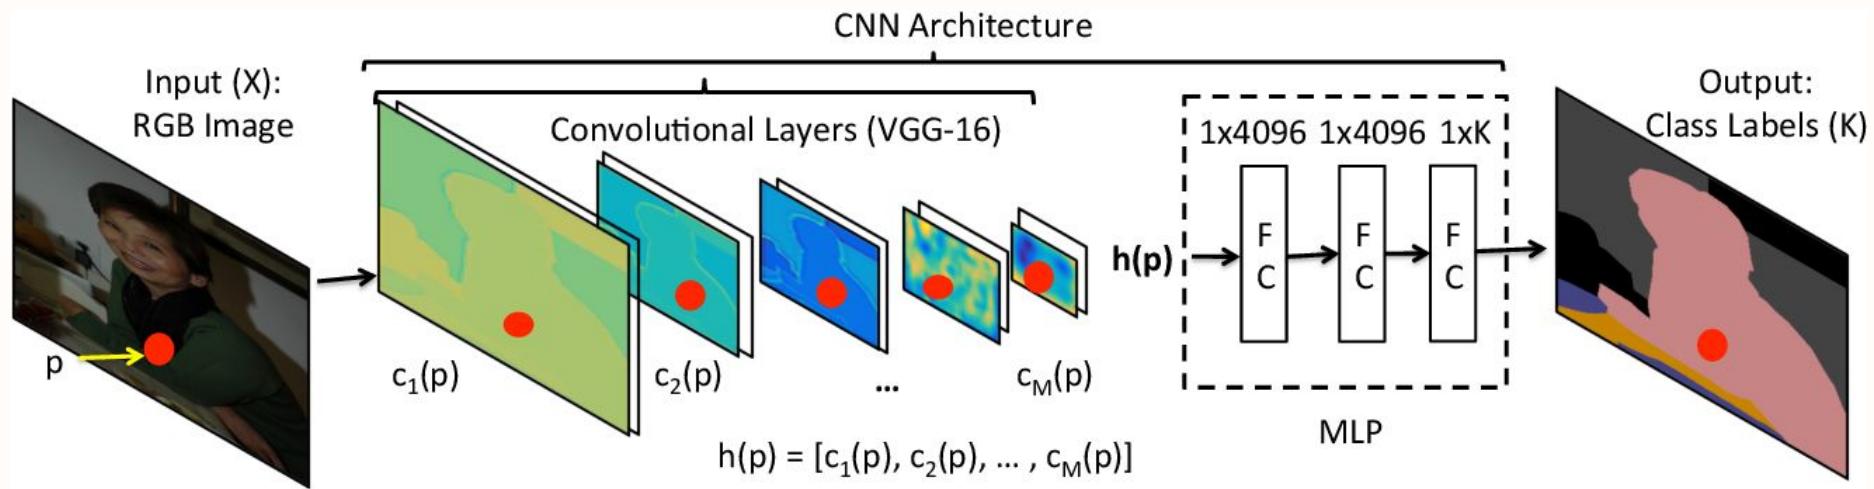
Image-level classification

→ AlexNet, VGG, ResNet



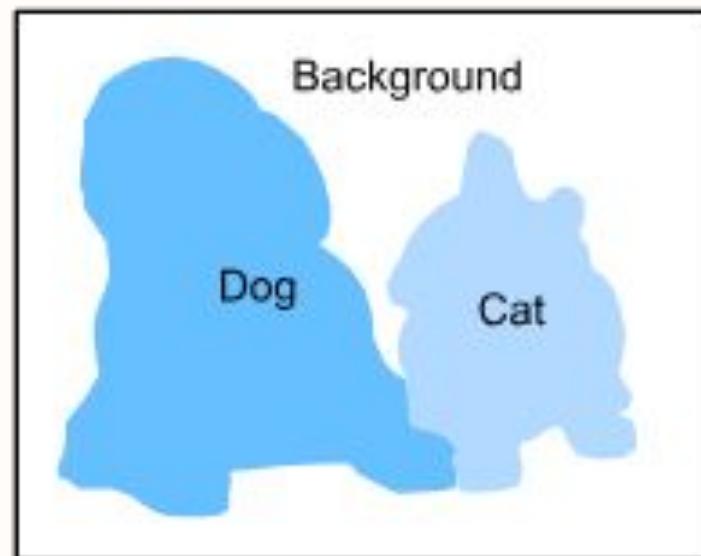
Pixel-level classification

- Entrada e saída tem mesma resolução espacial (largura e altura)

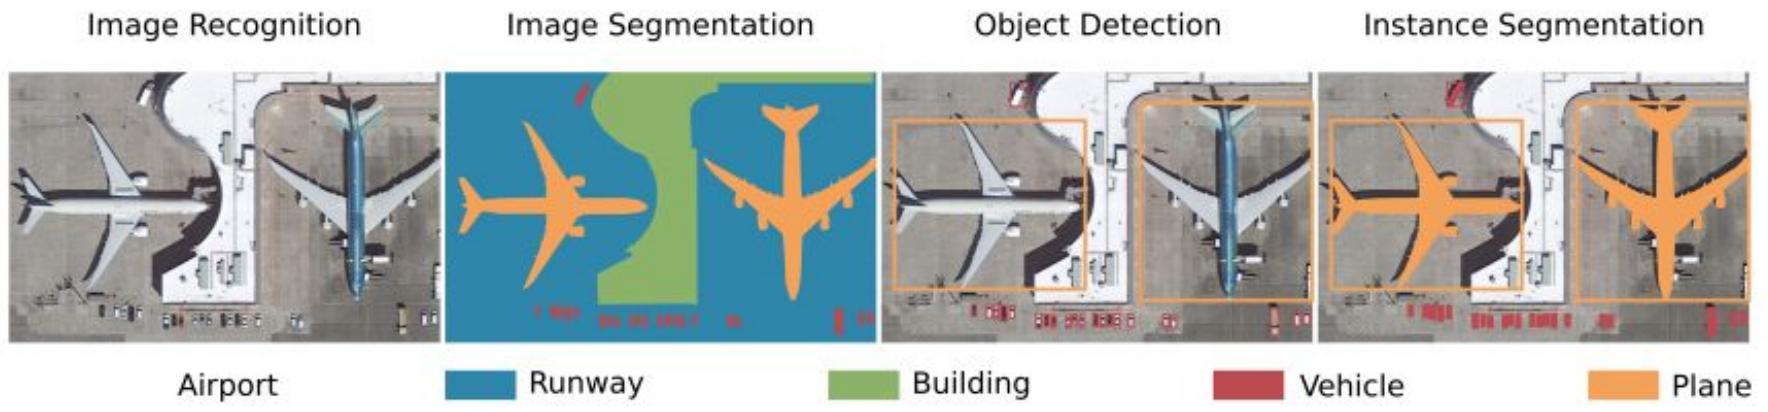


Pixel-level classification - Segmentação de objetos

- Consiste em dividir a imagem em regiões pertencentes a diferentes classes semânticas
- Diferentemente da detecção, a segmentação tem por objetivo identificar e classificar o que está presente na imagem a nível de pixel



Segmentação de objetos



Segmentação

- A segmentação pode se basear em informações de descontinuidade, gradiente ou regiões similares



Segmentação

- Em visão computacional existem duas tarefas correspondentes à segmentação: **segmentação semântica** e **segmentação de instância**

Segmentação

- Em visão computacional existem duas tarefas correspondentes à segmentação: **segmentação semântica** e **segmentação de instância**
 - ◆ **Segmentação semântica:** refere-se ao processo de encontrar e rotular determinados objetos na imagem, de tal forma a destacar cada pixel correspondente ao objeto

Segmentação

- Em visão computacional existem duas tarefas correspondentes à segmentação: **segmentação semântica** e **segmentação de instância**
 - ◆ **Segmentação semântica**: refere-se ao processo de encontrar e rotular determinados objetos na imagem, de tal forma a destacar cada pixel correspondente ao objeto
 - ◆ **Segmentação de instância**: os objetos detectados de uma mesma classe não são agrupados, mas sim são destacados como instâncias separadas

Segmentação - Semântica vs Instâncias

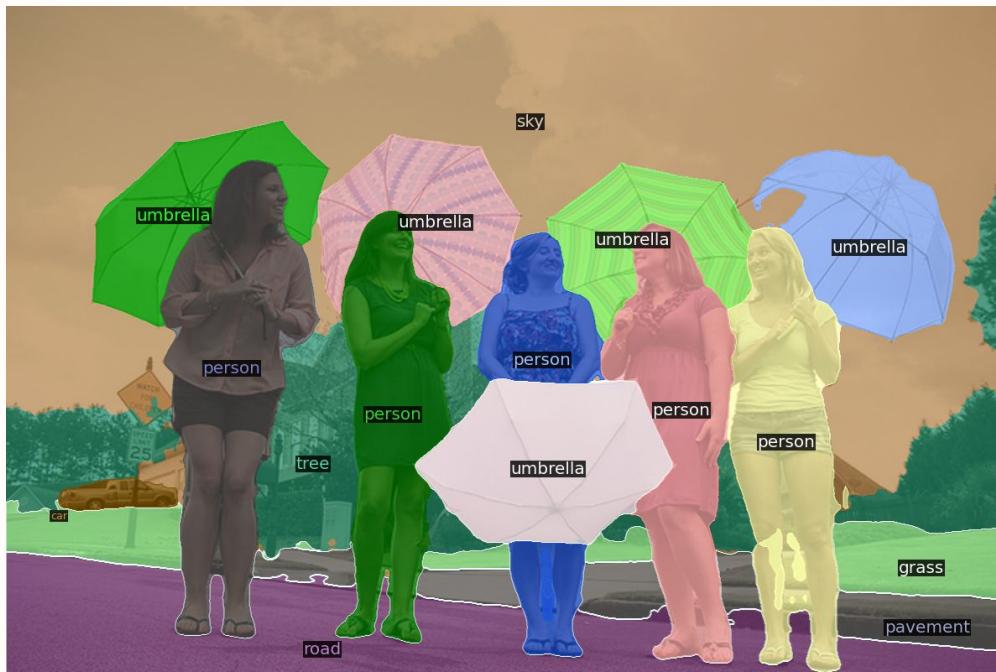
Grupos são identificados e segmentados (e.g., Pessoas, Carros, Pista)



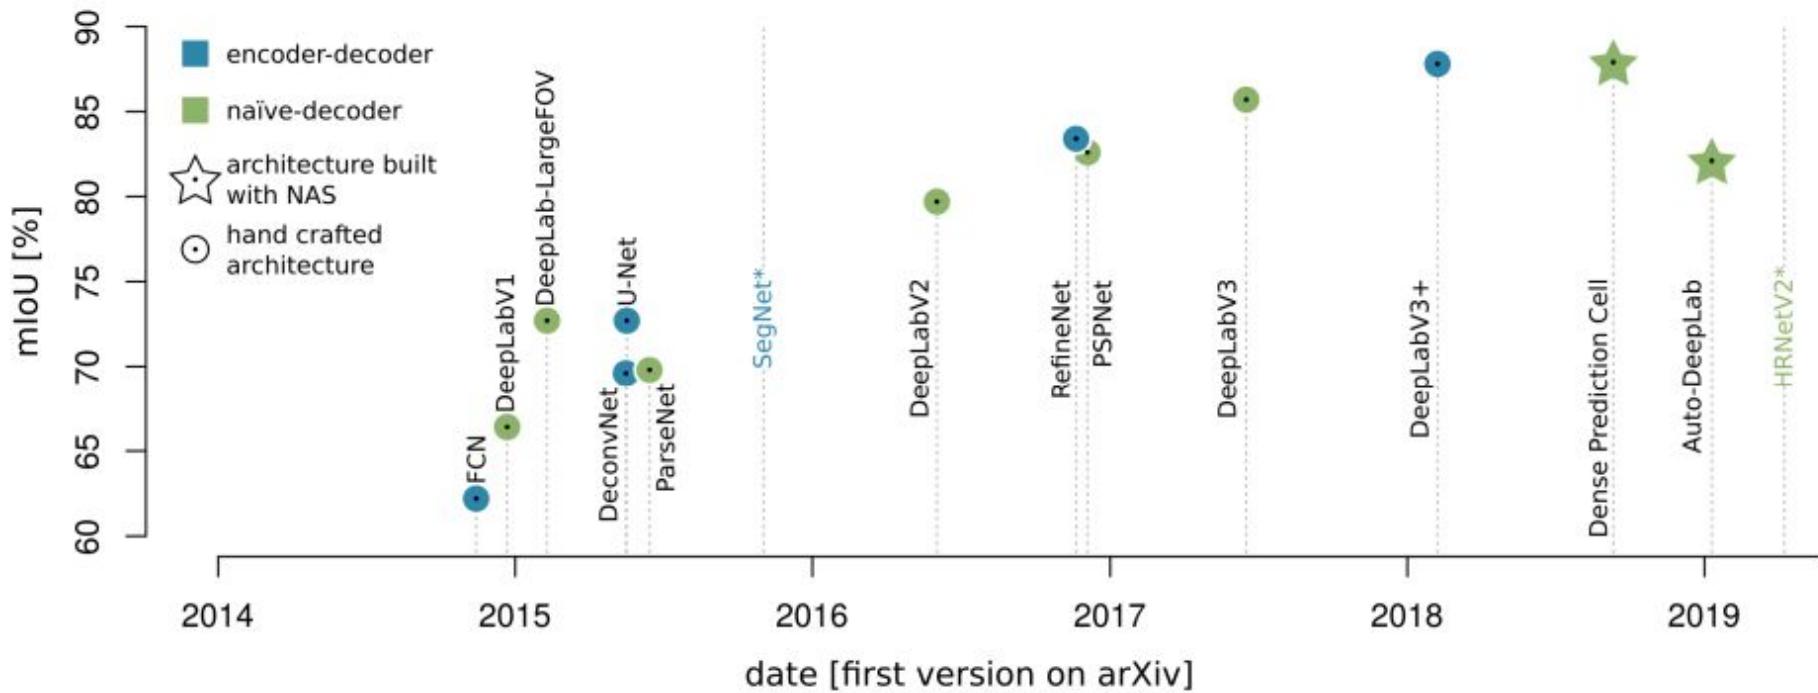
Objetos são identificados de forma única, sem agrupamento de classes (e.g., pessoa 1, pessoa 2, pessoa 3, etc)

Segmentação Panóptica

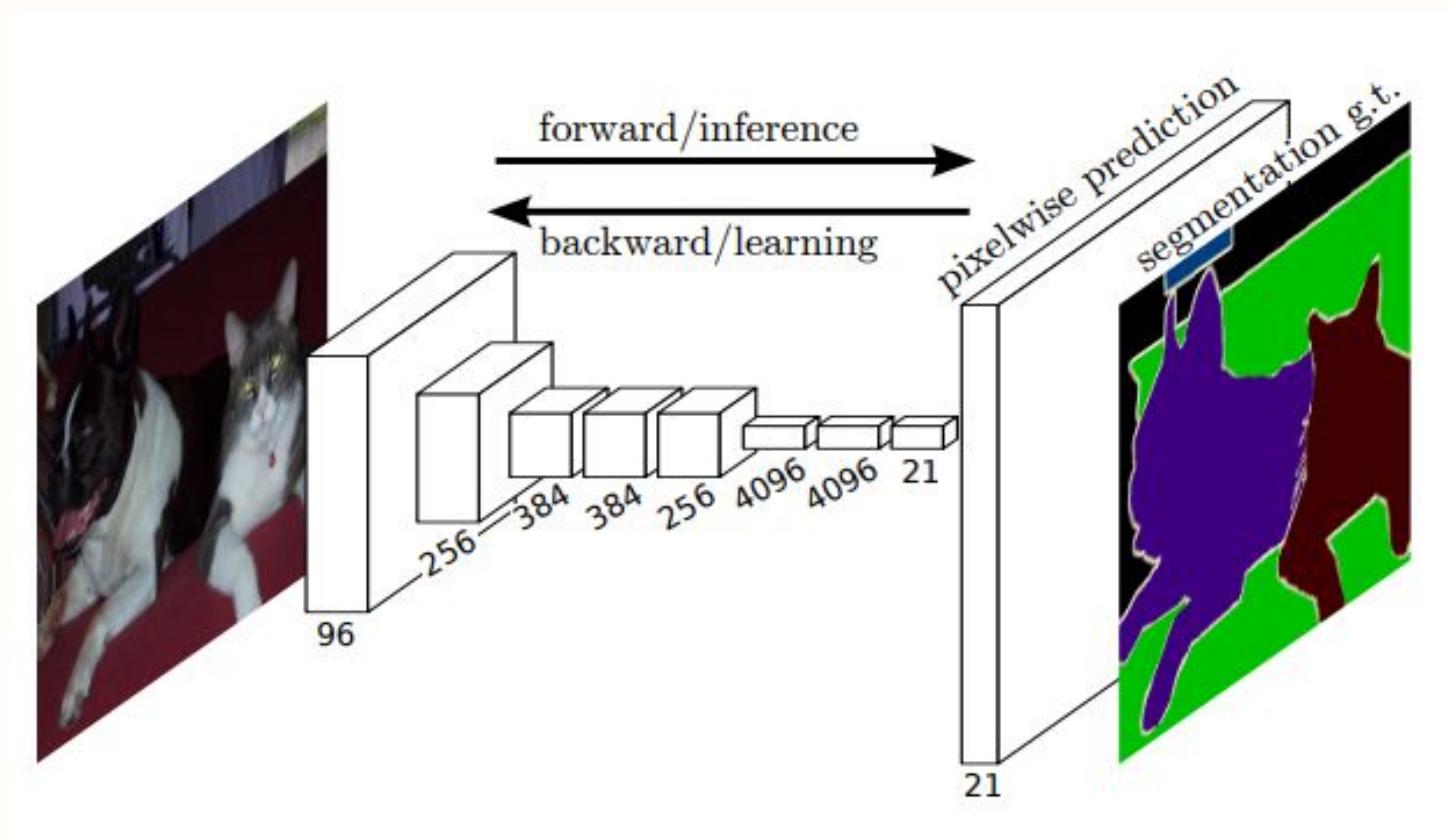
- Essencialmente corresponde à **junção da segmentação semântica e de instância**, já que segmenta e rotula simultaneamente a instância de um objeto na imagem, de tal forma a distinguir instâncias de um mesmo objeto, ao passo que atribui o mesmo rótulo da classe semântica correspondente



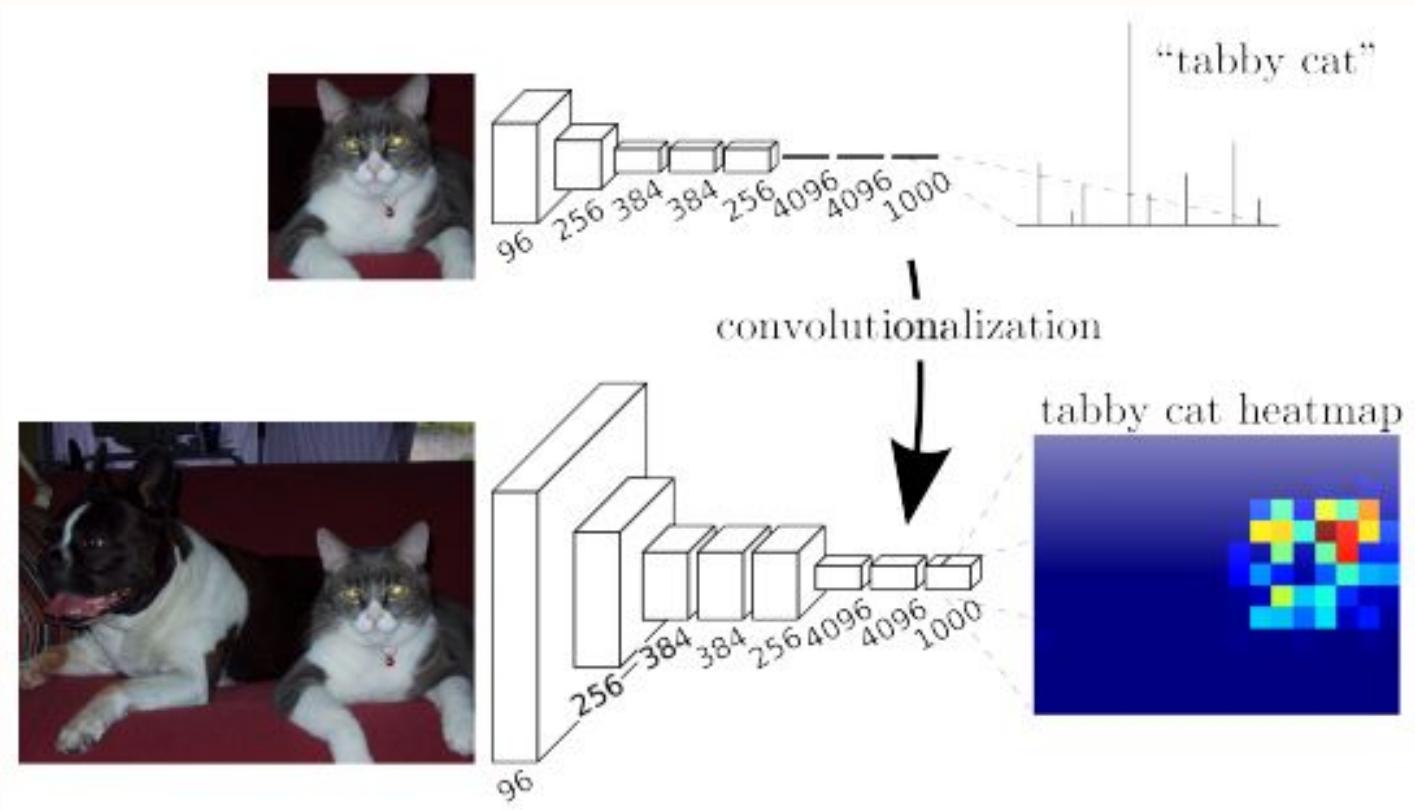
Evolução da Segmentação de objetos com Deep Learning



Segmentação e Deep Learning - Fully Convolutional Networks

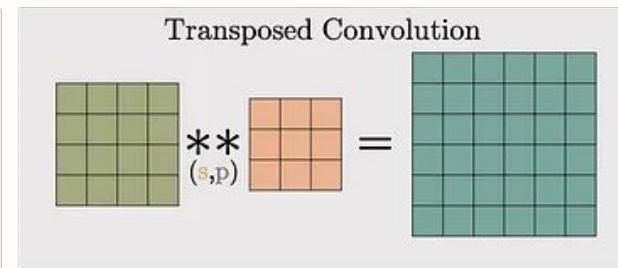
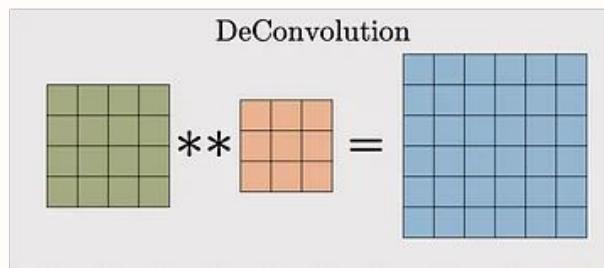
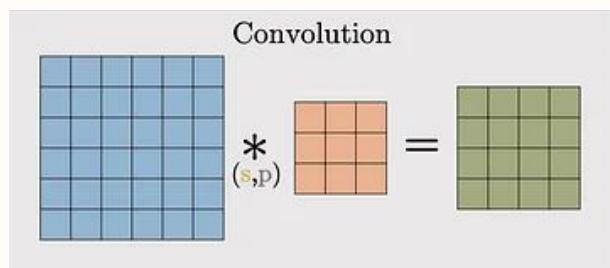


Fully Convolutional Networks - FC, upsampling e correspondências espaciais



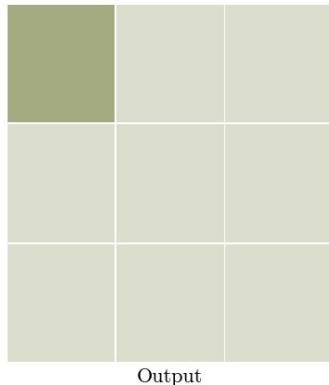
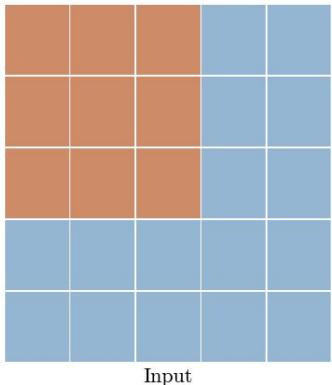
Transformando camadas fully connected em camadas convolucionais possibilita a classificação dos mapas de ativação espacial.

Fully Convolutional Networks - FC, upsampling e correspondências espaciais

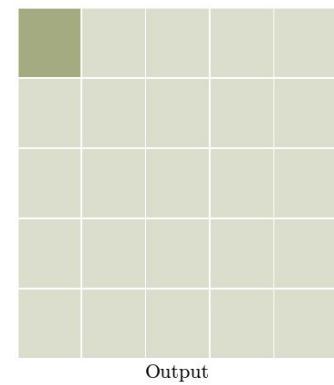
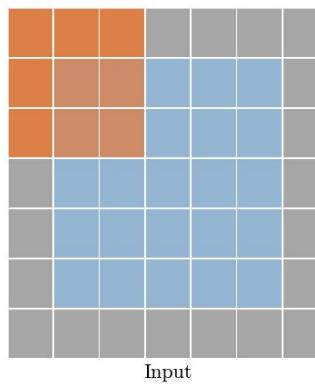


Fully Convolutional Networks - FC, upsampling e correspondências espaciais

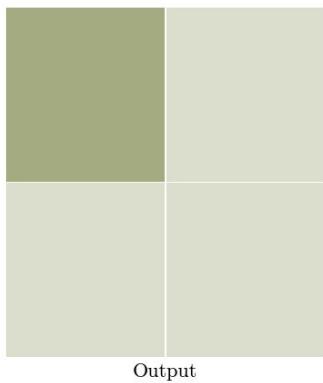
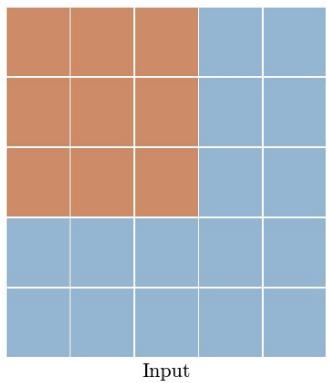
Type: conv - Stride: 1 Padding: 0



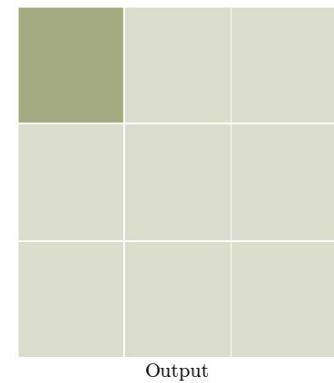
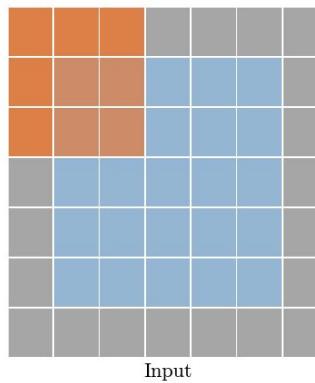
Type: conv - Stride: 1 Padding: 1



Type: conv - Stride: 2 Padding: 0



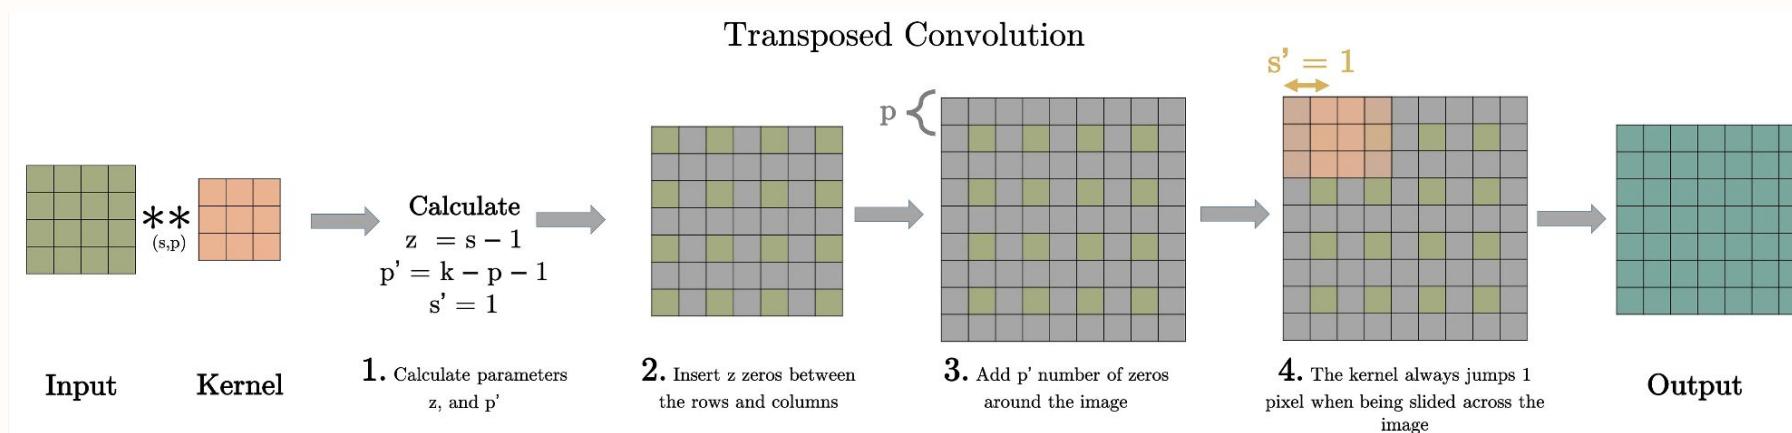
Type: conv - Stride: 2 Padding: 1



$$o = \frac{i + 2p - k}{s} + 1$$

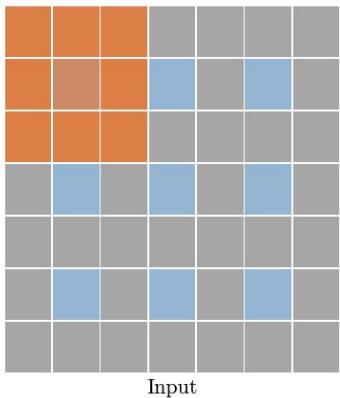
Fully Convolutional Networks - FC, upsampling e correspondências espaciais

1. Calcular parâmetros z' e p'
2. Adicionar entre cada linha e coluna z números 0s.
3. Realizar o pad com p' números 0s.
4. Executar a convolução com o resultado e stride 1

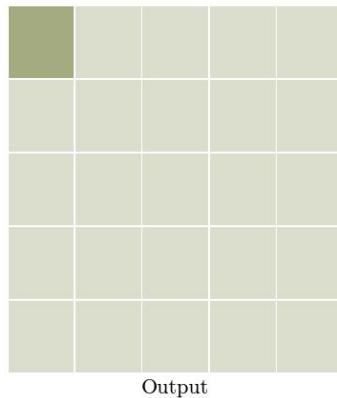


Fully Convolutional Networks - FC, upsampling e correspondências espaciais

Type: transposed'conv - Stride: 2 Padding: 1

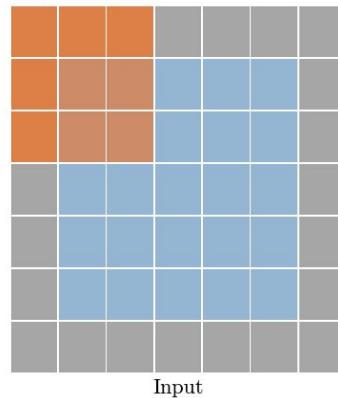


Input

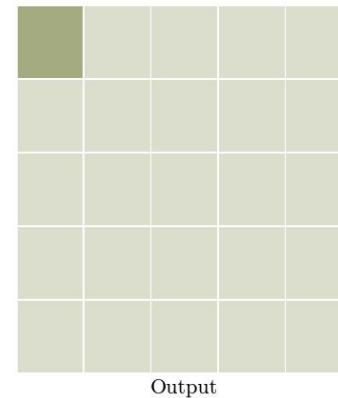


Output

Type: transposed'conv - Stride: 1 Padding: 1

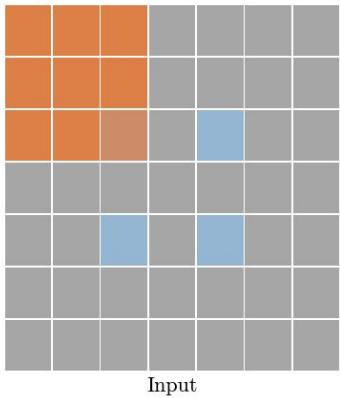


Input

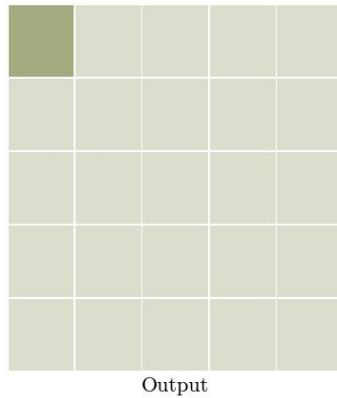


Output

Type: transposed'conv - Stride: 2 Padding: 0

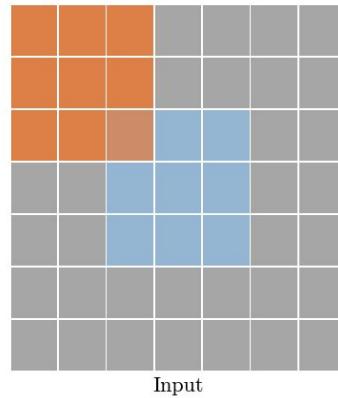


Input

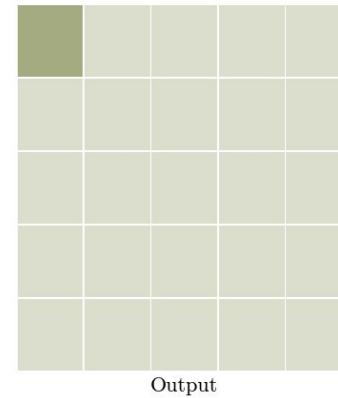


Output

Type: transposed'conv - Stride: 1 Padding: 0

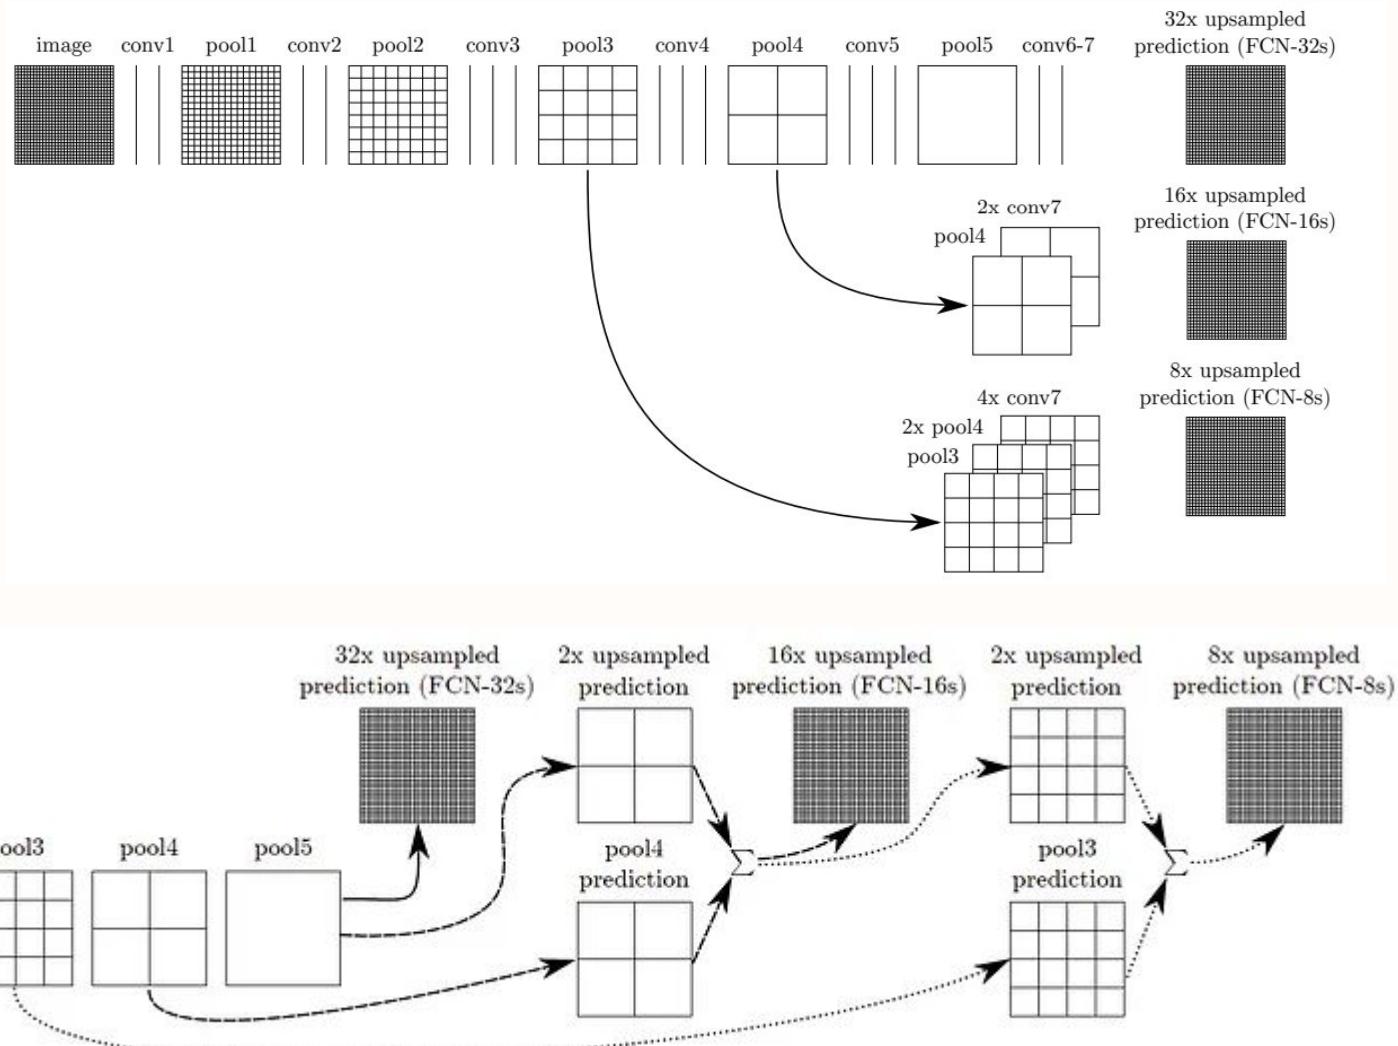


Input

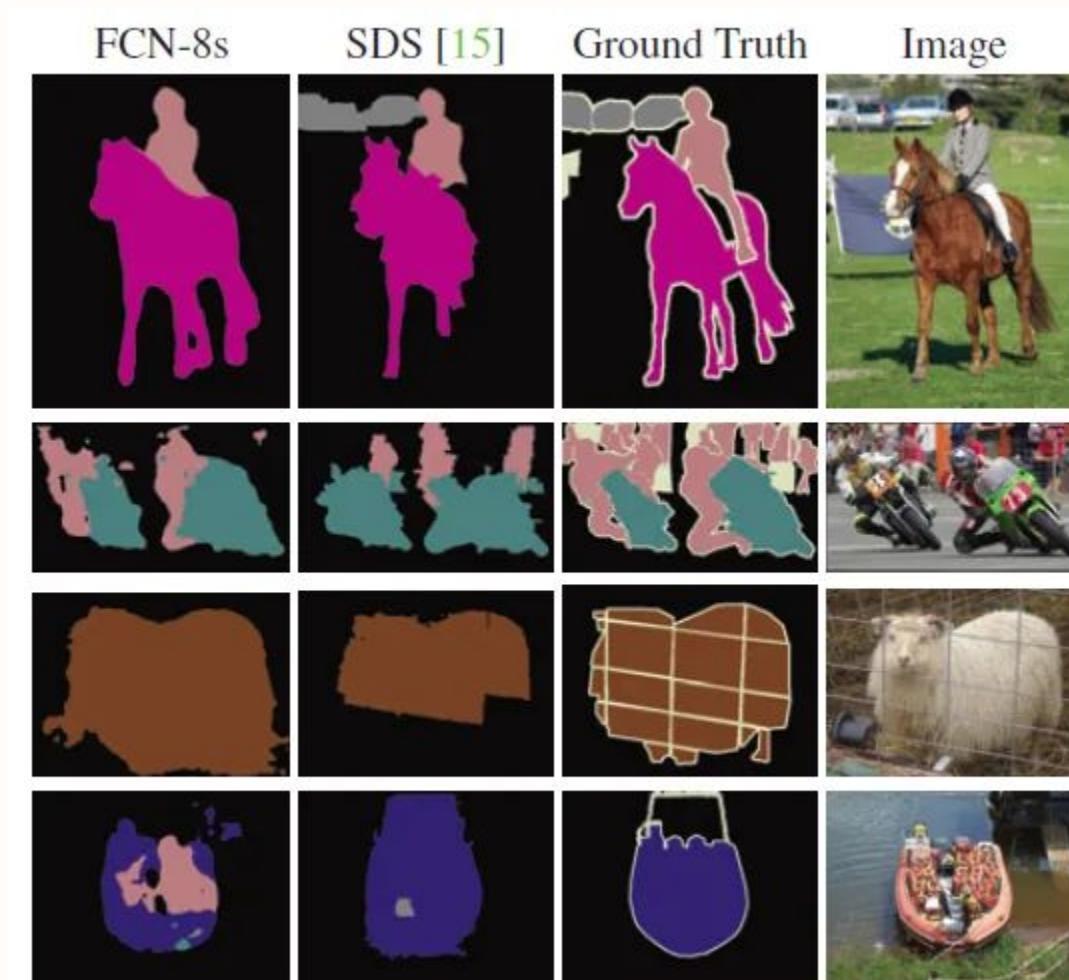


Output

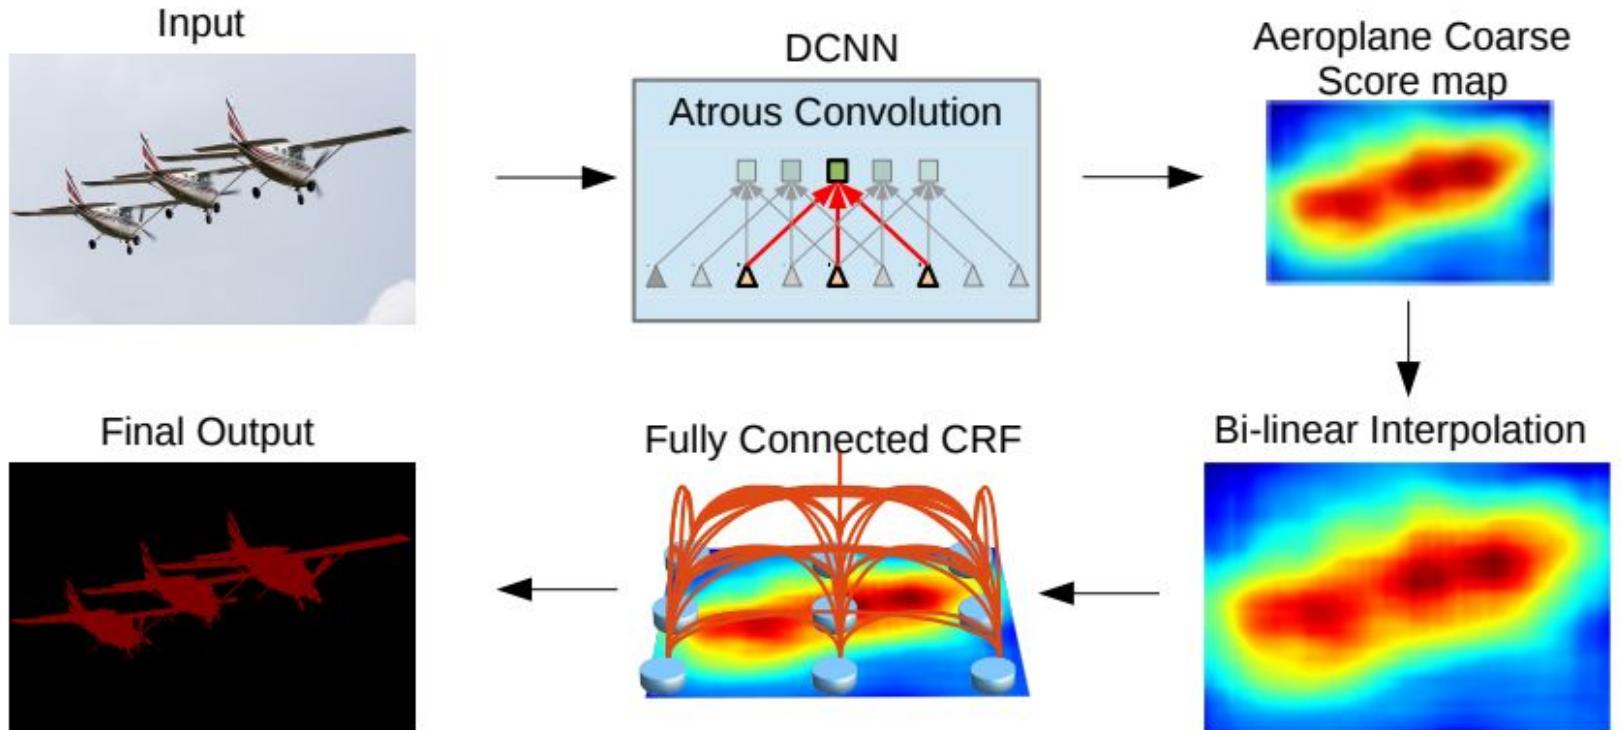
Fully Convolutional Networks - Fusão de camadas



Fully Convolutional Networks



Segmentação e Deep Learning - DeepLab



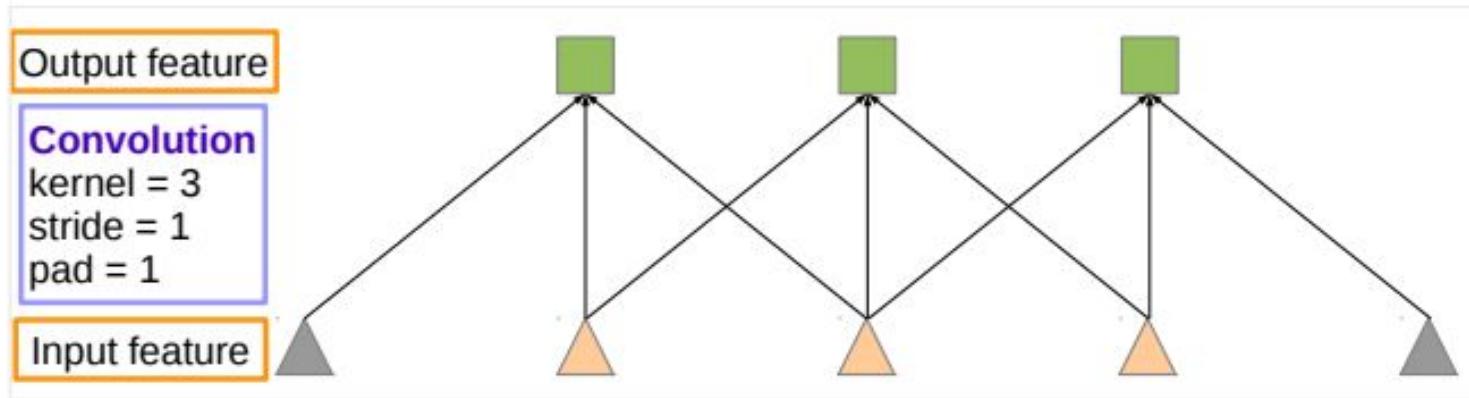
DeepLab - Atrous Convolution

- Convolução Atrous: Inspirado no termo francês “à trous”, que significa buraco, alguns trabalhos se referem ao algoritmo como “dilated convolution”.
 - ◆ É aplicado normalmente com a transformada de wavelet.

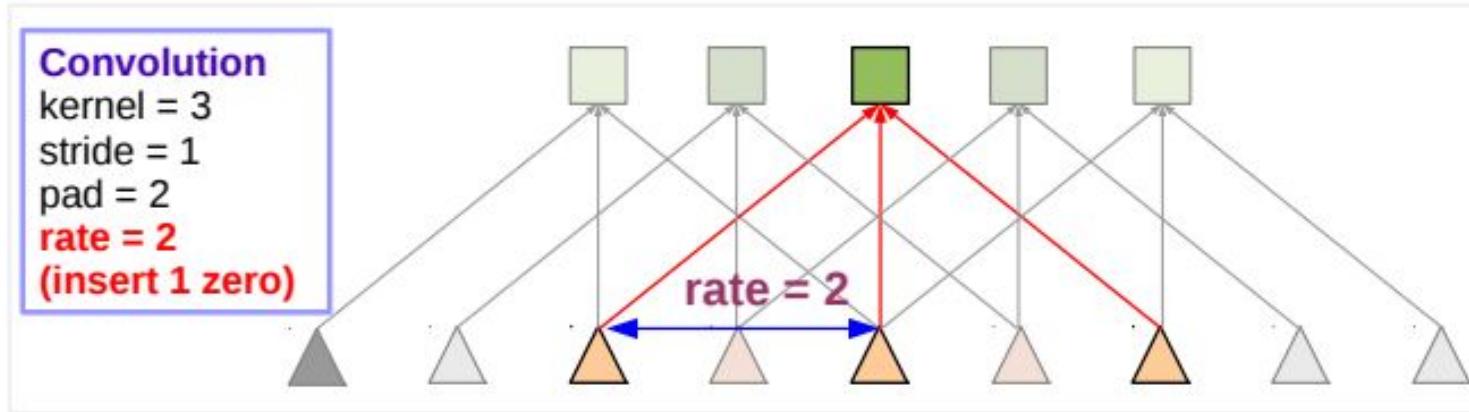
$$y_i = \sum_{k=1}^K x[i + r \cdot k]w[k]$$

- Se $r=1$, temos a convolução padrão.
- Quando $r>1$, obtemos a convolução atrous, aumentando o stride dos exemplos de entradas

DeepLab - Atrous Convolution

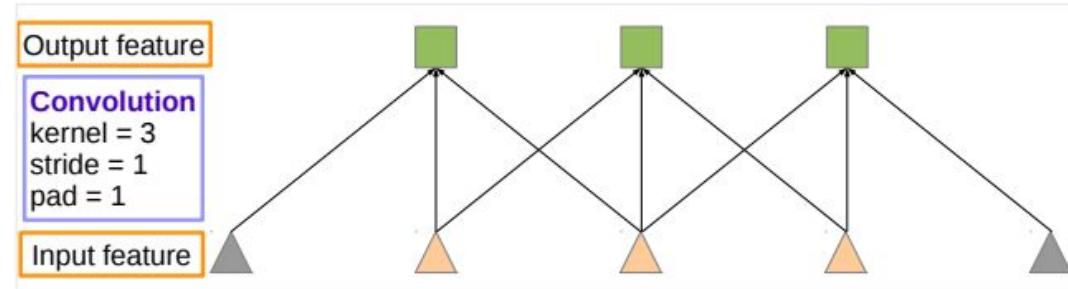


(a) Sparse feature extraction

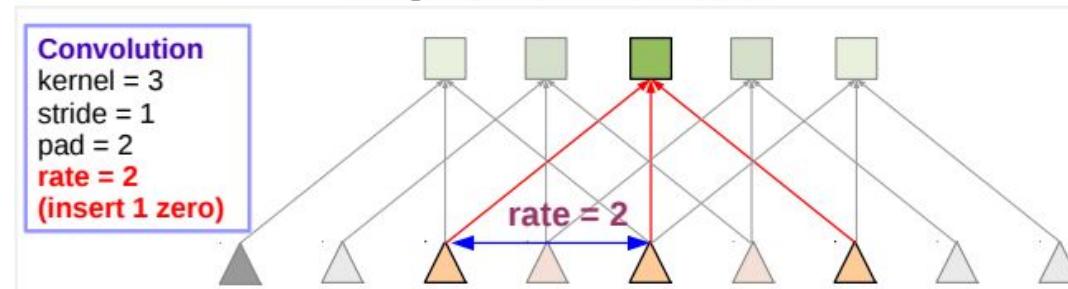


(b) Dense feature extraction

DeepLab - Atrous Convolution



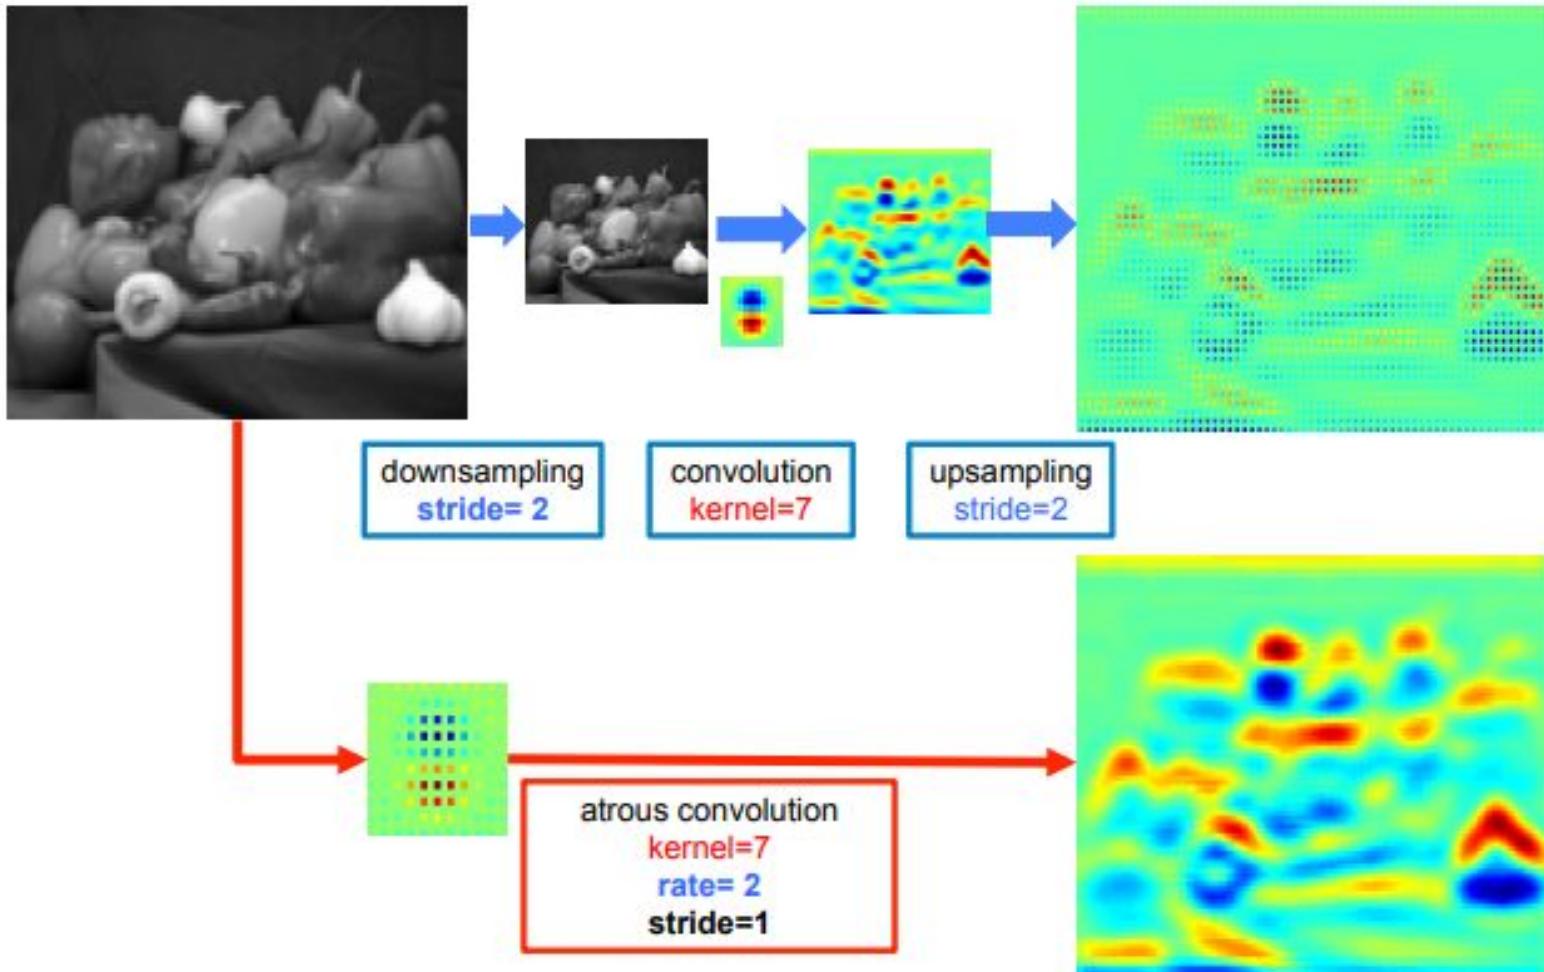
(a) Sparse feature extraction



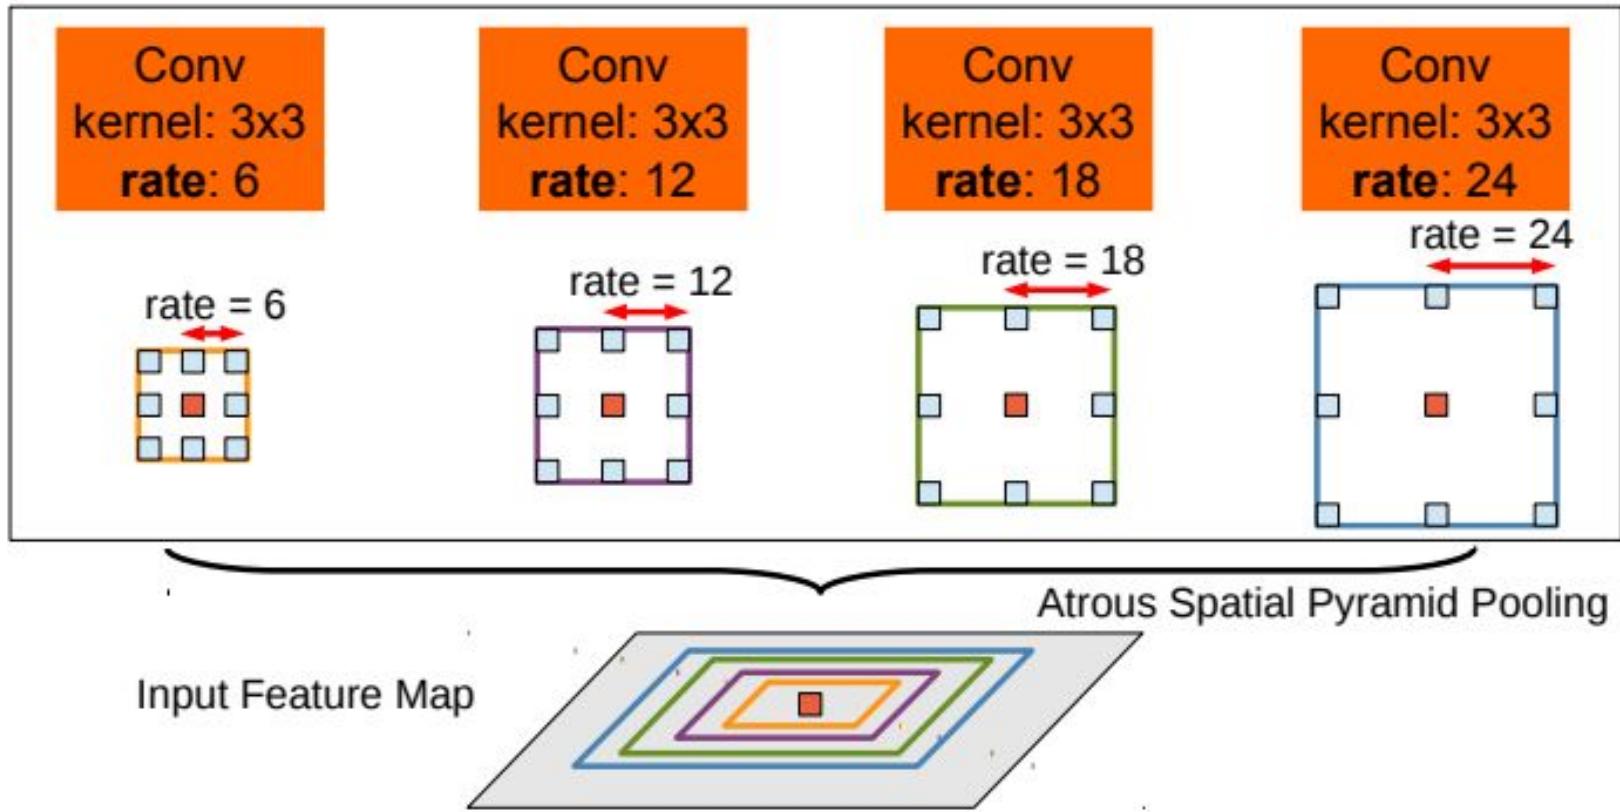
(b) Dense feature extraction

- Acima temos a convolução padrão
- Na figura abaixo, temos um exemplo da convolução atrous com $r=2$

DeepLab - Atrous Convolution

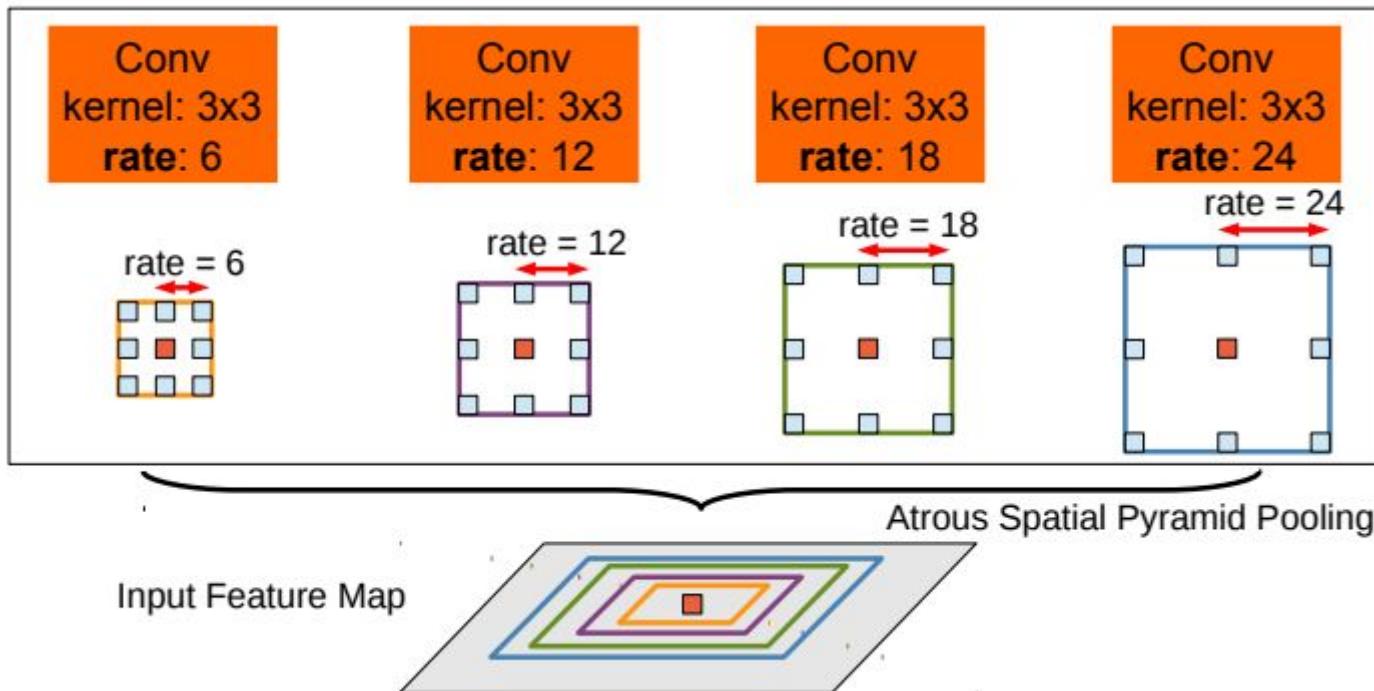


DeepLab - Atrous Spatial Pyramid Pooling (ASPP)



DeepLab - Atrous Spatial Pyramid Pooling (ASPP)

- Aplicação do algoritmo atrous com SPP (Spatial Pyramid Pooling)
 - ◆ Melhora a acurácia para segmentação de objetos com diferentes escalas



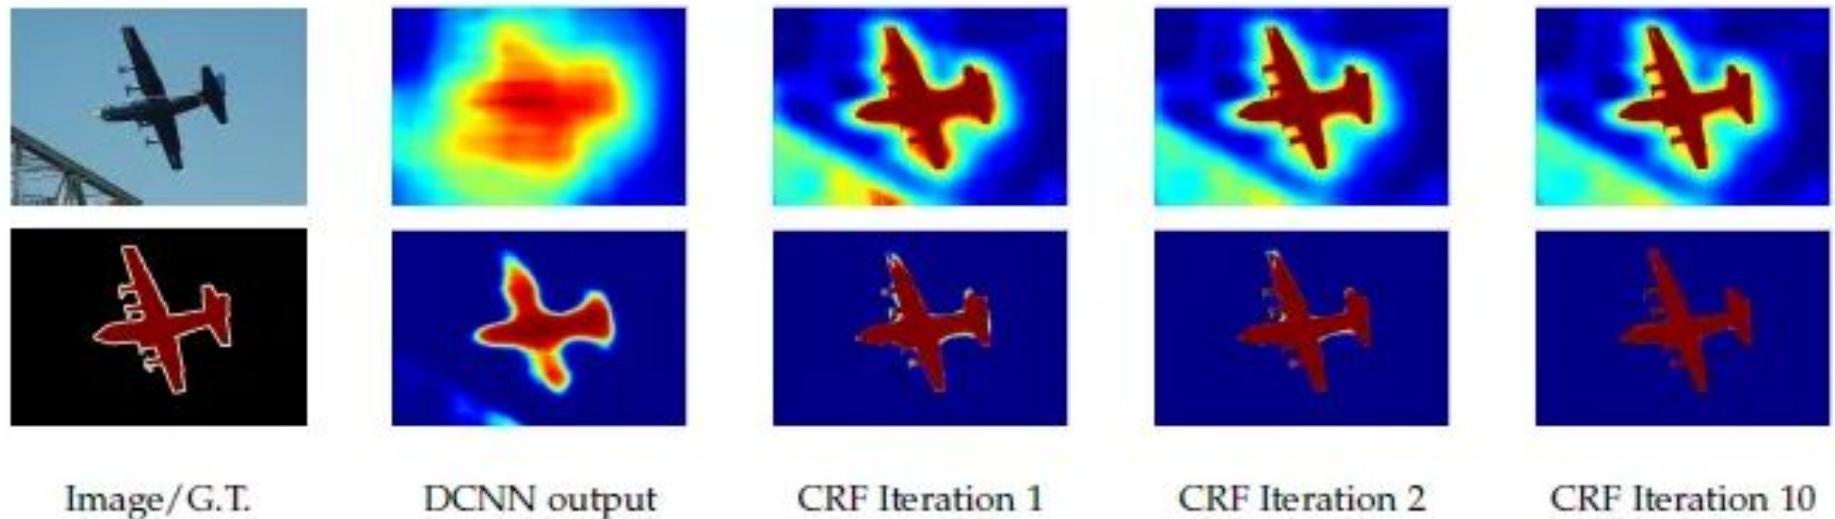
DeepLab - Fully Connected CRF (Conditional Random Field)

- FC-CRF é aplicado após a interpolação bilinear
- x é o label correspondente ao pixel e $P(x)$ é a probabilidade associada ao pixel.
- θ_{ij} funciona como um filtro
 - ◆ $\mu = 1$ se x_j é diferente de x_i e $\mu = 0$ quando $x_i = x_j$
 - ◆ Entre colchetes o primeiro termo é similar a um filtro bilateral (preserva características das arestas)
 - ◆ O segundo termo depende apenas da posição dos pixels, e funciona como um filtro gaussiano

$$E(x) = \sum_i \theta_i(x_i) + \sum_{ij} \theta_{ij}(x_i, x_j)$$
$$\theta_i = -\log P(x_i)$$

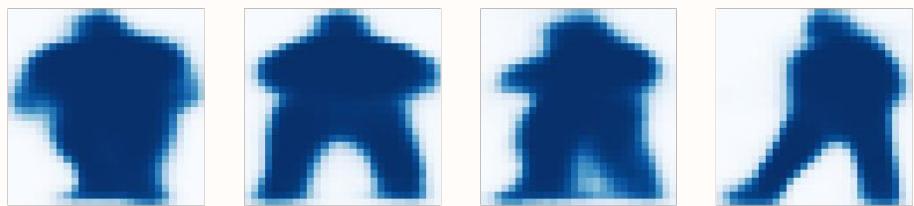
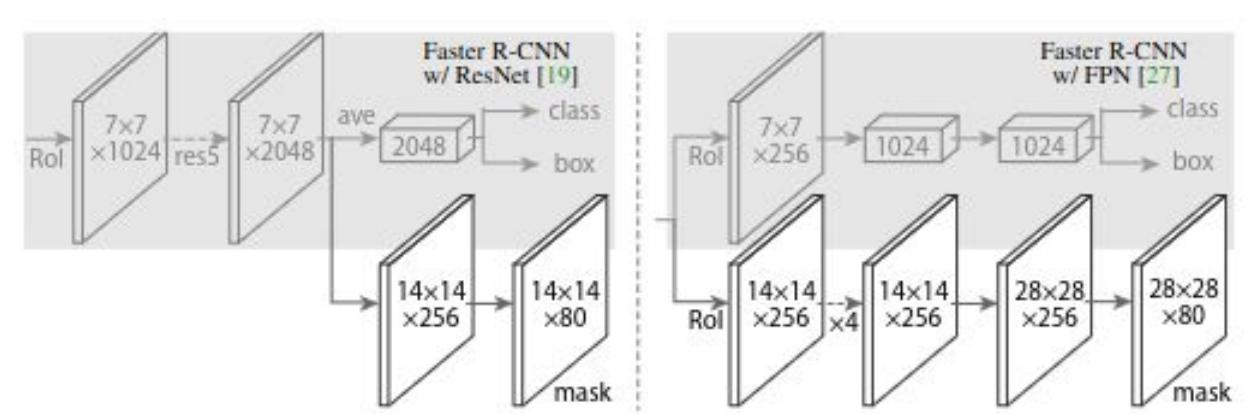
$$\theta_{ij}(x_i, x_j) = \mu(x_i, x_j) \left[w_1 \exp \left(-\frac{\|p_i - p_j\|^2}{2\delta_\alpha^2} - \frac{\|I_i - I_j\|^2}{2\delta_\beta^2} \right) + w_2 \exp \left(-\frac{\|p_i - p_j\|^2}{2\delta_\gamma^2} \right) \right]$$

DeepLab - Fully Connected CRF (Conditional Random Field)



Top: Score map (input before softmax function), Bottom: belief map (output of softmax function)

Mask-RCNN



He, Kaiming, et al. "Mask r-cnn." *Proceedings of the IEEE international conference on computer vision*. 2017.

https://github.com/matterport/Mask_RCNN

Segmentação e Deep Learning - UNet

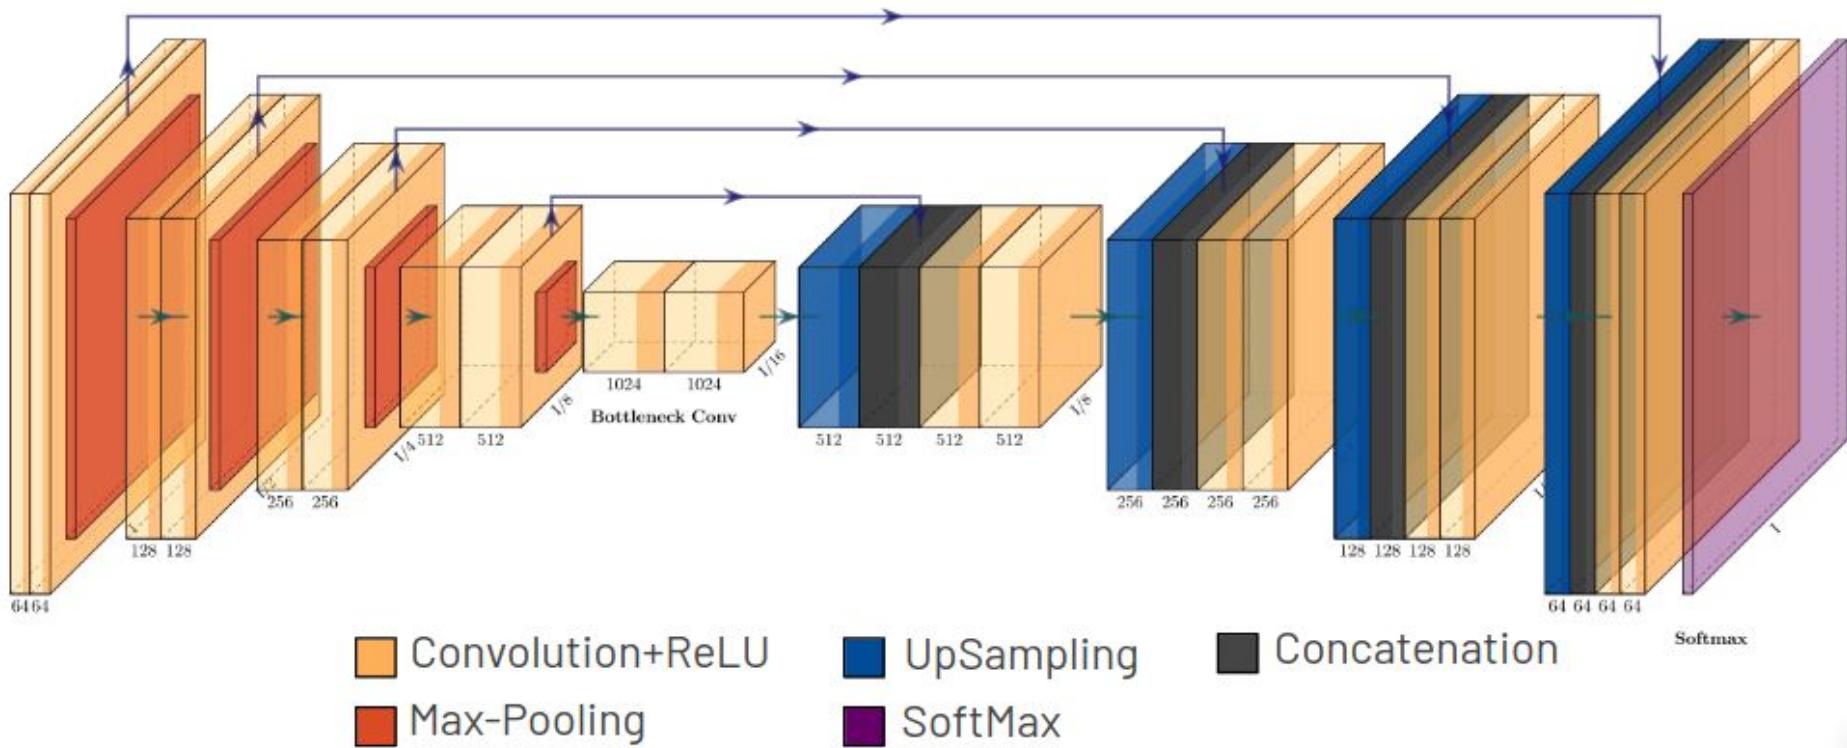
- U-Net apresenta uma arquitetura de rede **mais estruturada**
- Arquitetura baseada na ideia de Encoder-Decoder
 - ◆ Não utiliza camadas FC
 - ◆ Adiciona skip-connections por **concatenação**
- Treinamento se beneficia com operações de augmentation

U-Net - Arquitetura Encoder-Decoder

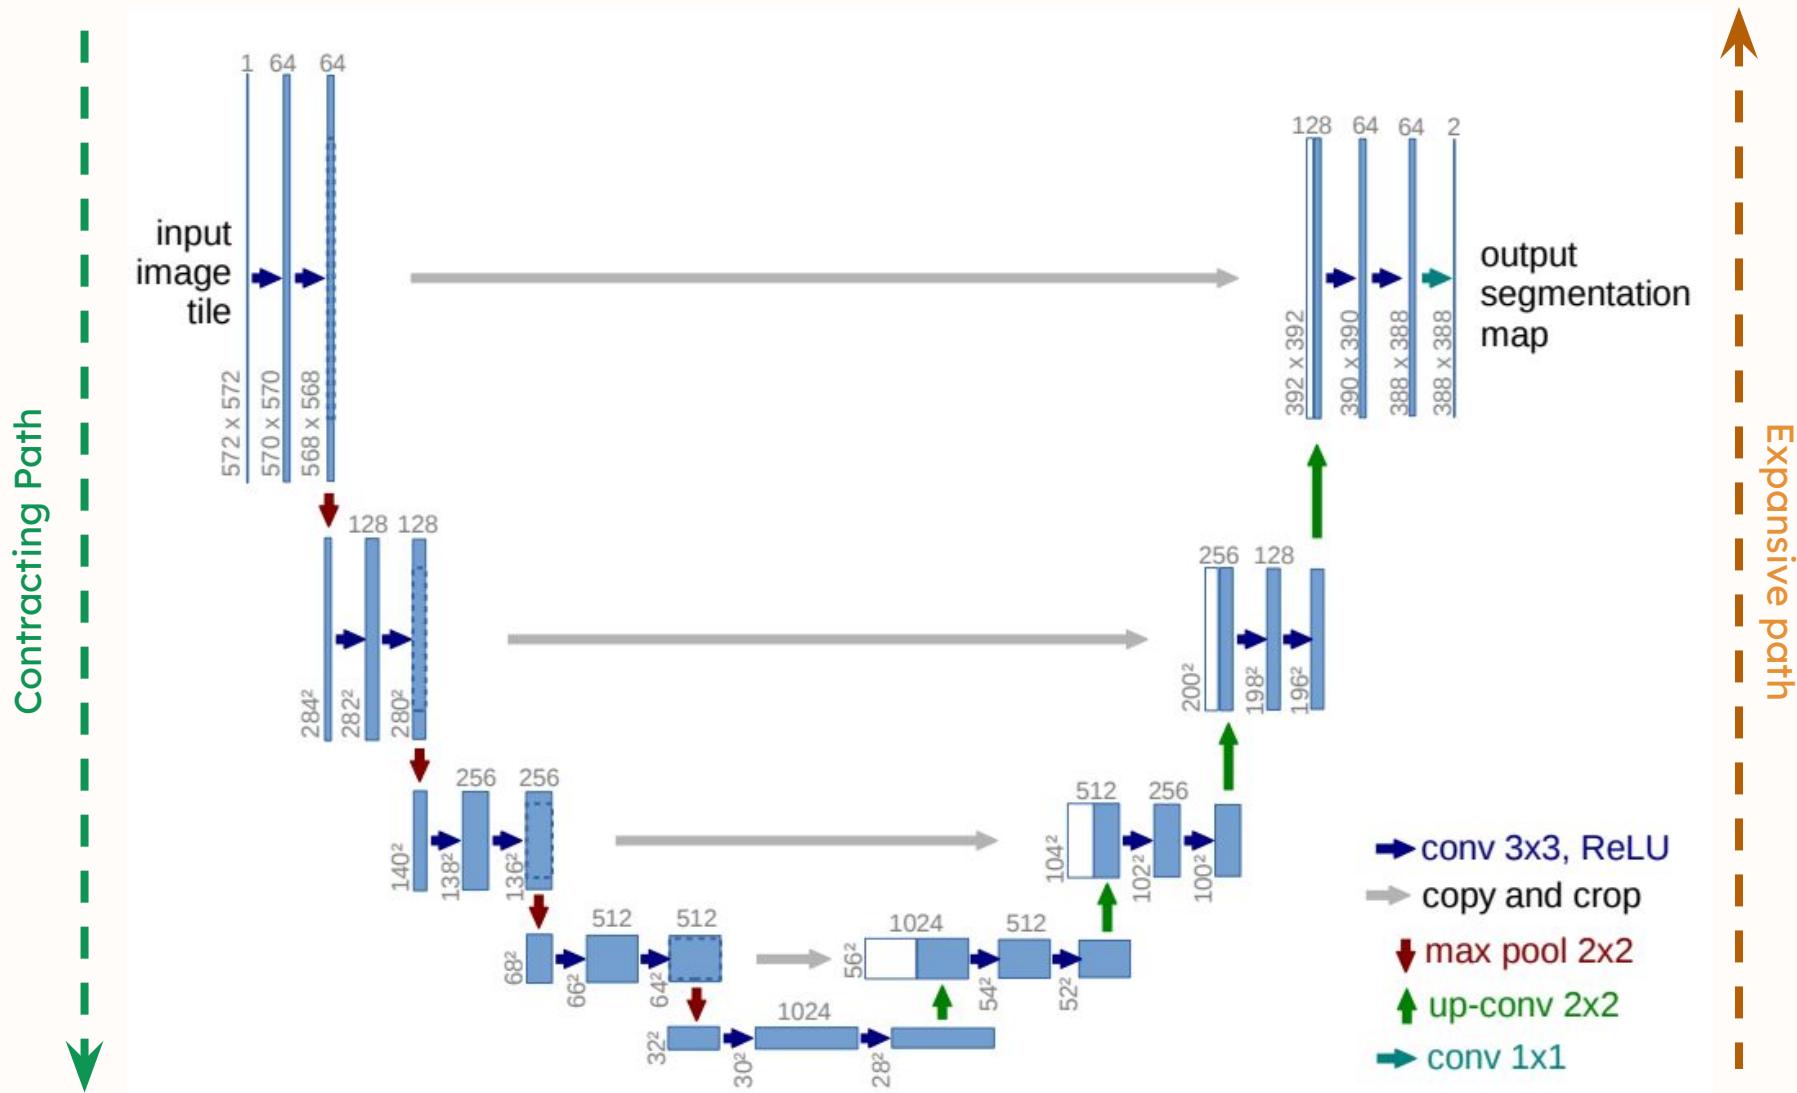
- Arquitetura utilizada em problemas onde devemos alinhar uma entrada de tamanho variável em um saída específica
 - ◆ Encoder: Recebe uma entrada e aplica uma série de transformações, mapeando o sinal recebido para um novo espaço de características através uma representação intermediária
 - ◆ Decoder: Recebe a representação gerada e analisa as características, mapeando-as para o espaço desejado



U-Net - Arquitetura Encoder-Decoder

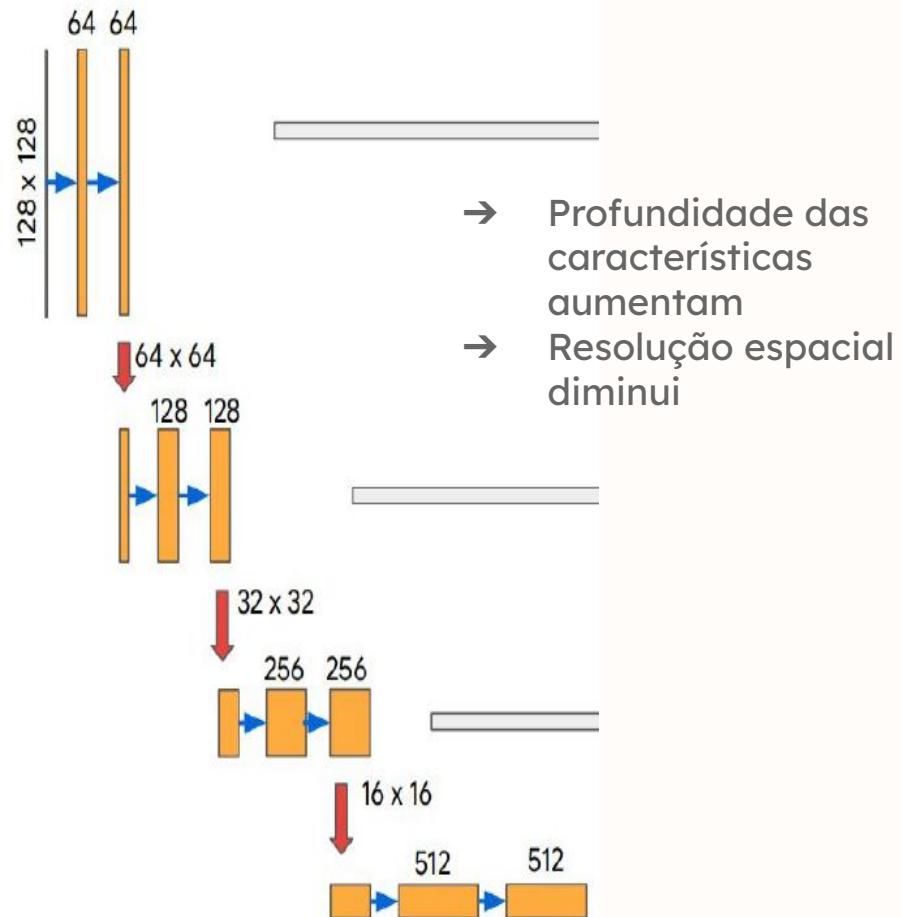


UNet - Arquitetura



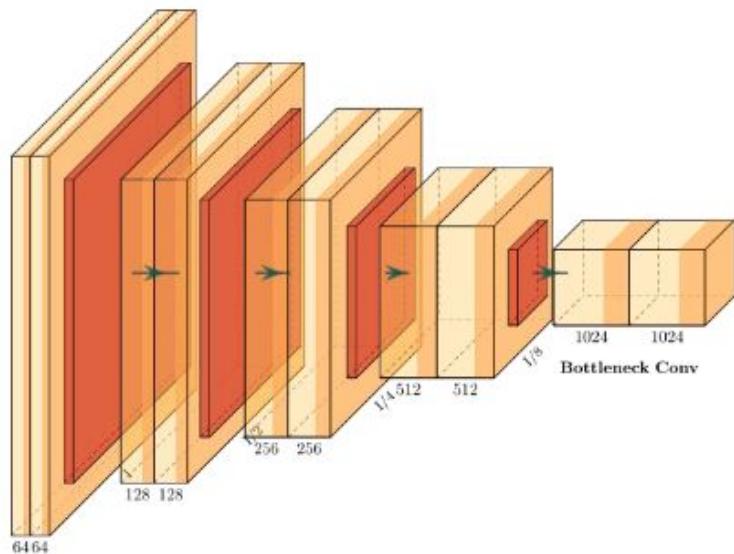
UNet Arquitetura - Contração (Encoder)

- Caminho de contração:
Arquitetura convolucional padrão, são aplicadas repetidas camadas convolucionais 3×3 (sem pad) seguidas de ativação ReLU e max pooling 2×2
 - ◆ Cada downsample do max pooling dobra o número de features (profundidade das ativações)



UNet Arquitetura - Contração (Encoder)

Encoder

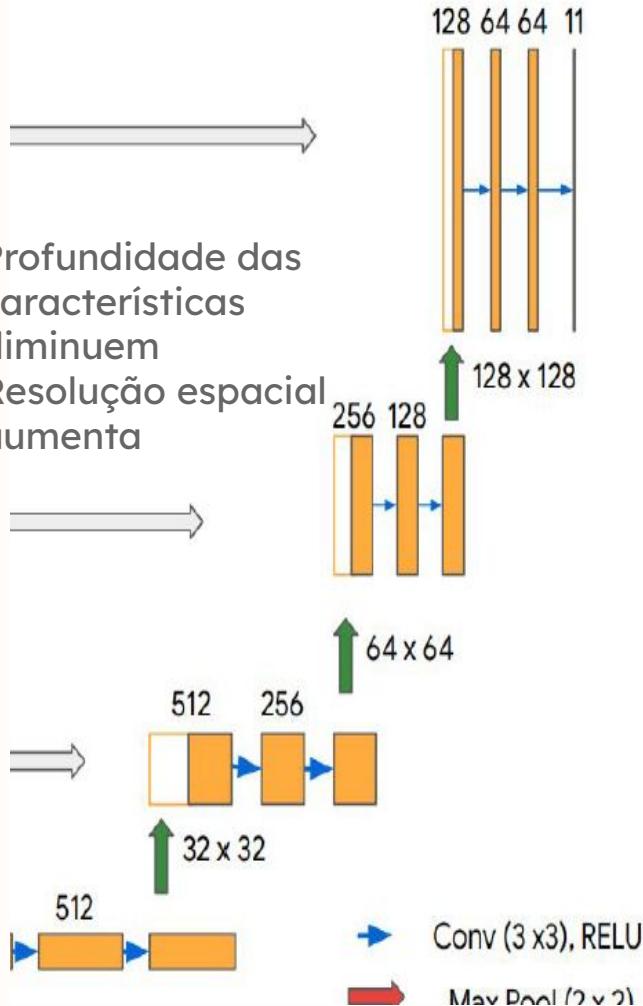


■ Convolution+ReLU
■ Max-Pooling

Layer	Input	Type	Output
Block1	572 x 572 x 3	Encoder	284 x 284 x 64
Block2	284 x 284 x 64	Encoder	140 x 140 x 128
Block3	140 x 140 x 128	Encoder	68 x 68 x 256
Block4	68 x 68 x 256	Encoder	32 x 32 x 512
Block5	32 x 32 x 512	Bottleneck	28 x 28 x 1024

UNet Arquitetura - Expansão (Decoder)

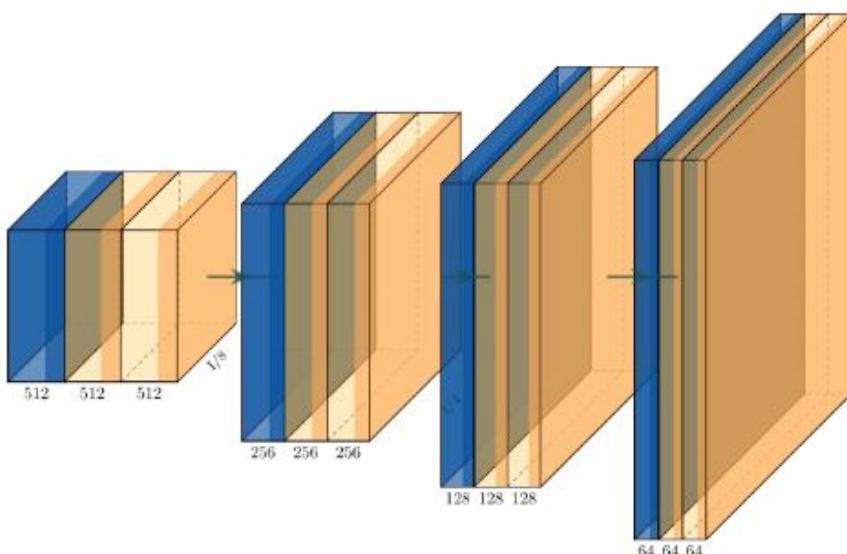
- Profundidade das características diminuem
- Resolução espacial aumenta



- Caminho de expansão: Upsample dos mapas de ativação seguidas por up-convolution 2×2 que divide por 2 a profundidade do mapa (reduz o número de canais das features), uma concatenação com o mapa de ativação correspondente a contração do mesmo nível e convoluções 3×3 com ativação ReLU
- Na última camada uma convolução 1×1 é utilizada para mapear o vetor de features (dimensão 64) para o número de classes desejada

UNet Arquitetura - Expansão (Decoder)

Decoder

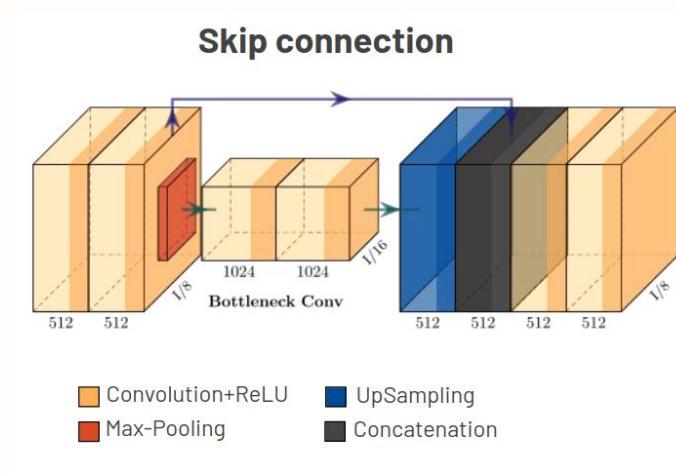


■ Convolution+ReLU
■ UpSampling

Layer	Input	Type	Output
Block6	28 x 28 x 1024	Decoder	52 x 52 x 512
Block7	52 x 52 x 512	Decoder	100 x 100 x 256
Block8	100 x 100 x 256	Decoder	196 x 196 x 128
Block9	196 x 196 x 128	Decoder	388 x 388 x 64

UNet Arquitetura - Skip connections

- DNNs podem esquecer certas características na medida que avança na arquitetura por sucessivas camadas
- Skip connections reforça o aprendizado, introduzindo as informações de camadas anteriores em pontos mais avançados da arquitetura
- U-Net utiliza skip connections em cada passo da expansão (decoder) a partir das ativações correspondentes de cada passo da contração (encoder)



UNet Arquitetura - Skip connections

- U-Net segmenta com base em detalhes de baixo nível e características genéricas
 - ◆ Arquiteturas Encoder-Decoder extraem características mais genéricas na medida em que avançam na arquitetura
 - ◆ Skip connections reintroduz features de baixo nível (detalhes)

UNet - Otimização e Loss

→ Categorical cross-entropy

$$L = \sum_{c=1}^k x_c \odot \log (\text{softmax}(\hat{x}_c))$$

$$\text{softmax}(\hat{x}_c) = \frac{\exp(\hat{x}_c)}{\sum_{j=1}^k \exp(\hat{x}_j)}$$

UNet - Otimização e Loss

→ Dice

$$L = 1 - \frac{2 \sum_{i=1}^N \text{softmax}(\hat{x}_c) \odot x_c + \epsilon}{\sum_{i=1}^N x_c + \sum_{i=1}^N \text{softmax}(\hat{x}_c) + \epsilon}$$

Segmentação - Comparação de utilização em segmentação das arquiteturas de deep learning

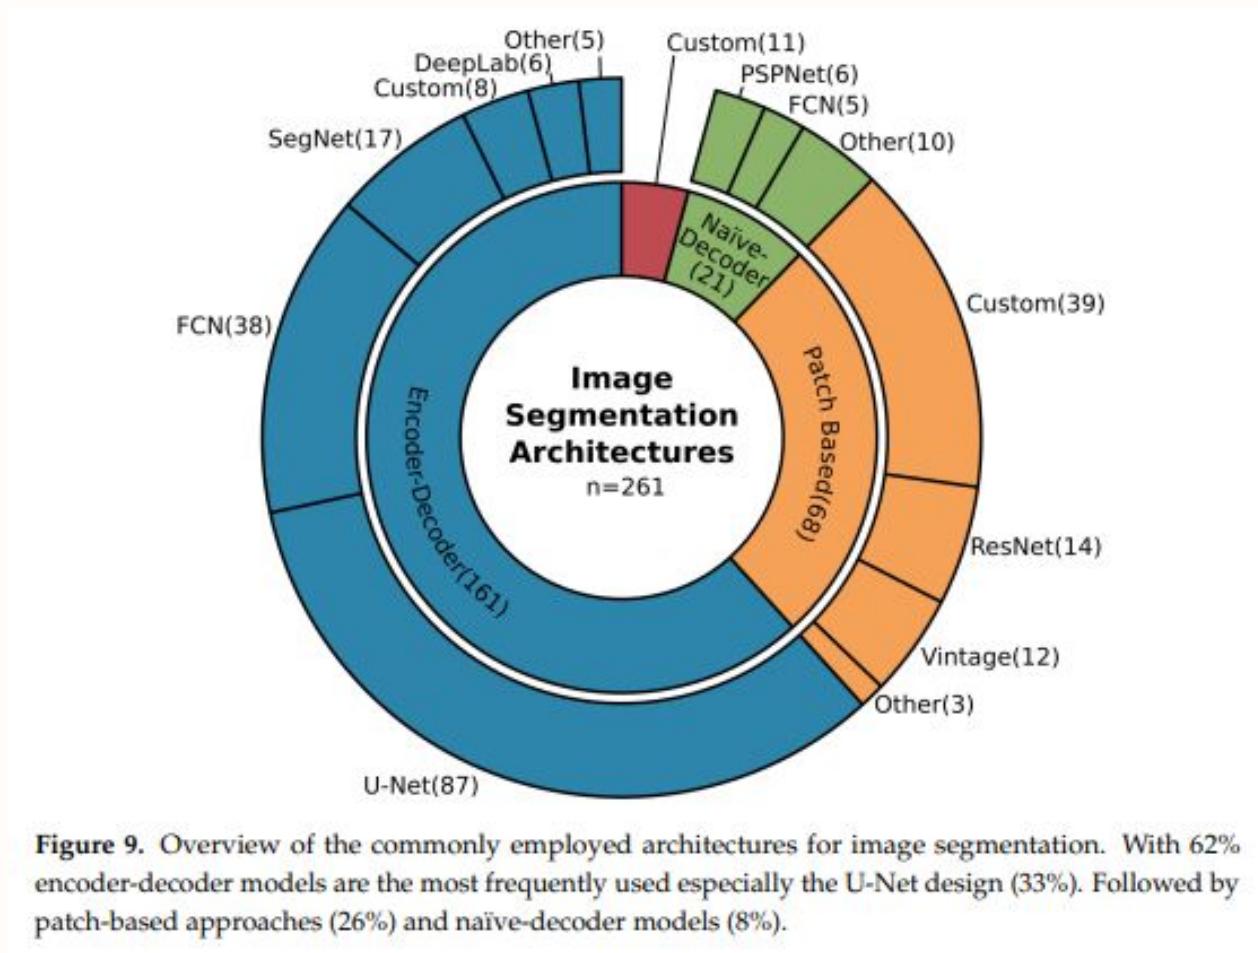
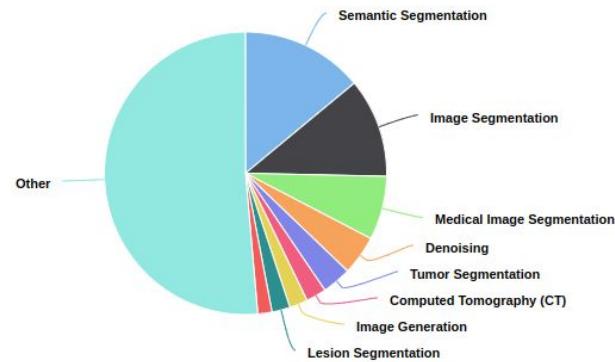


Figure 9. Overview of the commonly employed architectures for image segmentation. With 62% encoder-decoder models are the most frequently used especially the U-Net design (33%). Followed by patch-based approaches (26%) and naïve-decoder models (8%).

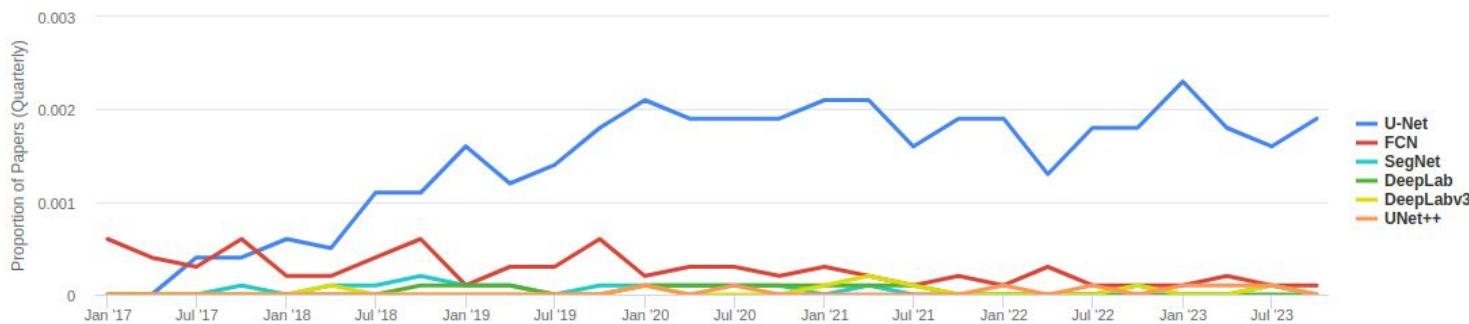
Segmentação - UNet - Aplicações e utilização

Tasks



Task	Papers	Share
Semantic Segmentation	121	14.00%
Image Segmentation	98	11.34%
Medical Image Segmentation	63	7.29%
Denoising	39	4.51%
Tumor Segmentation	29	3.36%
Computed Tomography (CT)	20	2.31%
Image Generation	18	2.08%
Lesion Segmentation	18	2.08%
Super-Resolution	14	1.62%

Usage Over Time



Variações UNet

Aproximadamente 68.700 resultados (0,05 s)

Unet 3+: A full-scale connected unet for medical image segmentation
H Huang, L Lin, R Tong, H Hu, Q Zhang... - ICASSP 2020-2020 ..., 2020 - ieeexplore.ieee.org
... In this section, we first compared the proposed **UNet** 3+ with **UNet** and **UNet++**. The loss ...
In this paper, we proposed a full-scale connected **UNet**, named **UNet** 3+ with deep supervision ...
☆ Salvar 99 Citar Citado por 1202 Artigos relacionados Todas as 4 versões

Sa-unet: Spatial attention u-net for retinal vessel segmentation
C Guo, M Szemenyei, Y Yi, W Wang... - ... conference on pattern ..., 2021 - ieeexplore.ieee.org
... Spatial Attention U-Net (SA-**UNet**) that does not require thousands of ... SA-**UNet** introduces a spatial attention module which infers ... We evaluate SA-**UNet** based on two benchmark retinal ...
☆ Salvar 99 Citar Citado por 233 Artigos relacionados Todas as 5 versões

[HTML] Review of Semantic Segmentation of Medical Images Using Modified Architectures of **UNET**
M Kirthika alias AnbuDevi, K Suganthi - Diagnostics, 2022 - mdpi.com
... **UNET** is the deep learning network that segments the critical ... of **UNET** suitable for increasing segmentation accuracy. ... This section highlights the modified architecture of **UNET** for ...
☆ Salvar 99 Citar Citado por 8 Artigos relacionados Todas as 7 versões Web of Science

Swin-unet: Unet-like pure transformer for medical image segmentation
H Cao, Y Wang, J Chen, D Jiang, X Zhang... - European conference on ..., 2022 - Springer
... In this paper, we propose Swin-**UNet**, which is an **Unet**-like pure Transformer for medical image segmentation. The tokenized image patches are fed into the Transformer-based U-...
☆ Salvar 99 Citar Citado por 1235 Artigos relacionados Todas as 6 versões

RIC-Unet: An improved neural network based on **UNet for nuclei segmentation in histology images**
Z Zeng, W Xie, Y Zhang, Y Lu - Ieee Access, 2019 - ieeexplore.ieee.org
... In this paper, an **UNet**-based neural network, RIC-**Unet** (residual-inception-channel attention-**UNet**)... attention mechanism are applied on RIC-**Unet** to segment nuclei more accurately. ...
☆ Salvar 99 Citar Citado por 216 Artigos relacionados Todas as 2 versões Web of Science: 138

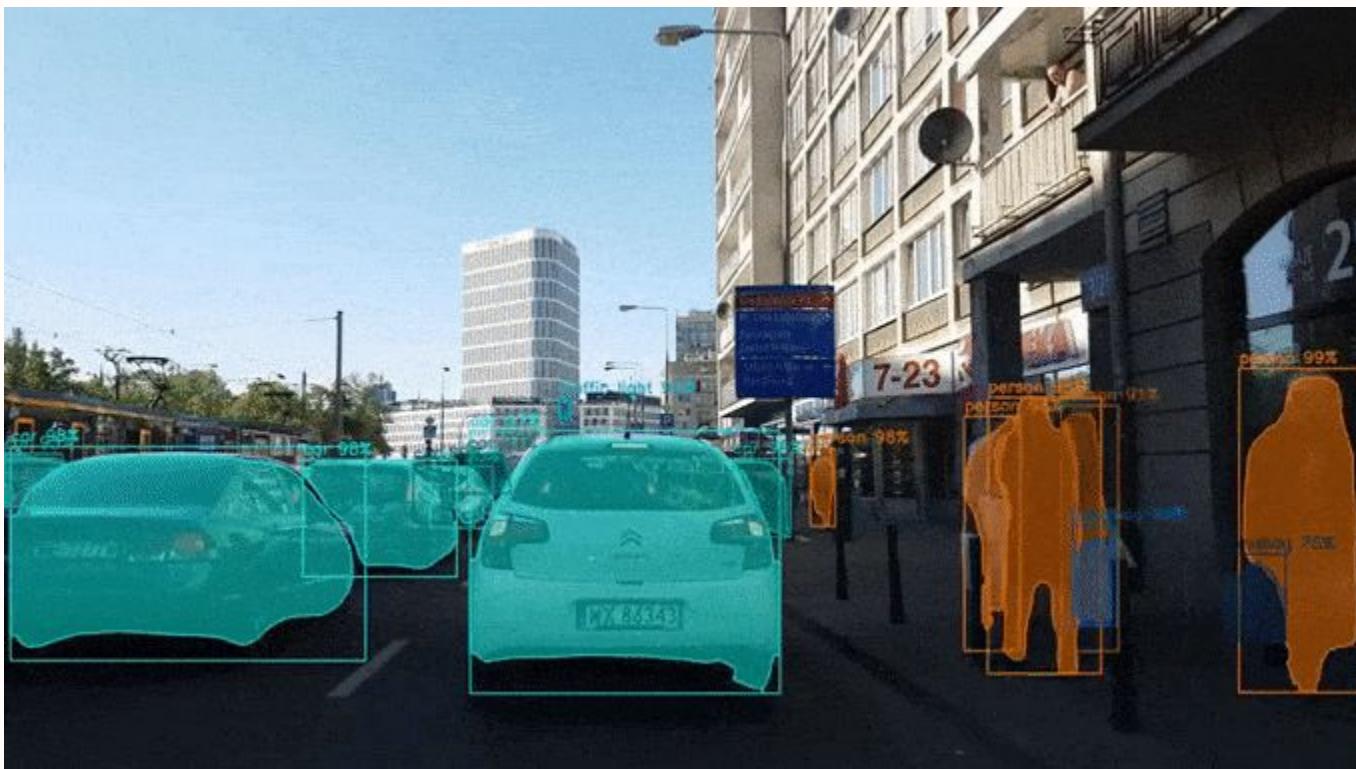
Fully dense **UNet for 2-D sparse photoacoustic tomography artifact removal**
S Guan, AA Khan, S Sikdar... - IEEE journal of ..., 2019 - ieeexplore.ieee.org
... We compare the FD-**UNet** and the **UNet** using datasets generated from synthetic phantoms (circles, Shepp-Logan, and vasculature) and an anatomically realistic mouse brain ...
☆ Salvar 99 Citar Citado por 341 Artigos relacionados Todas as 10 versões Web of Science: 187

Swin transformer embedding **UNet for remote sensing image semantic segmentation**
X He, Y Zhou, J Zhao, D Zhang... - IEEE Transactions on ..., 2022 - ieeexplore.ieee.org
... -**UNet** is shown in Fig. 3. As a hybrid of the Swin transformer and **UNet**, our ST-**UNet** follows the excellent structure of **UNet**, ... In particular, ST-**UNet** constructs the dual encoder composed ...
☆ Salvar 99 Citar Citado por 109 Artigos relacionados Todas as 2 versões Web of Science: 73

[HTML] SmaAt-**UNet**: Precipitation nowcasting using a small attention-**UNet** architecture
K Trebing, T Stanczyk, S Mehrkanooon - Pattern Recognition Letters, 2021 - Elsevier
... in this study, ie the original **UNet**, **UNet** with CBAM, **UNet** with DSCs, and our proposed model. Table 1 ... When looking at the standard **UNet** architecture and our proposed modified **UNet** ...
☆ Salvar 99 Citar Citado por 191 Artigos relacionados Todas as 8 versões Web of Science: 101

H-DenseUNet: hybrid densely connected **UNet for liver and tumor segmentation from CT volumes**
X Li, H Chen, X Qi, Q Dou, CW Fu... - IEEE transactions on ..., 2018 - ieeexplore.ieee.org
... 3) Effectiveness of **UNet** Connections: We analyze the effectiveness of **UNet** connections in our proposed framework. Both 2D DenseNet and DenseUNet are trained with the same pre-...
☆ Salvar 99 Citar Citado por 1738 Artigos relacionados Todas as 9 versões Web of Science: 917

Aplicações



https://github.com/matterport/Mask_RCNN

<https://www.youtube.com/watch?v=OOT3UIXZztE>

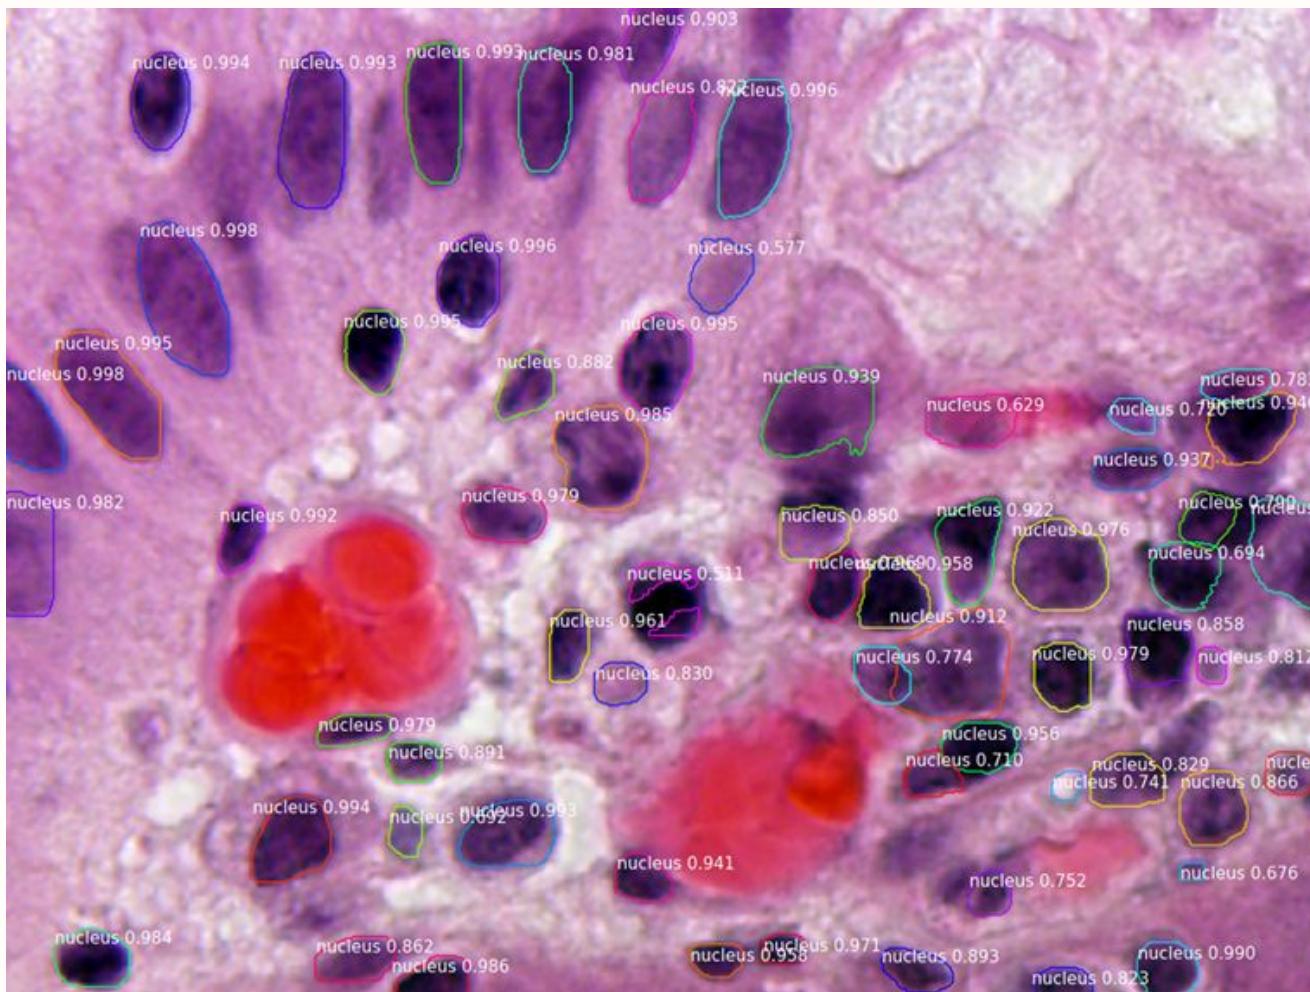
Aplicações



https://github.com/matterport/Mask_RCNN

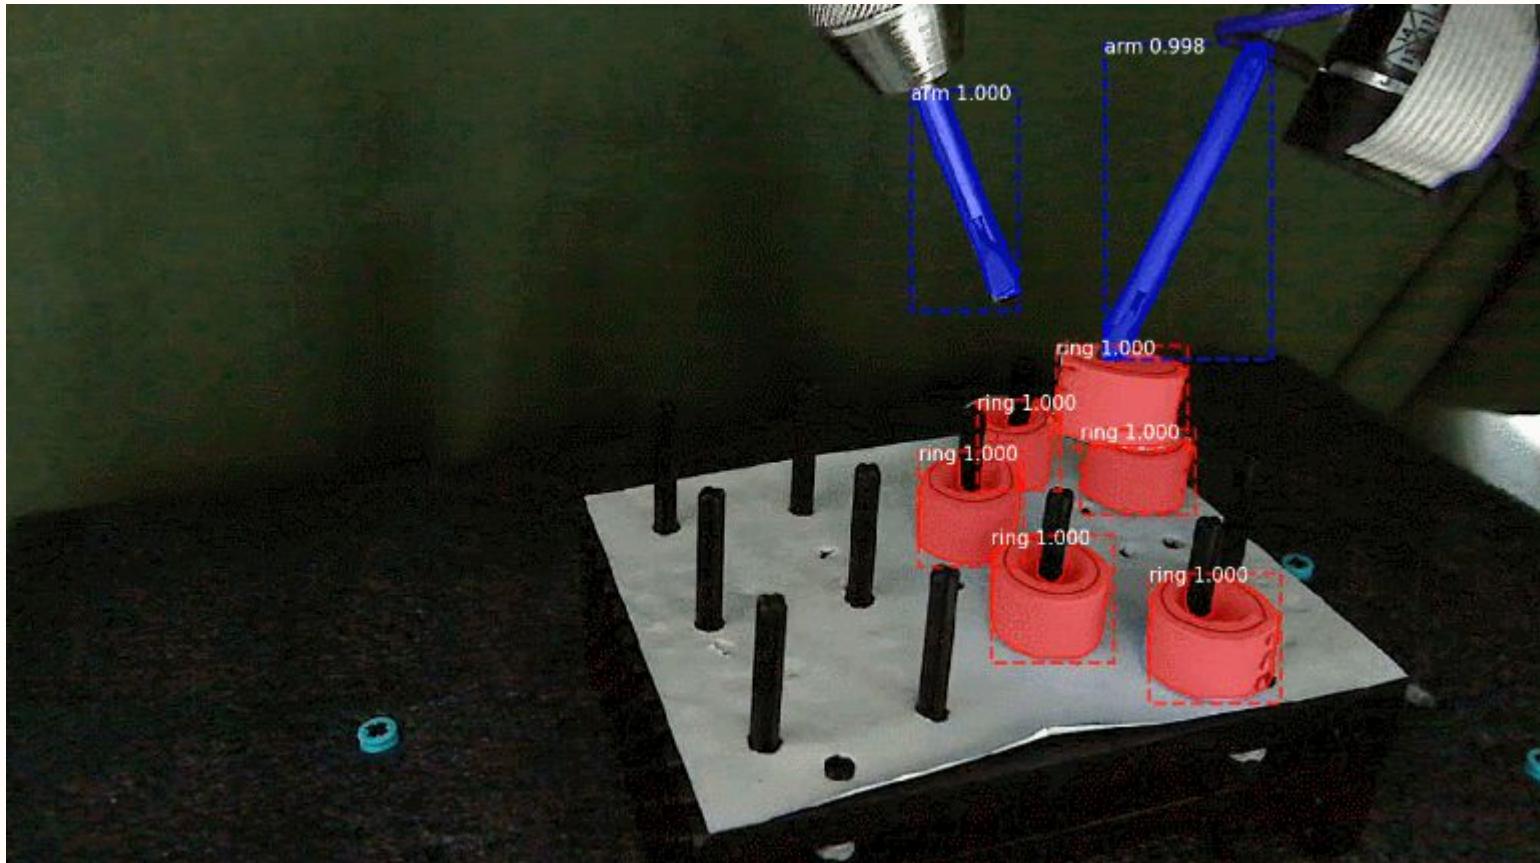
<https://github.com/jremillard/images-to-osm>

Aplicações



https://github.com/matterport/Mask_RCNN/tree/master/samples/nucleus

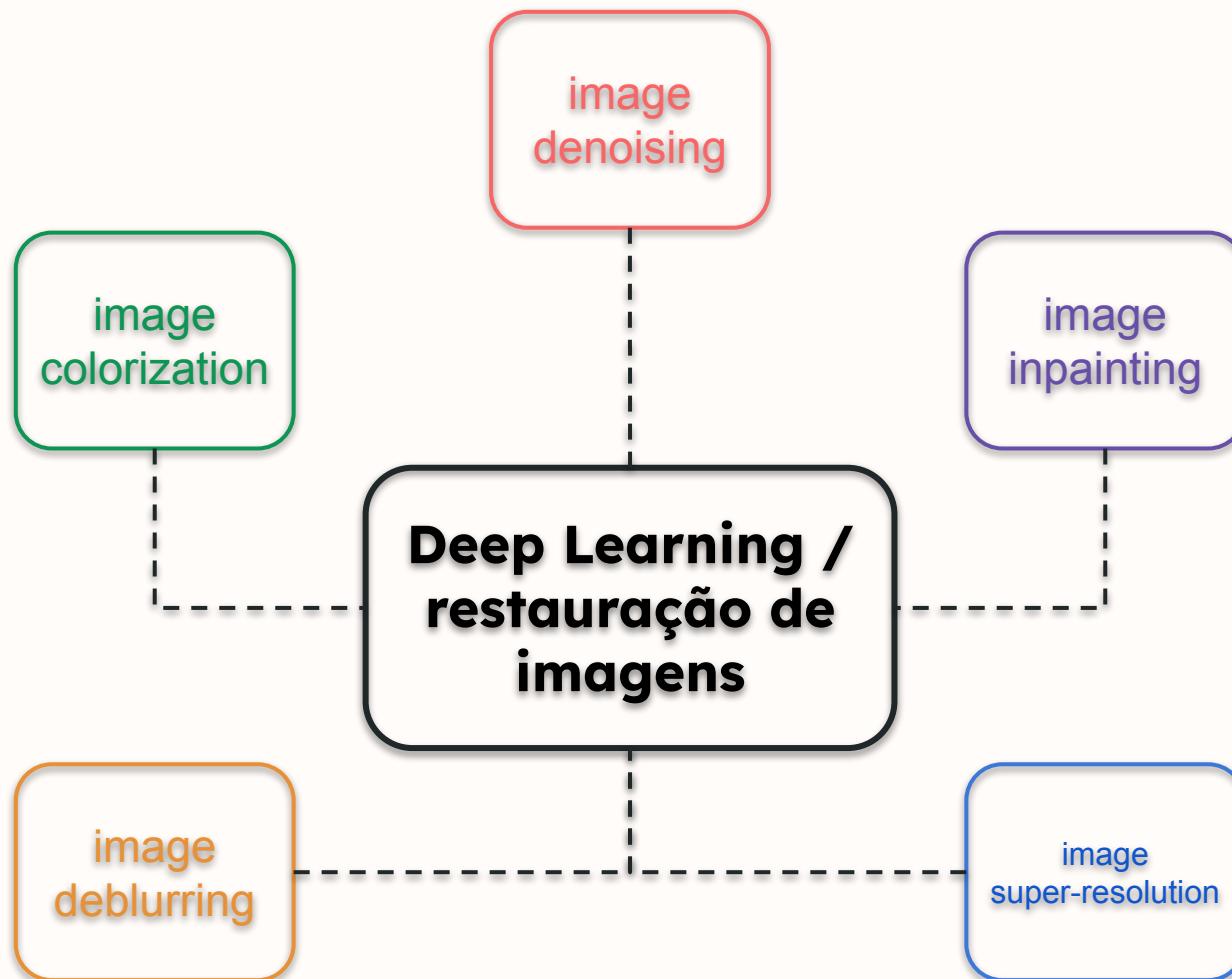
Aplicações



<https://github.com/SUYEgit/Surgery-Robot-Detection-Segmentation>

Aplicações - Restauração de imagens e deep learning

Visão geral



Restauração

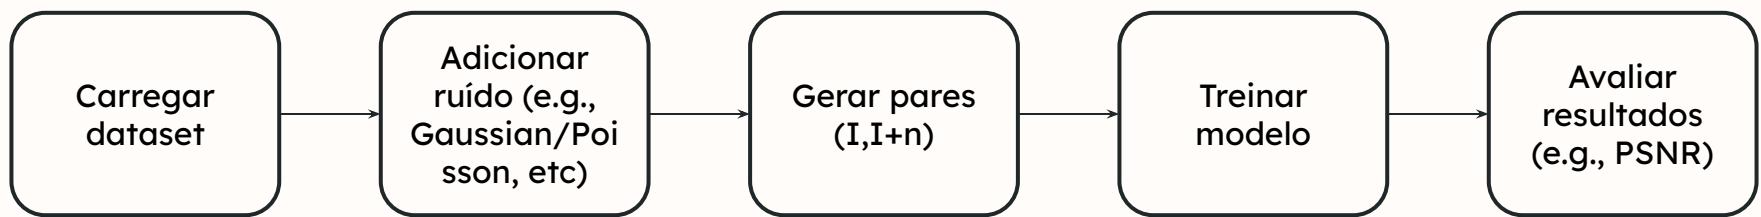


Image denoising e deblurring

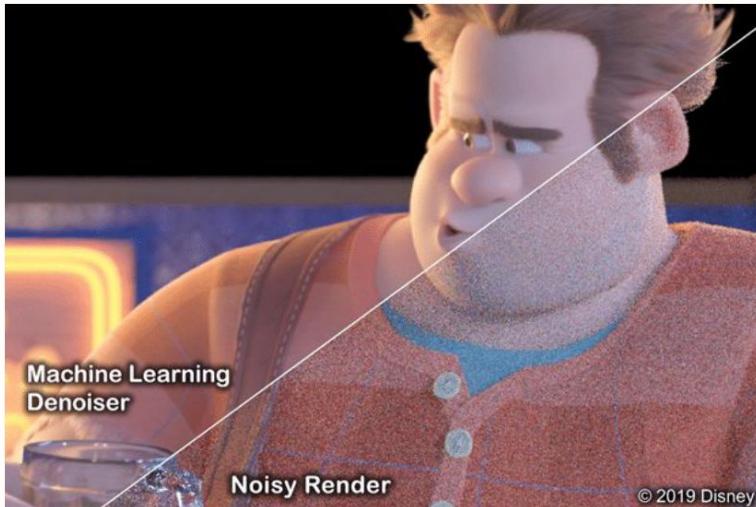


Image colorization

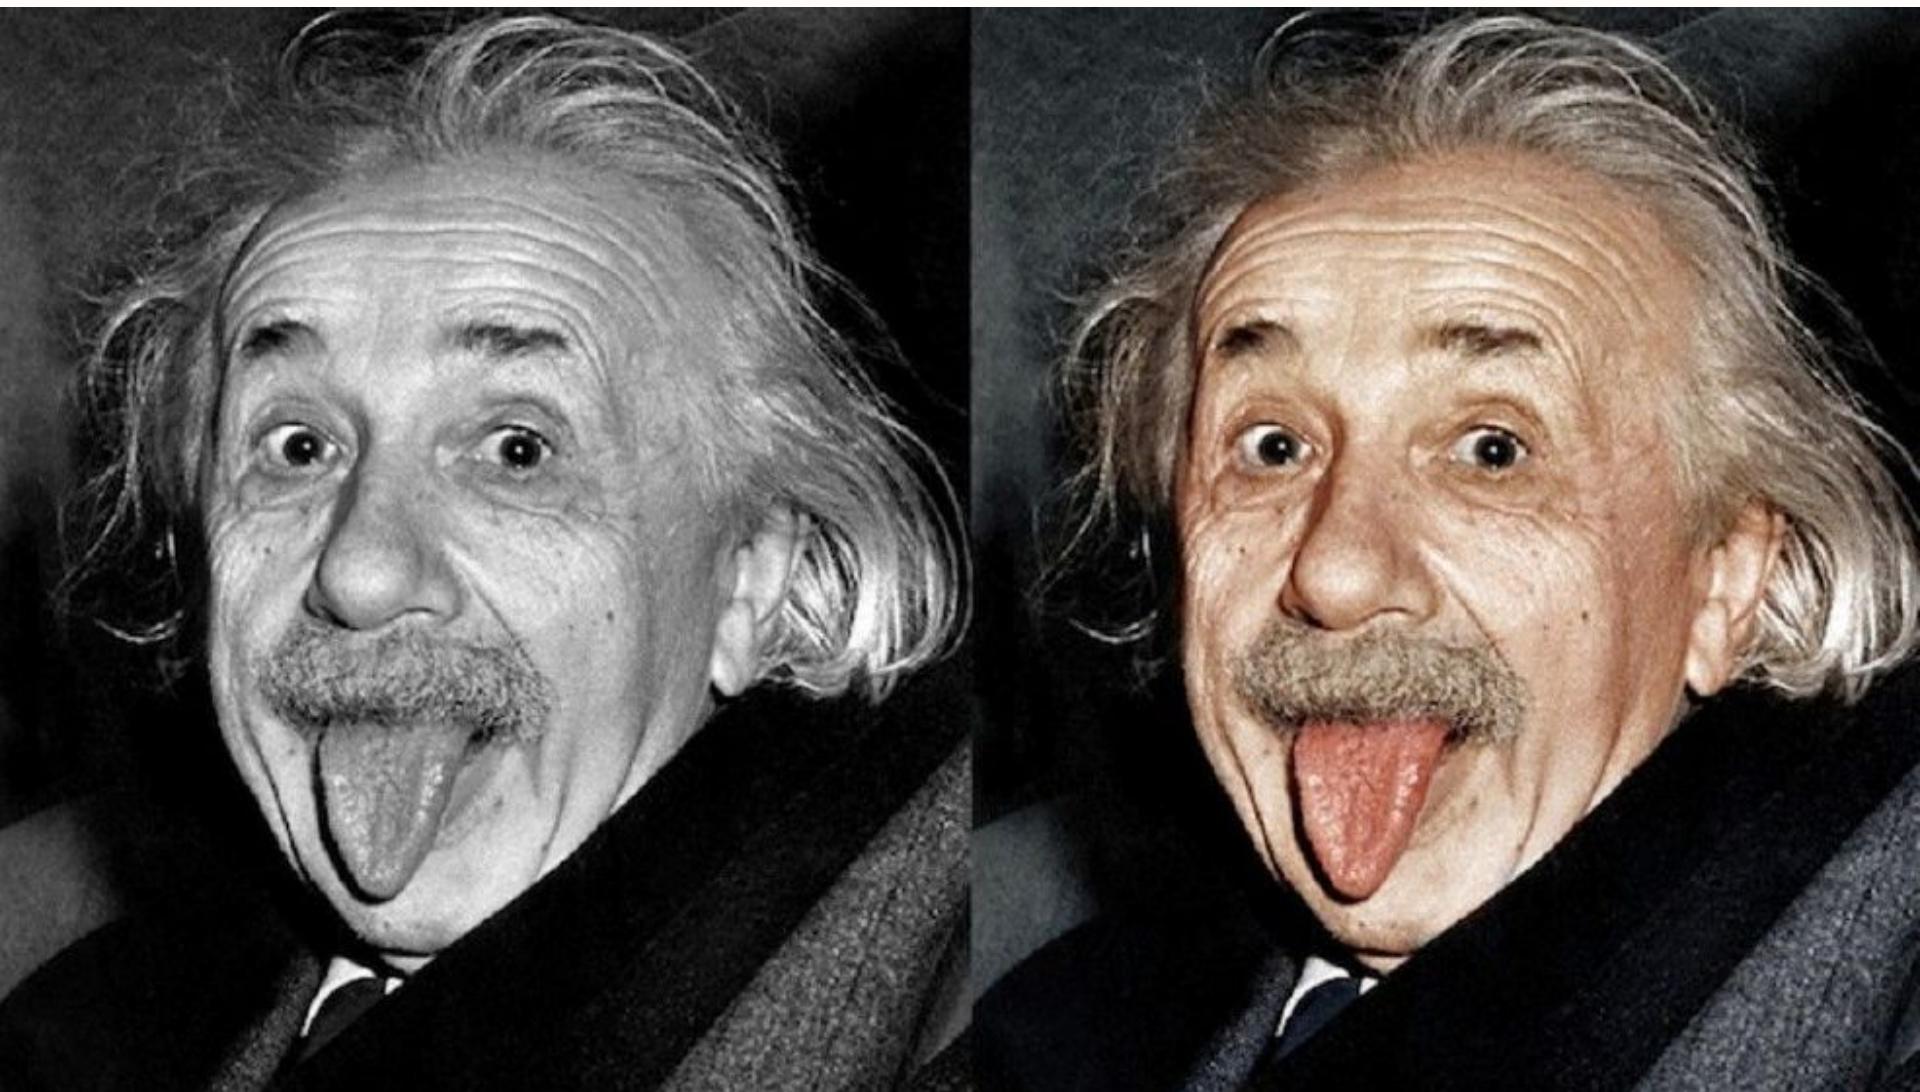


Image super-resolution

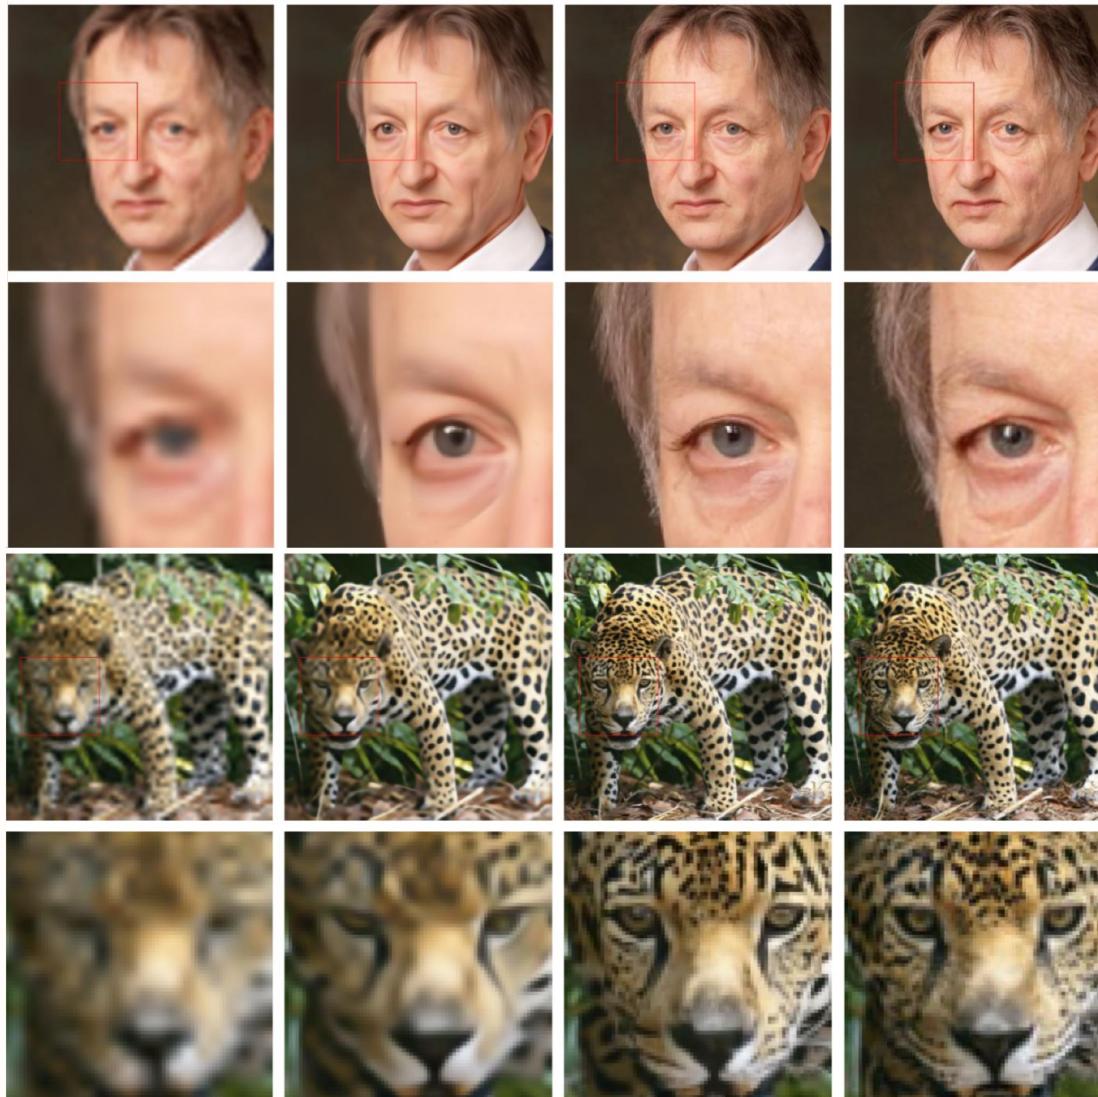
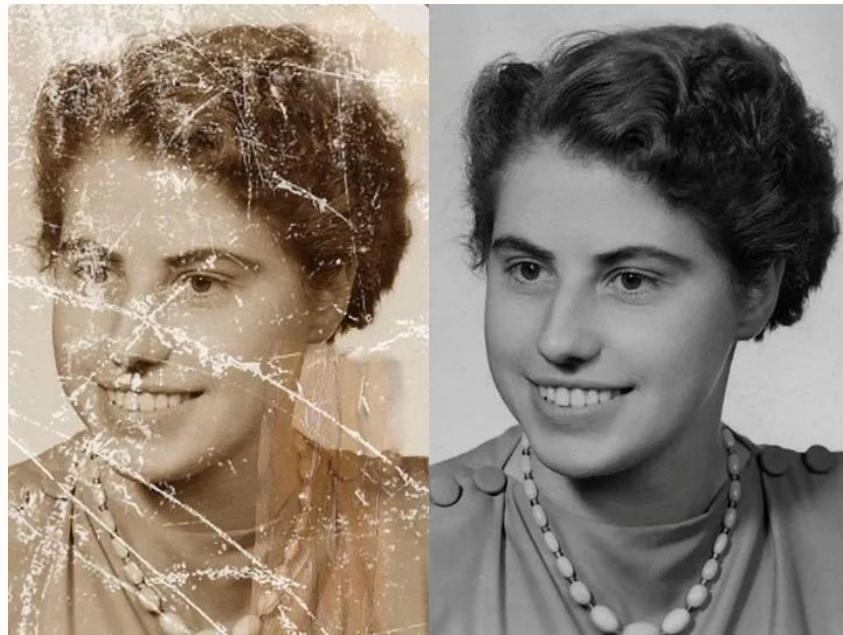


Image inpainting



Detecção e Segmentação de objetos

Aprendizado de máquina e aprendizado
profundo - Lux.AI
luxai.cin.ufpe.br

INSTITUIÇÃO EXECUTORA



COORDENADORA



APOIO

MINISTÉRIO DA
CIÊNCIA, TECNOLOGIA
E INOVAÇÃO

